

1.1 传统数据集成

数据集成的目标是为多个自治数据源中的数据提供统一的存取。这一目标说起来容易，但实现起来已被证明异常困难，即使是针对少量几个结构化数据源，即传统的数据集成[Doan et al. 2012]。

为了理解数据集成中一些挑战性的问题，这里用一个航空领域的例子来说明。该领域的常见任务是跟踪航班的起飞和降落，检查航班时刻表以及预定航班等。

1.1.1 航班示例：数据源

我们有一些不同类型的数据源，包括：两个航空公司数据源 **Airline1** 和 **Airline2**（如美国联合航空公司、美国航空公司、达美等），分别提供自家航空公司航班的信息；一个机场数据源 **Airport3**，提供在某机场（如 **EWB**、**SFO**）出发和到达航班的信息；以及一个旅行数据源 **Airfare4**（如 **Kayak**、**Orbitz** 等），提供不同航班不同价位的票价信息；还有一个信息类数据源 **Airinfo5**（如 **Wikipedia table**），提供有关机场和航空公司的数据。

各数据源的样例数据如表 1-1~表 1-8 所示。为简便起见，表中使用缩写的属性名，属性名的缩写和全称的对应关系见表 1-9。下面解释各表的具体内容。

1. 数据源 **Airline1**

数据源 **Airline1** 提供两张关系表 **Airline1.Schedule**（**Flight Id**, **Flight Number**, **Start Date**, **End Date**, **Departure Time**, **Departure**

Airport, Arrival Time, Arrival Airport) 和 Airline1.Flight (Flight Id, Departure Date, Departure Time, Departure Gate, Arrival Date, Arrival Time, Arrival Gate, Plane Id)。加下划线的属性构成相应表的主键。Flight Id 被用作两张表的连接键。

关系表 Airline1.Schedule 如表 1-1 所示，显示了航班的时间计划表。例如，Airline1.Schedule 中的记录 r11 说明 Airline1 航空公司的 49 号航班在 2013-10-01 到 2014-03-31 期间，固定从 EWR 飞往 SFO，起飞时间 18:05，到达时间 21:10。记录 r12 显示同一航班在 2014-04-01 到 2014-09-30 期间安排了另外的起飞降落时间。记录 r13 和 r14 分别显示了 55 号航班在 2013-10-01 到 2014-09-30 期间两个飞行段的安排，第一段从 ORD 飞到 BOS，第二段从 BOS 飞到 EWR。

关系表 Airline1.Flight 如表 1-2 所示，显示了 Airline1.Schedule 中航班的实际起飞和到达信息。例如，Airline1.Flight 中的 r21 记录了对应于 r11 (FI 等于 123，为两者的连接键) 的航班的一次具体的飞行，即 PI (飞机号) 为 4013 的飞机，实际于 2013-12-21 的 18:45 (比计划的时间 18:05 晚 40 分钟) 从 C98 登机口起飞，并于 2013-12-21 的 21:30 (比计划的时间 21:10 晚 20 分钟) 降落在 81 号登机口。记录 r11 和 r21 都用浅灰高亮显示以表示它们的关系。同一张表中的记录 r22 记录了航班 r11 的另外一次实际飞行，比计划的起飞降落时间有更大的延迟。记录 r23 和 r24 记录的是 2013-12-29 航班 r13

和 r14 的飞行信息。

表1-1 Airline1.Schedule的样例数据

	FI	FN	SD	ED	DT	DA	AT	AA
r ₁₁	123	49	2013-10-01	2014-03-31	18:05	EWR	21:10	SFO
r ₁₂	234	49	2014-04-01	2014-09-30	18:20	EWR	21:25	SFO
r ₁₃	345	55	2013-10-01	2014-09-30	18:30	ORD	21:30	BOS
r ₁₄	346	55	2013-10-01	2014-09-30	22:30	BOS	23:30	EWR

表1-2 Airline1.Flight的样例数据

	FI	DD	DT	DG	AD	AT	AG	PI
r ₂₁	123	2013-12-21	18:45	C98	2013-12-21	21:30	81	4013
r ₂₂	123	2013-12-28	21:30	C101	2013-12-29	00:30	81	3008
r ₂₃	345	2013-12-29	18:30	B6	2013-12-29	21:45	C18	4013
r ₂₄	346	2013-12-29	22:35	C18	2013-12-29	23:35	C101	4013

2. 数据源 Airline2

数据源 Airline2 提供的信息类似于数据源 Airline1，但是使用的是关系表 Airline2.Flight（Flight Number, Departure Airport, Scheduled Departure Date, Scheduled Departure Time, Actual Departure Time, Arrival Airport, Scheduled Arrival Date, Scheduled Arrival Time, Actual Arrival Time）。

关系表 Airline2.Flight 如表 1-3 所示，包含计划的和实际的航班信息。例如，记录 r31 记录了 Airline2 航空公司的 53 号航班计划 2013-12-21 的 15:30 从 SFO 起飞，但实际延迟 30 分钟，计划 2013-12-21 的 23:35 抵达 EWR，但实际晚点了 40 分钟，第二天（表中显示 +1d）即 2013-12-22 到达。注意表中有一条关于 Airline2 航空公司 49 号航班的记录 r35，它不同于 Ailine1 航空公司的 49 号航班。这表明不同航空公司可以使用相同的航班号。

不同于数据源 Airline1，数据源 Airline2 没有发布出发登机口和到

达登机口以及飞机号。这表明这些数据源的模式之间是有差异的。

表1-3 Airline2.Flight的样例数据

	FN	DA	SDD	SDT	ADT	AA	SAD	SAT	AAT
r ₃₁	53	SFO	2013-12-21	15:30	16:00	EWR	2013-12-21	23:35	00:15 (+1d)
r ₃₂	53	SFO	2013-12-22	15:30	16:15	EWR	2013-12-22	23:35	00:30
r ₃₃	53	SFO	2014-06-28	16:00	16:05	EWR	2014-06-29	00:05	23:57 (-1d)
r ₃₄	53	SFO	2014-07-06	16:00	16:00	EWR	2014-07-07	00:05	00:09
r ₃₅	49	SFO	2013-12-21	12:00	12:35	EWR	2013-12-21	20:05	20:45
r ₃₆	77	LAX	2013-12-22	09:15	09:15	SFO	2013-12-22	11:00	10:59

3. 数据源 Airport3

数据源 Airport3 提供两张关系表 Airport3.Departures (Air Line, Flight Number, Scheduled, Actual, Gate Time, Takeoff Time, Terminal, Gate, Runway) 和 Airport3.Arrivals (Air Line, Flight Number, Scheduled, Actual, Gate Time, Landing Time, Terminal, Gate, Runway)。

关系表 Airport3.Departures 如表 1-4 所示，仅发布了从 EWR 机场起飞的航班。例如，表中的记录 r₄₁ 记录了 Airline1 航空公司的 49 号航班，计划在 2013-12-21 的 18:45 从航站楼 C 的 98 号登机口出发，18:53 从跑道 2 起飞。表中没有该航班的到达机场、到达日期和时间的信息。注意 r₄₁ 对应于记录 r₁₁ 和 r₂₁，同样用浅灰高亮显示。

表1-4 Airport3.Departures的样例数据

	AL	FN	S	A	GT	TT	T	G	R
r ₄₁	A1	49	2013-12-21	2013-12-21	18:45	18:53	C	98	2
r ₄₂	A1	49	2013-12-28	2013-12-28	21:29	21:38	C	101	2

关系表 Airport3.Arrivals 如表 1-5 所示，仅发布了到达 EWR 机场的航班。例如，表中的记录 r₅₁ 记录了 Airline2 航空公司的 53 号航班，计划 2013-12-21 到达，实际 2013-12-22 到达，于 00:15 在跑道 2 降落，00:21 抵达航站楼 B 的 53 号登机口。表中没有该航班的出发机

场、出发日期和时间。注意 r51 对应于记录 r31。

表 1-5 Airport3.Arrivals 的样例数据

	AL	FN	S	A	GT	LT	T	G	R
r ₅₁	A2	53	2013-12-21	2013-12-22	00:21	00:15	B	53	2
r ₅₂	A2	53	2013-12-22	2013-12-23	00:40	00:30	B	53	2
r ₅₃	A1	55	2013-12-29	2013-12-29	23:35	23:31	C	101	1
r ₅₄	A2	49	2013-12-21	2013-12-21	20:50	20:45	B	55	2

不同于数据源 Airline1 和 Airline2，数据源 Airport3 区分航班离开/到达登机口的时间和在机场跑道上起飞/降落的时间。

4. 数据源 Airfare4

旅行数据源 Airfare4 发布对不同航空公司售票信息的比较，包括航班的时间计划 Airfare4.Flight（Flight Id, Flight Number, Departure Airport, Departure Date, Departure Time, Arrival Airport, Arrival Time）以及机票价格 Airfare4.Fares（Flight Id, Fare Class, Fare）。Flight Id 被用作两表的连接键。

例如，如表 1-6 所示，Airfare4.Flight 中的记录 r61 显示 Airline1 航空公司的航班 A1-49 计划于 2013-12-21 的 18:05 从 Newark Liberty 机场出发，并于当天的 21:10 抵达 San Francisco 机场。注意 r61 对应于记录 r11、r21 和 r41。

关系表 Airfare4.Fares 中的记录如表 1-7 所示，给出了该航班的各类票价。例如，记录 r71 显示该航班的 A 类票价是\$5799.00；FI456 是连接键。

表1-6 Airfare4.Flight的样例数据

	FI	FN	DA	DD	DT	AA	AT
<i>r</i> ₆₁	456	A1-49	Newark Liberty	2013-12-21	18:05	San Francisco	21:10
<i>r</i> ₆₂	457	A1-49	Newark Liberty	2014-04-05	18:05	San Francisco	21:10
<i>r</i> ₆₃	458	A1-49	Newark Liberty	2014-04-12	18:05	San Francisco	21:10
<i>r</i> ₆₄	460	A2-53	San Francisco	2013-12-22	15:30	Newark Liberty	23:35
<i>r</i> ₆₅	461	A2-53	San Francisco	2014-06-28	15:30	Newark Liberty	23:35
<i>r</i> ₆₆	462	A2-53	San Francisco	2014-07-06	16:00	Newark Liberty	00:05 (+1d)

表1-7 Airfare4.Fares的样例数据

	FI	FC	F
<i>r</i> ₇₁	456	A	\$5799.00
<i>r</i> ₇₂	456	K	\$999.00
<i>r</i> ₇₃	456	Y	\$599.00

5. 数据源 Airinfo5

数据源 Airinfo5 发布的是关于机场和航空公司的信息，即关系表 Airinfo5.AirportCodes（Airport Code, Airport Name）和 Airinfo5.AirlineCodes（Air Line Code, Air Line Name）。

例如，如表 1-8 所示，Airinfo5.AirportCodes 中的记录 *r*₈₁ 显示代号为 EWR 的机场是美国新泽西州的 Newark Liberty 机场。类似地，Airinfo5.AirlineCodes 的记录 *r*₉₁ 显示代号为 A1 的航空公司是 Airline1 航空公司。

表1-8 Airinfo5.AirportCodes和Airinfo5.AirlineCodes的样例数据

	Airinfo5.AirportCodes			Airinfo5.AirlineCodes	
	AC	AN		ALC	ALN
r_{81}	EWR	Newark Liberty, NJ, US	r_{91}	A1	Airline1
r_{82}	SFO	San Francisco, CA, US	r_{92}	A2	Airline2

表1-9 缩写的属性名称

缩写	全称	缩写	全称
A	Actual	AA	Arrival Airport
AAT	Actual Arrival Time	AC	Airport Code
AD	Arrival Date	ADT	Actual Departure Time
AG	Arrival Gate	AL	Air Line
ALC	Air Line Code	ALN	Air Line Name
AN	Airport Name	AT	Arrival Time
DA	Departure Airport	DD	Departure Date
DG	Departure Gate	DT	Departure Time
ED	End Date	F	Fare
FC	Fare Class	FI	Flight Id
FN	Flight Number	G	Gate
GT	Gate Time	LT	Landing Time
PI	Plane Id	R	Runway
S	Scheduled	SAD	Scheduled Arrival Date
SAT	Scheduled Arrival Time	SD	Start Date
SDD	Scheduled Departure Date	SDT	Scheduled Departure Time
T	Terminal	TT	Takeoff Time

1.1.2 航班示例：数据集成

虽然 5 个数据源单独都是有用的，但当它们被集成在一起时，这些数据的价值将被大大提升。

1. 集成数据源

首先，每个航空公司数据源（如 Airline1、Airline2）都从与机场数据源 Airport3 的链接中获益，因为机场数据源提供了航班实际出发和到达的详细信息，如登机时间、起飞降落的时间和使用的跑道；这些可以帮助航空公司更好地分析航班延误的原因。其次，机场数据源 Airport3 也可以从与航空公司数据源（如 Airline1、Airline2）的链接中

获益，因为航空公司数据源提供了关于航班时刻表和整体飞行计划的详细信息（尤其是对那些多段飞行的航班，如 **Airline1** 的 55 号航班）；这些可以帮助机场更好地理解航班的飞行模式。第三，旅行数据源 **Airfare4** 可以通过链接航空公司数据源和机场数据源提供一些附加信息，例如历史上准点起飞/到达的统计数据等；而这些信息对预定航班的用户可能非常有用。这种关联使得信息源 **Airinfo5** 非常关键。这一点我们在后面会看到。最后，将所有这些不同数据源集成起来也会使用户获益，因为他们不需要分别去访问多个数据源才能获得自己想要的信息。

例如，查询“计算出上个月每个航班的计划和实际出发时间之间的平均延迟，以及实际登机 and 起飞时间之间的平均延迟”可以在集成起来的数据库上作答，却无法用任一单个的数据源回答。

然而，集成多个自治的数据源非常困难，经常需要大量人工的努力去理解每个数据源的数据语义以解决歧义性问题。让我们再一次看一下航班的示例。

2. 语义歧义性

为了正确对齐各种数据源表，我们需要理解：i) 同一概念信息在不同数据源中的表示可能非常不同；ii) 不同概念信息在不同数据源中的表示可能很相似。

例如，数据源 **Airline1** 在表 **Airline1.Schedule** 中给出在一定日期范围内（由 **Start Date** 和 **End Date** 所指定）的航班时刻表，使用属性 **Departure Time** 和 **Arrival Time** 记录时间信息。然而，数据源 **Airline2**

在表 **Airline2.Flight** 中一起给出了航班时刻表和实际航班的飞行信息，每次不同的飞行用不同的记录描述，并且使用不同的属性名称，**Scheduled Departure Date**，**Scheduled Departure Time**，**Scheduled Arrival Date**，**Scheduled Arrival Time**。

又如，数据源 **Airport3** 既记录了航班的实际登机口出发/到达时间（表 **Airport3.Departures** 和表 **Airport3.Arrivals** 中的 **Gate Time**），也记录了实际起飞/降落时间（表 **Airport3.Departures** 中的 **Takeoff Time** 和表 **Airport3.Arrivals** 中的 **Landing Time**）。而 **Airline1** 和 **Airline2** 数据源只记录其中一种时间，具体地，仔细检查数据就会发现，数据源 **Airline1** 记录的是登机口出发/到达时间（表 **Airline1.Schedule** 和 **Airline1.Flight** 中的 **Departure Time** 和 **Arrival Time**），而 **Airline2** 记录的是起飞/降落时间（表 **Airline2.Flight** 中的 **Scheduled Departure Time**，**Actual Departure Time**，**Scheduled Arrival Time**，**Actual Arrival Time**）。

不同的概念信息表示得很相似，如属性 **Departure Date** 在数据源 **Airline1** 中表示实际出发日期（在表 **Airline1.Flight** 中），但是在数据源 **Airfare4** 中表示计划的出发日期（在表 **Airfare4.Flight** 中）。

3. 实例表示歧义性

要来自多个数据源的同一个数据实例关联在一起，我们需要意识到由于数据源的自治性，这些数据实例具有不同的表示形式。

例如，航班号在数据源 **Airline1** 和 **Airline2** 中被表示为数字（例如，**r11** 中的 **49**，**r31** 中的 **53**），在数据源 **Airfare4** 中被表示为数字

和字母的组合（如，r61 中的 A1-49）。类似地，出发和到达机场在数据源 Airline1 和 Airline2 中被表示为三字母的编码（如 EWR、SFO、LAX），但在 Airfare4.Flight 表中被表示为一个描述性的字符串（如 Newark Liberty, San Francisco）。由于航班是由属性组合（Airline, Flight Number, Departure Airport, Departure Date）所唯一标识的，如果没有另外一张表（例如表 1-8 中的 Airinfo5.AirlineCodes 和 Airinfo5.AirportCodes 表）将航空公司编码和机场编码分别和它们描述性的名字对应起来的话，表 Airline4.Flight 中的数据将无法和 Airline1、Airline2 和 Airline3 中的相应数据关联起来。即使有这样的对应表，我们仍然需要使用近似字符串匹配的技术 [Hadjieleftheriou and Srivastava 2011]将 Airfare4.Flight 中的 Newark Liberty 匹配到 Airinfo5.AirportCodes 表中的 Newark Liberty, NJ, US。

4. 数据不一致性

为了融合来自不同数据源的数据，我们需要解决实例级的歧义性和数据源之间的不一致性。

例如，Airline2.Flight 中的 r32 和 Airport3.Arrivals 中的 r52 存在着不一致（两者被高亮显示为蓝色以表明它们指的是同一航班）。r32 表示 Airline2 航空公司的 53 号航班的原定到达日期和实际到达时间分别是 2013-12-22 和 00:30，即实际到达日期和原定到达日期是同一天（不同于 r31，其实际到达时间包含了（+1d），表明实际到达日期比原定到达日期晚一天）。然而，r52 则记录了此航班的实际到达时间是 2013-12-23 的 00:30。在集成的数据里，需要解决这样的不一致性。

另一个例子，Airfare4.Flight 中的 r62 表示 Airline1 的 49 号航班在 2014-04-05 原定的出发和到达时间分别是 18:05 和 21:10。虽然出发日期和 Airline1.Schedule 中的 r12 一致（r12 和 r62 被高亮显示为绿色来表示它们之间的这种关系），但是原定的出发和到达时间却不一致，也许因为 r62 错误地使用了 Airline1.Schedule 中的 r11 中给出的过去的出发和到达时间。类似地，Airfare4.Flight 中的 r65 表示 Airline2 的 53 号航班在 2014-06-28 原定的出发和到达时间分别是 15:30 和 23:35。虽然出发日期和 Airline2.Flight 中的 r33 一致（r65 和 r33 都被高亮显示为黄绿色以表明它们之间的关系），但是原定的出发和到达时间却不一致，也许因为 r65 错误地使用了 Airline2.Flight 中的 r32 给出的过去的出发和到达时间。再一次表明，这些不一致性在集成起来的数据里需要被解决。

1.1.3 数据集成：体系结构和三个主要步骤

传统数据集成的方法解决语义歧义性、实例表示歧义性和数据不一致性带来的挑战时使用的是一种流水线体系结构，主要包含三个步骤，如图 1-1 所示。




图 1-1 传统数据集成的体系结构 云栖社区 yq.aliyun.com

传统数据集成中的第一个主要步骤是模式对齐。它主要针对的是语义歧义性带来的问题，目标是理解哪些属性具有相同的含义而哪些

属性的含义不同。其正式的定义如下。

给定某一领域内的一组数据源模式，不同的模式用不同的方式描述该领域。模式对齐步骤生成以下三种输出。

1) 中间模式。它为不同数据源提供一个统一的视图，并描述了给定领域的突出方面。

2) 属性匹配。它将每个源模式中的属性匹配到中间模式的相应属性。

3) 模式映射。每个源模式和中间模式之间的映射用来说明数据源的内容和中间数据的内容之间的语义关系。

结果模式映射被用来在查询问答中将一个用户查询重新表达成一组底层数据源上的查询。

种种原因使得这一步并不简单。不同数据源可以用非常不同的模式描述同一领域，如前面的航班例子。他们可以用不同的属性名来描述同一属性（如 `Airline1.Flight` 中的 `Arrival Date`、`Airline2.Flight` 中的 `Actual Arrival Date` 以及 `Airport3.Arrivals` 中的 `Actual`）。另外，数据源也会用相同的名字表示不同含义的属性（如 `Airport3.Departures` 中的 `Actual` 指的是实际出发日期，而 `Airport3.Arrivals` 中的 `Actual` 指的是实际到达日期）。

传统数据集成中的第二个主要步骤是记录链接。它主要针对的是实例表示歧义性所造成的问题，目标是理解哪些记录表示相同的实体而哪些不是。其正式的定义如下。

给定一组数据源，每个包含了定义在一组属性上的一组记录。记

录链接是计算出记录集上的一个划分，使得每个划分类包含描述同一实体的记录。

即使已经完成了模式对齐，记录链接仍然很有挑战。不同的数据源会用不同的方式描述同一实体。例如，**Airline1.Schedule** 中的 **r11** 和 **Airline1.Flight** 中的 **r21** 应该被链接到 **Airport3.Departures** 中的 **r41**；然而，**r11** 和 **r21** 没有显式地提到航空公司的名字，而 **r41** 没有显式地给出起飞机场，而要唯一确定一个航班，这两种信息都需要。另外，不同数据源可能使用不同的形式表示相同的信息（例如前面例子中讨论的表示机场的各种方式）。最后，在数百亿条记录中使用两两比较的方法来判定两条记录是否描述同一实体的方法是不可行的。

传统数据集成中的第三个主要步骤是数据融合。它主要针对的是数据质量带来的挑战，目标是理解在数据源提供相互冲突的数据值时在集成起来的数据中应该使用哪个值。其正式的定义如下。

给定一组数据项，以及为其中一些数据项提供值的一组数据源。数据融合决定每个数据项正确的值。

许多种原因都可能造成数据冲突，如输入错误、计算错误（例如，**r32** 和 **r52** 的实际到达日期之间的不一致）、过时的信息（例如，**r12** 和 **r62** 的原定出发和到达时间之间的不一致）等。

我们将在后面的章节逐一介绍每一步骤中所使用的各种方法。下面我们继续讨论当数据集成从传统数据集成演化到大数据集成时所带来的挑战和机遇。