

实验三 爬取天气预报数据与网页结构分析

3.1 实验介绍

本实验旨在通过爬取中国天气网（www.weather.com.cn）的天气预报数据，掌握静态网页与动态网页的数据采集技术，并分析所爬取页面的 DOM 结构，实现数据的提取、存储与可视化。

3.2 实验目标

- 理解静态网页与动态网页的区别及其爬取方法
- 掌握使用 BeautifulSoup 解析静态 HTML 内容
- 掌握使用 Selenium 或 Playwright 处理动态加载内容
- 能够提取并展示网页的 DOM 结构
- 掌握数据存储与可视化方法

3.3 实验原理与方法

3.3.1 静态网页与动态网页

静态网页：内容在服务器端已完全生成，直接通过 HTTP 请求获取

动态网页：内容通过 JavaScript 在浏览器端动态生成，需使用浏览器模拟工具（如 Selenium）获取

3.3.2 使用工具

BeautifulSoup：解析 HTML/XML，提取静态内容

Selenium / Playwright：模拟浏览器行为，获取动态渲染内容

Requests：发送 HTTP 请求

PyQuery / lxml：辅助解析 DOM 结构

3.4 实验内容与步骤

任务一：静态网页爬取与 DOM 结构分析

1. 爬取中国天气网中上海市 9 月份天气页面
2. 提取以下信息：
 - a) 日期
 - b) 最高温/最低温
 - c) 天气状况
 - d) 风力风向
3. 输出所爬取页面的 DOM 结构树（至少到目标数据所在的层级）

任务二：动态网页爬取与结构分析

1. 使用 Selenium 爬取中国天气网中上海实时天气信息（如逐小时天气），以下任选一个网页。

- 1) 实时天气详情页（含动态更新）

<http://www.weather.com.cn/weather/101020100.shtml>

城市代码说明：101020100 = 上海

动态内容：实时温度、湿度、风速等数据的动态更新

适合分析：页面加载后会通过 JavaScript 动态更新当前天气数据

- 2) 逐小时天气预报

<http://www.weather.com.cn/weather15d/101020100.shtml>

动态内容：24 小时逐小时天气预测，通常通过异步加载

结构特点：包含动态生成的图表和数据表格

- 3) 生活指数页面

<http://www.weather.com.cn/weather15d/101020100.shtml>

动态内容：穿衣、运动、洗车等生活指数的动态计算

分析价值：多种动态生成的生活建议内容

2. 分析动态加载数据的来源（如 XHR 请求）

- 查找通过 JavaScript 动态插入的元素
- 分析 AJAX 请求的数据源

- 识别定时刷新的数据区域

3. 提取数据并输出动态生成部分的 DOM 结构

任务三：数据存储与可视化

1. 将爬取的数据存入数据库（SQLite、MySQL）或文件
2. 绘制上海市 9 月份温度变化曲线图
3. 绘制全国省会城市当天天气情况柱状图

任务四：DOM 结构对比分析

1. 对比静态页面与动态页面的 DOM 结构差异
2. 分析动态内容是如何被插入到 DOM 中的

3.5 实验要求

基本要求（必做）：

- 使用 BeautifulSoup 完成静态页面爬取
- 使用 Selenium 完成动态内容爬取
- 分析静态页面与动态页面的 DOM 差异
- 提取目标数据并存储到数据库
- 绘制温度变化曲线图

提高要求（选做）：

- 输出所爬取页面的 DOM 结构（使用 prettify()或自定义格式）
- 实现全国省会城市天气数据的自动更新机制
- 使用多线程或异步方式提高爬取效率

3.6 实验报告要求

网页分析部分：

- 静态页面结构分析
- 动态页面加载机制分析
- 目标数据在 DOM 中的位置

代码实现：

- 静态爬虫代码（含 DOM 结构输出）
- 动态爬虫代码（含 DOM 结构输出）
- 数据存储与可视化代码

结果展示：

- 爬取的数据截图
- DOM 结构输出示例
- 可视化图表

分析与总结：

- 静态与动态爬取的对比
- DOM 结构分析的心得
- 遇到的问题与解决方案