

数据集成实验

一、实验介绍

本实验将整合来自多个数据源的信息，包括混凝土的成分配比、养护时间和强度测试结果。通过数据清洗、集成和可视化分析，展示集成的数据。

二、实验目标

- 2.1. 掌握基本的数据集成方法
- 2.2. 掌握简单的可视化操作

三、数据介绍

近年来，随着城市化进程的加快和基础设施建设的大规模展开，混凝土作为主要建筑材料的需求量急剧增加。然而，混凝土质量问题频发，导致建筑安全隐患增多，引起了行业和监管部门的高度关注。同时，随着环保要求的提高，对混凝土生产过程的节能减排和原材料优化也提出了更高的要求。为了确保建筑工程的质量和安​​全，提高混凝土生产的效率和环保性，亟需开发基于数据分析的混凝土性能预测和优化方法，而这就需要进行数据集成处理。

本实验提供了某大型混凝土生产企业的原材料配比信息、养护时间数据和强度测试结果。其中，element.xlsx 文件为混凝土原材料配比信息，age.xlsx 文件为混凝土养护时间数据，strength.xlsx 文件为混凝土强度测试结果数据。

通过对这些信息的集成，可以从水泥含量、矿物掺合料用量、骨料配比、养护条件等维度进行特征挖掘。

四、相关技术

对实验过程中可能涉及的 python 语法进行介绍：

1. 使用 pandas 库读取 Excel 文件 (`pd.read_excel()`)
2. 重命名数据列 (`df.rename()`)

3. 数据合并 (`pd.merge()`)
4. 处理缺失值 (`df.dropna()`)
5. 使用 `pandas` 将处理后的数据保存为 Excel 文件 (`pd.ExcelWriter()`, `df.to_excel()`)
6. 使用 `matplotlib` 库创建基础图表 (`plt.figure()`, `plt.scatter()`, `plt.bar()`, `plt.xlabel()`, `plt.ylabel()`, `plt.title()`, `plt.show()`)
7. 使用 `seaborn` 库创建高级统计图表 (`sns.heatmap()`)
8. 数据分组和聚合 (`df.groupby().mean()`)
9. 计算相关性矩阵 (`df.corr()`)

五、实验步骤

5.1 模式对齐：

将不同文件中表示相同含义但属性命名不同的某些数据列重命名，如可将将混凝土龄期信息中的属性 No.改为 number，为下面与原材料配比信息的数据融合合作准备。

5.2 记录连接：

基于分类，比较记录对是否为统一实体的局部决策，这里具体可以举例为 `element.xlsx` 中的某一个行记录的是编号为 A 的混凝土原材料配比信息，`age.xlsx` 中有编号为 A 的混凝土的养护时间数据，这两条记录就是编号为 A 的混凝土实体的两个局部决策，数据项匹配。

5.3 数据融合

判断有无不同数据源同一实体的同一属性提供值时可能出现的冲突问题，融合后的数据有无缺失问题等，进行处理。

5.4 数据可视化

对集成后的数据作简单的数据分析，生成一些可视化结果展示。


六 、实验要求

1、通过对三张表进行数据集成处理，整合到一张表中


举例：

number	Cement	Blast Furnace Slag	Fly Ash	Water	Superplasticizer	Coarse Aggregate
180000	540	0	0	162	2.5	1040
Fine Aggregate	Age (day)	Concrete compressive strength (MPa, megapascals)				
676	28	79.99				

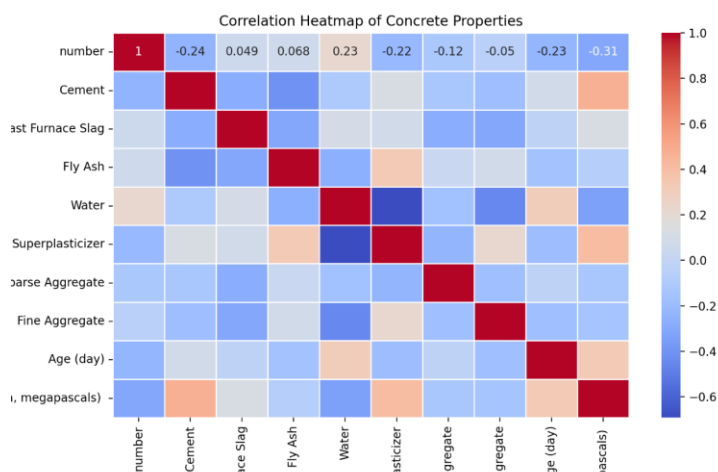
2、对数据进行简单的可视化展示，可自由发挥。



散点图：水泥含量 vs 抗压强度



柱状图：不同年龄的平均抗压强度



热力图：属性相关性

- 3、撰写试验报告，包括试验原理（可按数据集成步骤）、实验步骤、试验结果、实验重点、心得体会等；
- 4、提交相关代码。