

基于多层次建模与集成学习的 NIPT 检测优化及胎儿染色体异常判定研究

摘要

本文针对 NIPT（无创产前检测）中孕妇个体差异对检测时机与准确率的影响问题，结合统计学与优化方法，建立多种模型以探讨 Y 染色体浓度达标规律及最佳检测时点的确定策略。通过系统建模与数据分析，本文力图为临床检测提供科学合理的决策依据，降低孕妇潜在风险。

针对问题一，我们考虑到孕妇 BMI、孕周天数及年龄等母体因素对 Y 染色体浓度的影响，利用 Spearman 秩相关、Logit 回归与广义加性模型（GAM）等方法，系统分析了关键变量与浓度之间的关系。Spearman 相关分析表明，孕周天数与 Y 染色体浓度呈显著正相关（相关系数 0.07*），BMI 与 Y 染色体浓度呈显著负相关（相关系数 -0.15*），年龄也与 Y 染色体浓度呈显著负相关（相关系数 -0.11*）。进一步通过 GAM 模型成功捕捉到变量间的非线性效应。综合分析确认孕周和 BMI 是影响 Y 染色体浓度的关键因素，该研究结果为后续建立多因素预测模型提供了重要的变量选择依据和建模基础。

针对问题二，我们根据男胎孕妇 Y 染色体浓度的最早达标时间的分布使用 K-means 聚类算法对 BMI 进行分组，共分为 4 组，即 [26.62, 29.98], [29.98, 32.55], [32.55, 37.43], [37.43, 46.88]。同时定义孕妇可能的潜在风险为三重风险，以综合风险最小的时间点作为各组最佳的 NIPT 点，依次为 12.57 周、11.7 周、11.43 周、16.82 周。并进行了敏感性分析，结果表明模型在不同运行条件下表现出良好的最佳检测时点与 BMI 分组边界的稳定性，核心结论具有较高的鲁棒性。

针对问题三，进一步综合考虑孕妇的 BMI、年龄、身高、体重及孕次等多因素影响，在建模中引入检测误差和个体内相关性。基于多因素混合效应建模与多目标优化分析，我们将孕妇按 BMI 划分为三组，区间分别为 [20.7, 30.4]、[30.4, 33.7] 和 [33.9, 46.9]，并确定各组最佳 NIPT 检测时点依次为 15.85 周、16.76 周和 18.48 周。该分组及时点方案显著降低了因检测过早或过晚带来的潜在风险，兼顾临床可行性与个体差异，为高精度、低风险的产前筛查提供了可靠依据。

针对问题四，我们首先利用随机森林模型对全部候选特征进行重要性评估，筛选出对异常判定贡献最大的前 10 个变量作为核心自变量。随后，为解决胎儿染色体异常样本极度不平衡的问题，建立了 AdaBoost 集成分类模型，通过迭代训练弱分类器并自适应调整样本权重，以增强对难分类异常样本的识别能力。进一步地，通过 ROC 曲线分析与分类阈值调优，将默认阈值从 0.5 调整为 0.448。最终，模型在女胎染色体异常检测中表现出较高综合性能：准确率 86.84%、召回率 66.67%、F1 分数 0.5161，AUC-ROC 达到 0.8779，AUC-PR 为 0.5335，显示其具备可靠的临床辅助诊断能力，尤其适用于产前筛查的初筛阶段。

综上所述，本文系统构建了针对 NIPT 检测的多层次建模框架，全面考虑孕妇个体差异及测序数据特征，提出了男胎 Y 染色体浓度达标规律分析、BMI 分组与最佳检测时点优化，以及女胎染色体异常判定的方法。整个建模过程具有如下优点：一是充分利用统计分析方法（Spearman 秩相关、Logit 回归、GAM）识别关键影响因素，为变量选择和模型构建提供科学依据；二是综合应用插值、聚类、混合效应模型及多目标优化，实现了对孕妇风险的量化与最佳检测时点的个性化推荐，兼顾准确性与稳

健性；三是针对女胎异常判定，采用随机森林特征筛选与 AdaBoost 集成学习，并结合阈值优化，实现了在样本不平衡条件下对异常样本的高效识别，具有良好的临床适用性；四是全流程模型均考虑了测量误差与不确定性，使方法在实际应用中更加可靠。总体而言，本文的建模策略能够为临床 NIPT 检测提供科学决策支持，有助于降低孕妇潜在风险、提升检测准确性与可靠性。

关键词：NIPT，分段回归建模，综合风险模型，多目标优化，AdaBoost

一、 问题重述

无创产前检测 (NIPT) 是一种利用孕妇血液中游离 DNA 信息来推断胎儿染色体状态的技术。其优势在于操作安全、检测灵敏, 但检测效果高度依赖于孕期选择和染色体浓度水平。现有研究与临床经验均显示, 若男胎的 Y 染色体比例达到一定阈值, 或女胎 X 染色体表现正常, 则检测结果较为可信。反之, 如果检测时机过早, 胎儿 DNA 浓度可能不足以支撑准确分析; 若时点过晚, 则可能延误发现异常胎儿的最佳干预窗口。因此, 合理确定检测时间与判定方法, 直接关系到孕妇与胎儿的健康风险。

在诸多影响因素中, 孕周和孕妇的体质指数 (BMI) 是影响胎儿 DNA 浓度的关键变量。其中 BMI 与男胎 Y 染色体浓度“最早达标时间” (即首次超过有效阈值的孕周) 存在显著联系。临床上常根据 BMI 对人群进行粗略分组并推荐统一检测时点, 但由于个体差异, 这种方式往往难以兼顾所有群体的准确性与安全性。因此, 有必要结合实际数据, 重新评估 BMI 分组的合理性, 并进一步考虑身高、体重、年龄以及测序质量等多维因素, 以制定更具针对性的检测策略。

针对上述问题, 本研究需解决以下四个方面: 其一, 探究 Y 染色体浓度与孕周及 BMI 等变量的关系并建立统计模型; 其二, 基于 BMI 提出合理分组及各组推荐的检测时点, 并分析误差对结论的影响; 其三, 综合更多个体与实验特征, 对分组与最佳检测时点做进一步优化; 其四, 针对女胎, 结合常见非整倍体相关染色体的 Z 值及多类质量控制指标, 提出异常识别方法。

通过这些研究, 可以为临床检测提供更加科学的分组依据与时间建议, 既保证结果的准确性, 也尽可能降低因检测时机不当带来的潜在风险。

二、 问题分析

2.1 问题一的分析

从现有文献来看, NIPT 的检测效果与胎儿游离 DNA 的含量密切相关, 而 Y 染色体浓度是判断检测准确性的关键指标之一。多项研究表明 母体 BMI 与 FF 呈显著负相关 (高 BMI 常导致 FF 降低), 孕周随时间增长通常会提高 FF, 但二者存在交互与混杂效应 (例如高 BMI 与妊娠早期更易导致低 FF / 无结果)。^{[1][2]} Y 浓度会受到孕妇孕周、BMI 等母体因素的显著影响, 这种生理学和统计学规律已在多项研究中得到验证。该问题的核心是通过定量方法刻画 Y 浓度与孕周、BMI 之间的关系特征, 并检验这种关系是否显著。需要注意的限制条件包括: 部分数据存在不符合正态分布的情况, 以及检测点有限且个体差异较大, 这对线性建模提出挑战。因此, 在方法上可以考虑采用相关性检验 (如 Spearman 秩相关)、Logit 回归或分段回归等方式, 以便更真实地反映非线性和个体差异对浓度变化的影响。

2.2 问题二的分析

由于 BMI 会降低 FF 并提高 no-call / 失败率, 临床上高 BMI 群体比低 BMI 群体更可能在早期出现低 FF 或需重复采样, 故 BMI 可作为分层或分组的关键驱动变量。^{[1][2]} 因此, 合理分组并确定不同 BMI 区间的最佳 NIPT 时点, 是降低孕妇潜在风险的重要问题。限制条件包括: 检测失败或误检的存在会导致部分样本不可用, 同时个体检测次数不一致也增加了数据处理难度。在建模思路, 可以考虑利用插值或外推方法推算最早达标时点, 再结合聚类 (如 K-Means)、分组优化和综合风险函

数（考虑不达标风险、误检风险和晚检风险）来确定每个 BMI 区间的最佳检测时机，并通过蒙特卡洛模拟评估检测误差对结果的影响。

2.3 问题三的分析

男胎 Y 染色体浓度的达标时间不仅受 BMI 影响，还会受到身高、体重、年龄、孕次等多重因素的共同作用。除 BMI 外，年龄、胎次、孕周本身、测序质量指标（GC、比对率、读段数）均被报告为影响 FF 或 NIPT 失败风险的因素；因此，多因子同时考虑有利于提高个体化时点推荐的准确性与鲁棒性。^[3]因此，本问题的重点是综合考虑多因素及检测误差，建立更具普适性的分组与优化模型。限制条件在于：变量之间可能存在相关性与非线性关系，且个体间重复检测结果存在内在相关性，必须选择能处理层次结构与个体差异的模型。在方法选择上，可采用多目标优化模型，将期望风险与不确定性风险纳入统一框架，并利用增强版混合效应模型刻画个体内外差异；同时，可以结合聚类（如基于肘部法则的 K-Means）与决策树方法，实现 BMI 的自动分段与风险类别映射，确保结果具有统计最优性与临床可解释性。

2.4 问题四的分析

女胎不携带 Y 染色体，染色体异常判定主要依赖 21/18/13 的标准化统计量（Z 值）以及 X 染色体的异常模式；Z 值在实践中常用于初筛，且 QC 指标（FF、GC、读段数/比对率）对判定灵敏度与特异度有重要影响。^{[4][5]}因此，本问题的关键在于如何综合多源信息建立异常判定模型。限制条件包括：女胎的检测信号特征较弱，误差与噪声的影响更为显著；同时，GC 含量、测序深度及 X 染色体浓度等因素可能导致偏倚，需要在建模时加以校正。适用的方法包括：基于多变量统计分析的判别模型（如 Logistic 回归或判别分析）、基于机器学习的分类方法（如随机森林、支持向量机），以及结合 Z 值、GC 含量和读段比例的综合判定方法。这些方法能够在保证灵敏度和特异性的前提下，提升对女胎异常的识别能力。

三、 模型假设

- （1）Y 染色体浓度随孕周增加总体呈上升趋势，且可通过插值方法估计其达标时间。
- （2）孕妇的潜在风险主要由三部分构成：检测过早导致的浓度不达标风险、误检风险、以及检测过晚导致的治疗窗口缩短风险。
- （3）提供给我们的数据（包括 BMI、孕周、Y 染色体浓度）虽然存在测量误差，但整体可靠，能够反映真实趋势。

四、 符号说明

符号	说明
B	孕妇的身体质量指数（BMI）
T	孕周天数
C _Y	Y 染色体浓度
T _{ec}	Y 染色体浓度达到 4%的最早时间（天）
alpha	浓度不达标风险的权重因子
beta	误检风险的权重因子
gamma	晚检风险的权重因子

五、模型的建立与求解

模板不是固定的，根据你的文章内容来定。基本原则就是：

- (1) 针对某一小问、或者某个模型，用二级标题
- (2) 某个模型或求解过程的一大步，例如 XX 模型的建立，用三级标题

5.1 问题一的求解

5.1.1 数据分析

Step1: 描述性统计

我们在正式建模之前对数据集进行了探索性数据分析（Exploratory Data Analysis, EDA），以系统地理解数据特征、发现潜在规律、识别异常或问题的分析方法，并为后续分析提供方向。

在本研究的数据集中，共纳入 1072 例孕妇样本。总体来看，孕妇年龄介于 21 至 43 岁之间，平均年龄约 29 岁，分布相对集中，略呈右偏。孕妇的 BMI 范围在 20.7 至 46.9 之间，均值为 32.29，标准差约 2.95，显示样本群体整体偏高 BMI，且分布呈正偏态，极端值相对较多。测序质量相关指标表现较为稳定，原始读段数均值约 469 万，分布在 134 万至 989 万之间；比对比例集中在 0.80 左右，但偏度和峰度值提示其分布较尖锐；重复读段比例及被过滤读段比例均较低，分别约为 3.0% 和 2.3%，符合预期的测序质量水平；GC 含量均值为 0.40，标准差很小，说明不同样本间差异有限。性染色体方面，Y 染色体 Z 值均值接近 0，但范围较宽（-4.01 至 7.00），说明部分样本差异显著；Y 染色体浓度均值约 7.6%，中位数为 7.5%，分布较均衡；X 染色体浓度均值约 5.6%，波动范围相对更大。孕周方面，样本覆盖 77 至 203 天（约 11 至 29 周），平均孕周约 118 天（约 16.8 周），分布略偏右。总体而言，数据质量较好，变量分布合理，部分指标（如 BMI、Y 染色体 Z 值）呈现明显偏度与离群性，这为后续建模分析提供了必要的分布特征参考。




图 1 变量分布直方图

Step2: 数据预处理

在对原始 NIPT 数据进行建模分析之前，我们首先进行了系统的数据预处理。首先，将孕周信息统一转换为“天”为单位的数值形式，例如“12w+3d”“15w”“20w+4”均被标准化为孕天数，以便后续进行连续变量建模。其次，考虑到研究重点是男胎 Y 染色体浓度与孕周、BMI 的关系，我们筛选出 Y 染色体浓度非空的样本，仅保留男胎数据进行分析。再次，为了减少极端值对结果的影响，我们采用四分位距（IQR）方法对关键变量——孕周、BMI 和 Y 染色体浓度——进行异常值处理，剔除超出 $[Q1-1.5IQR, Q3+1.5IQR]$ 、 $[Q1-1.5IQR, Q3+1.5IQR]$ 、 $[Q1-1.5IQR, Q3+1.5IQR]$ 范围的样本点。上述步骤的目的在于提高数据的一致性与可比性，增强模型的稳健性，并确保分析结果不受个别异常样本的干扰，从而为后续关系建模和分组研究奠定可靠的数据基础。

5.1.2 基于 Spearman 秩相关的 Y 染色体浓度与母体特征关系分析

Step1: 前置统计检验与相关性探索

在开展回归建模之前，我们首先对各变量分布特征进行了检验。以胎儿 Y 染色体浓度作为因变量，选取年龄、孕妇 BMI、原始读段数、参考基因组比对比例、重复读段比例、GC 含量、Y 染色体 Z 值、X 染色体浓度、被过滤读段比例以及孕周天数作为自变量，对其分布进行正态性检验，并结合 QQ 图进行可视化呈现。




图2 多变量 QQ 图分析

结果显示，部分变量近似符合正态分布，但仍存在不同程度的偏差，而另一些变量则完全不满足正态性要求。这说明在后续建模中，可能需要考虑变量变换或选择非参数方法，以减弱分布假设的限制。

进一步地，我们通过散点图矩阵考察各自变量与因变量 Y 染色体浓度之间的相关趋势。




图3 Y 染色体浓度与其他变量的相关关系

结果表明，除 X 染色体浓度表现出一定关系外，其余变量与 Y 染色体浓度并未呈现明显的线性相关性。这一结果提示，简单的线性回归不足以刻画各变量与因变量之间的关系，后续模型设计需结合非线性效应、交互作用或混合效应等更灵活的建

模方式，以更全面反映变量间的潜在联系。

Step2: Spearman 秩相关性分析

由于前期检验结果显示部分变量显著偏离正态分布，且大多数自变量与 Y 染色体浓度之间未表现出明显的线性关系，因此在后续相关性分析中不再采用对正态性与线性假设较为敏感的 Pearson 相关系数，而是选用 Spearman 秩相关系数作为主要方法。Spearman 相关系数通过对原始观测值进行秩次转换，进而衡量两个变量之间的单调关系，其优势在于对变量的分布形式不作严格要求，能够适用于非正态分布的数据，同时对异常值具有较强的稳健性。

在本研究中，候选自变量均为定量指标，但部分变量分布偏态严重，不满足参数统计方法所需的前提条件。Spearman 方法通过计算秩次间的相关程度，可以更合理地揭示变量间的潜在关联模式。当变量中至少包含一个定序变量时，该方法同样适用，因此在处理复杂生物医学数据时被广泛采用。基于上述考虑，本研究采用 Spearman 秩相关分析来刻画 Y 染色体浓度与各候选自变量之间的相关性，从而确保分析结果的稳健性和解释的科学性。结果如下：




图4 斯皮尔曼相关系数矩阵




图 5 P 值矩阵

从 Spearman 相关系数矩阵可以看出，胎儿 Y 染色体浓度与孕周天数呈现轻度正相关 ($\rho=0.069$)，与孕妇 BMI 存在一定负相关 ($\rho=-0.153$)，表明孕周越大浓度略有增加，而 BMI 越高则可能导致浓度下降，这与既往文献报道相符。此外，Y 染色体 Z 值也存在一定的正相关 ($\rho=0.095$)。在测序质量指标方面，原始读段数与被过滤读段比例 ($\rho=0.221$) 以及 Y 染色体浓度与比对比例 ($\rho=-0.165$) 等关系提示测序数据质量与检测结果之间可能存在一定联系。总体而言，孕周、BMI 及部分测序质量指标与 Y 染色体浓度存在弱至中等程度的相关性，而绝大多数其他变量之间相关性较低，说明主要影响因素相对集中。

分析结果显示，胎儿 Y 染色体浓度与孕妇 BMI ($p=0$)、孕周天数 ($p=0.0248$)、原始读段数 ($p=0.0043$)、重复读段比例 ($p=0.0005$)、Y 染色体 Z 值 ($p=0.0018$) 以及被过滤掉读段数的比例 ($p=0.003$) 存在显著相关性 ($p<0.05$)，说明这些因素对 Y 染色体浓度具有统计学影响。其中，孕妇 BMI 和孕周天数的显著性尤为突出，表明 BMI 和孕周对胎儿 Y 染色体浓度达标时间可能是关键影响因素。相比之下，胎儿 Y 染色体浓度与孕妇年龄 ($p=0.0002$)、GC 含量 ($p=0.6288$)、在参考基因组上比对比例 ($p=0$)、X 染色体浓度 ($p=0$) 等部分指标的相关性不显著或较弱。这一分析验证了临床经验：男胎孕妇的 BMI 与孕周是影响 Y 染色体浓度及 NIPT 准确性的重要因素，为后续模型建立和 NIPT 时点优化提供了统计依据。

5.1.3 分段回归建模：基于孕周分组的 Logit 与 GAM 分析

既往研究表明，胎儿游离 DNA 浓度 (fetal fraction) 在孕早期至约 17 周呈逐渐上升趋势，但进入孕中晚期后，浓度增幅明显减缓，存在阶段性差异。^[6] 为了更合理地刻画这一非均质关系，本研究根据孕周天数将样本划分为两个区间：10 - 17 周和 18 - 25 周。在孕早期至中期的 10 - 17 周区间内，浓度随孕周的变化相对平缓，适合采用 Logit 回归模型对达标概率 (Y 染色体浓度 $\geq 4\%$) 进行建模，从而量化孕周对检测准确性的影响。而在 18 - 25 周区间，胎儿游离 DNA 浓度与孕周之间的关系更具非线性特征，单一线性函数难以充分拟合，因此引入广义加性模型 (GAM) 以捕捉潜在的非线性变化模式。该分段建模策略既能保证模型的拟合精度，又能增强结果的解释力，为后续检测时点的优化提供方法学支持。

Step1: 基于 Logit 回归的 Y 染色体浓度达标概率建模 (10–17 周)

在孕早期至中期 (10–17 周) 的样本中, 我们采用 Logit 回归模型对胎儿 Y 染色体浓度的达标概率进行建模, 其中达标定义为 Y 染色体浓度 $\geq 4\%$ 。这一阈值的设定来源于临床实践与既往研究, 通常认为当男胎 Y 染色体浓度达到或超过 4% 时, NIPT 检测结果的准确性能够得到有效保证。模型的输出为达标概率, 即在给定母体特征的情况下, 胎儿 Y 染色体浓度达到 4% 及以上的可能性。

在输入变量的选择上, 本研究纳入了孕妇年龄、BMI 以及孕周天数三个指标。其一, 年龄作为基本人口学特征, 可能通过间接的生理机制影响胎儿游离 DNA 的水平; 其二, BMI 在前期 Spearman 相关性检验中与 Y 染色体浓度呈显著负相关, 是影响达标概率的主要因素; 其三, 孕周天数与 Y 染色体浓度存在正相关关系, 是浓度变化的时间维度关键变量。通过将上述三个变量作为自变量, 模型能够较为全面地反映母体特征与孕期进展对 Y 染色体浓度达标情况的综合影响。

从模型整体拟合情况来看, 零模型 (仅含截距项) 的对数似然值为 -355.27, 而包含所有预测变量的当前模型对数似然值为 -336.85。两者差异经似然比检验 (LRT) 得到统计量 36.84, 自由度为 3, 对应的 p 值为 4.99×10^{-8} , 显著小于 0.001。这表明模型整体在统计上高度显著, 即至少存在一个自变量对因变量具有显著影响。

在拟合优度方面, Cox-Snell 伪 R^2 值为 0.05184, 说明模型能够解释部分因变量变异, 但解释力相对有限, 提示可能仍有其他未纳入的影响因素。此外, 模型收敛顺利, 估计结果可信。分类准确率 (ACC) 达到 0.649, 虽不是极高水平, 但在生物医学数据中属于可以接受的范围。总体而言, 该模型能够显著提升对 Y 染色体浓度达标情况的预测效果, 为后续进一步分析提供了统计支持。




图 6 逻辑回归 ROC 曲线

在 Logit 回归模型中, 各自变量的显著性检验结果显示, 孕妇 BMI 与孕周天数均对胎儿 Y 染色体浓度是否达标 ($\geq 4\%$) 具有显著影响, 且显著性水平极高 ($p < 0.01$)。其中, 孕妇 BMI 的优势比 (OR=0.8619) 小于 1, 说明在控制其他变量不变的情况下, BMI 每增加一个单位, 胎儿 Y 染色体浓度达标的优势约减少 13.81%, 提示较高 BMI 可能抑制游离 DNA 浓度的提升。而孕周天数的优势比 (OR=1.0461) 大于 1,

意味着孕周每增加 1 天，浓度达标的优势约提高 4.61%，这与既往研究中“胎儿游离 DNA 随孕周增加而上升”的结论一致。相比之下，孕妇年龄的影响未达到统计显著性（ $p=0.124$ ， $OR=0.9595$ ），因此其作用需谨慎解读，不宜作为主要解释变量。整体来看，本研究结果进一步验证了孕周与 BMI 是决定 Y 染色体浓度水平及检测准确性的核心因素。




图 7 逻辑回归特征重要性

Step2: 基于 GAM 的 Y 染色体浓度非线性建模（18–25 周）

基于以下几点考虑：首先，前期相关性检验结果显示，BMI 与孕周天数虽与 Y 染色体浓度显著相关，但两者关系并不符合严格的线性模式，单纯采用线性回归可能低估或误判其真实效应；其次，年龄在早期建模中未达到显著性，但文献与经验均提示其可能以非线性形式作用于胎儿游离 DNA 水平，因而有必要引入平滑函数进行检验；最后，测序质量指标与染色体相关指标往往呈近似线性关系，因此将其作为线性项处理既可保证模型简洁性，又能减少过拟合风险。广义加性模型（Generalized Additive Model, GAM）作为半参数模型，既保留了部分变量的线性解释力，又通过样条平滑项灵活捕捉非线性变化，能够在提高拟合精度的同时保持良好的可解释性。我们采用的 GAM 模型的数学表达式为：

$$Y\text{染色体浓度} = \beta_0 + f_1(\text{孕妇BMI}) + f_2(\text{孕周天数}) + f_3(\text{年龄}) + \beta_4 \times \text{原始读段数} + \dots + \varepsilon \tag{1}$$

其中， f_1 、 f_2 、 f_3 为采用三次样条函数的非参数平滑项，用于捕捉 BMI、孕周天数与年龄对 Y 染色体浓度的非线性效应。

输入变量的选择基于前期的 Spearman 秩相关分析结果：孕周与 BMI 与浓度存在显著相关性，且趋势可能并非单纯线性；年龄虽在早期建模中未显著，但在不同孕周阶段可能表现出非线性效应，因此保留在模型中。通过这种半参数的建模方式，能够在保持模型可解释性的同时，有效揭示孕中晚期样本中 Y 染色体浓度的非线性变化规律。模型拟合效果如下：

表 1 模型整体拟合优度指标

指标	值	说明
样本量	341	有效观测值数量
决定系数(R ²)	0.853	模型解释的方差比例
调整 R ²	0.846	考虑变量个数后的拟合优度

指标	值	说明
均方根误差(RMSE)	0.0132	预测误差大小
对数似然值	992.23	模型拟合程度
AIC	-1948.46	模型选择准则（越小越好）
BIC	-1879.49	考虑复杂度的模型选择准则
F 统计量	110.6	模型整体显著性检验
F 检验 p 值	2.04e-123	模型整体高度显著

该广义加性模型（GAM）展现了出色的拟合性能，决定系数 R^2 达到 0.853，调整 R^2 为 0.846，表明模型能够解释 Y 染色体浓度 85.3% 的变异，这在生物医学数据分析中属于极高的解释力。模型整体 F 统计量为 110.6 且高度显著（ $p=2.04e-123$ ），确认了模型的整体有效性。对数似然值为 992.23，AIC 和 BIC 值分别为 -1948.46 和 -1879.49，这些指标均支持模型的优良质量。均方根误差（RMSE）为 0.0132，进一步证明了模型预测精度较高。

表 2 样条变量显著性分析

变量	显著性	最小 p 值	显著基函数数量
孕妇 BMI	显著	0.0031	3 个（sp2, sp3, sp4）
孕周天数	高度显著	0.0000	2 个（sp1, sp2）
年龄	不显著	0.2343	0 个

模型成功捕捉到了关键变量的复杂非线性关系。孕妇 BMI 的样条分析显示存在显著的非线性效应（最小 p 值=0.0031），其中 sp2、sp3 和 sp4 基函数均达到显著性水平，表明 BMI 与 Y 染色体浓度之间存在复杂的曲线关系，并非简单的线性关联。孕周天数同样表现出强烈的非线性特征（最小 p 值=0.0000），sp1 基函数高度显著而 sp2 边缘显著，提示孕周对 Y 染色体浓度的影响在不同阶段可能呈现不同的变化速率和方向。相比之下，年龄变量的所有样条基函数均不显著（最小 p 值=0.2343），表明在当前模型中年龄对 Y 染色体浓度的影响并不明显。

表 3 高度显著变量详情（ $p < 0.01$ ）

变量	系数	标准误	t 值	p 值	显著性
孕妇 BMI_sp2	0.0098	0.003	2.979	0.0031	**
孕周天数_sp1	0.0272	0.005	5.350	0.0000	***
Y 染色体的 Z 值	0.0119	0.001	19.792	0.0000	***
X 染色体浓度	0.7541	0.020	36.922	0.0000	***

两个变量表现出极强的线性预测能力：X 染色体浓度（系数=0.7541, $p<0.0001$ ）和 Y 染色体的 Z 值（系数=0.0119, $p<0.0001$ ）。X 染色体浓度每增加 1 单位，Y 染色体浓度预计增加 0.7541 单位，这反映了性染色体之间的生物学关联。Y 染色体 Z 值的显著正相关进一步验证了模型的理论合理性，表明 Z 值确实是 Y 染色体浓度的良好指标。

表 4 边缘显著变量详情（ $0.01 \leq p < 0.05$ ）

变量	系数	标准误	t 值	p 值	显著性
孕妇 BMI_sp3	0.0066	0.003	2.146	0.0326	*

变量	系数	标准误	t 值	p 值	显著性
孕妇 BMI_sp4	0.0067	0.003	1.977	0.0489	*
孕周天数_sp2	-0.0074	0.003	-2.252	0.0250	*
原始读段数	-2.099e-09	9.19e-10	-2.285	0.0230	*
重复读段的比例	0.6558	0.267	2.455	0.0146	*

原始读段数 ($p=0.0230$) 和重复读段的比例 ($p=0.0146$) 显示出边缘显著性, 但效应量相对较小。原始读段数的系数为 $-2.099e-09$, 虽然统计显著但实际影响微弱。重复读段比例的正向影响(系数 $=0.6558$) 可能反映了测序数据质量对浓度估计的影响。在参考基因组上比对的比例则完全不显著 ($p=0.4334$), 表明这一技术指标对 Y 染色体浓度的预测价值有限。

总而言之, 广义加性模型 (GAM) 在孕中晚期数据中的拟合效果优异, 能够解释 Y 染色体浓度约 85% 的变异, 整体模型高度显著, 预测精度较高。结果表明, 孕妇 BMI 与孕周天数均呈现显著的非线性效应, 说明二者对 Y 染色体浓度的影响并非简单的线性关系, 而是在不同区间表现出变化速率和方向的差异。相比之下, 年龄未显示显著作用。在线性预测因子中, X 染色体浓度和 Y 染色体 Z 值均为强显著变量, 且效应量较大, 进一步支持了生物学上的合理性。其他测序相关指标如原始读段数与重复读段比例虽在统计上接近显著, 但实际效应有限; 而比对比例则未显示出预测价值。总体而言, GAM 不仅在整体拟合上表现出色, 还揭示了关键变量的非线性特征, 为理解 Y 染色体浓度的决定因素提供了更精细的视角。

在本研究中, 基于文献结论与数据特征, 我们采用分段建模的策略来刻画孕妇特征与胎儿 Y 染色体浓度的关系。首先, 在孕早期至 17 周阶段, 胎儿游离 DNA 浓度总体较低且逐渐上升, 因而我们将 Y 染色体浓度是否达到临床阈值 ($\geq 4\%$) 作为分类因变量, 利用孕妇年龄、BMI 与孕周天数等指标构建 Logit 回归模型。模型整体显著, 结果表明 BMI 与孕周天数均对浓度达标概率有显著影响, 其中孕周天数正向促进达标, 而 BMI 增大则延缓达标。随后, 在 18~25 周阶段, 胎儿 DNA 浓度增速减缓并呈现复杂变化, 因此我们引入广义加性模型 (GAM), 以 Y 染色体浓度为连续因变量, 结合 BMI、孕周天数、年龄等自变量, 通过非线性样条函数捕捉变量间的非线性关系。GAM 模型拟合效果优异 ($R^2 \approx 0.85$), 揭示了孕周与 BMI 的非线性效应, 并确认了 X 染色体浓度与 Y 染色体 Z 值的强预测作用。整体而言, 分段建模策略兼顾了孕早期与中期的不同浓度变化模式, 既保证了早期分类判断的临床实用性, 又提升了中期预测的精细化和解释力。

5.1.4 总结

我们考虑到孕妇 BMI、孕周天数及年龄等母体因素对 Y 染色体浓度的影响, 利用 Spearman 秩相关、Logit 回归与广义加性模型 (GAM) 等方法, 系统分析了关键变量与浓度之间的关系。Spearman 相关分析表明, 孕周天数与 Y 染色体浓度呈显著正相关 (相关系数 0.07^*), BMI 与 Y 染色体浓度呈显著负相关 (相关系数 -0.15^*), 年龄也与 Y 染色体浓度呈显著负相关 (相关系数 -0.11^*)。进一步通过 GAM 模型成功捕捉到变量间的非线性效应。综合分析确认孕周和 BMI 是影响 Y 染色体浓度的关键因素, 该研究结果为后续建立多因素预测模型提供了重要的变量选择依据和建模基础。

5.2 问题二的求解

5.2.1 数据预处理

在构建最佳 NIPT 检测时点的模型之前, 我们首先对原始数据进行了进一步清洗

与转换。考虑到临床上胎儿性染色体浓度通常在孕 10~25 周之间具有参考意义，且超过该区间的检测结果可靠性较低，因此将孕周超出该范围的样本直接剔除。同时，由于正常 GC 含量应处于 40%~60% 区间，若 GC 含量过高或过低往往提示测序质量存在问题，为保证分析结果的准确性与降低潜在临床风险，我们将此类异常数据一并剔除。随后，对数据集中“染色体非整倍体”与“胎儿健康状况”两列信息进行了标准化转换，并据此构建新变量“是否误检”，其中 1 表示误检，0 表示未误检。通过以上处理，确保数据质量符合建模要求，同时为后续分析 NIPT 时点与潜在风险提供了更可靠的基础。

5.2.2 Y 染色体浓度最早达标时间点的确定方法

为准确识别各孕妇胎儿 Y 染色体浓度 (C_Y) 首次超过临床阈值 4% 的时间点，我们在数据处理中引入了插值与外推方法。具体而言，首先基于每位孕妇的检测记录，采用三次样条插值 (Cubic Spline) 对 C_Y 与孕周天数的关系进行拟合，以平滑化有限的观测点并提高最早达标时间点的估计精度。当插值计算能够求得浓度首次超过 4% 的根时，直接将该时间点作为最早达标时点；若遇到插值范围外的情况或无法求得有效根，则采用线性外推方法，或保留原始观测中首次超标的时点作为补充。通过该方法，可以在保证合理性的前提下，尽可能精确地确定各孕妇的 Y 染色体浓度达标时间。

5.2.3 基于 K-Means 聚类的 BMI 分组模型

因为孕妇的 Y 染色体浓度达标是鉴定结果准确的前提条件之一，因而将具有相近 Y 染色体浓度达标最早时间点的孕妇分为一组后寻找最佳 NIPT 时点更加合理有效。BMI 分组的目的是根据组内孕妇的 Y 染色体浓度最早达标时间 T 特征相似性进行分组。选择 K-Means 聚类算法，以 BMI 和 T 作为两个特征向量，对所有有效孕妇进行聚类。该方法的优势在于能够根据数据本身的内在结构，将 BMI 和达标时间特征相似的孕妇自动聚合，避免主观分组偏差。

Step1: 标准化处理

聚类分析以孕妇的 BMI 值和计算得到的最早达标时间 T_{ec} 两个特征向量构成样本点 X_n 。

$$X_n = [B_n, (T_{ec})_n]^T, n=1, 2, \dots, N \quad (2)$$

其中， B_n 为第 n 位孕妇的 BMI 值， $(T_{ec})_n$ 为其对应的 Y 染色体浓度达标时间 (天)，N 为有效孕妇样本数。为防止量纲差异对聚类结果产生主导影响，采用 Z-score 标准化对特征进行预处理。

Step2: K-Means 聚类

在确定孕妇群体的合理分组时，我们采用了 K-Means 聚类方法对 BMI 值进行无监督聚类分析。具体而言，设定聚类数目为 $K=4$ ，算法的优化目标是最小化所有样本点到其所属簇中心的欧氏距离平方和 (簇内方差和)。在迭代过程中，首先将每个样本分配到与其距离最近的簇中心；随后根据当前簇内样本重新计算簇中心，直至簇中心不再发生显著变化，从而得到稳定的分组结果。

聚类完成后，每个孕妇被分配到某一簇中，我们进一步计算各簇的原始 BMI 取值范围，并将其作为分组参考。为确保分组区间连续且无重叠，首先按照簇中心的 BMI 平均值对各簇进行升序排列，然后设定分组边界：全局最小值作为起始边界，全局最大值作为终止边界；中间边界则定义为相邻簇最大值与最小值的中点。

最终得到四个连续的 BMI 分组区间，分别为：

[26.62, 29.98)，样本数 173；

[29.98, 32.55), 样本数 338;

[32.55, 37.43), 样本数 313;

[37.43, 46.88), 样本数 35。

该分组方法既保证了 BMI 区间划分的客观性, 又能够反映不同孕妇群体的特征差异, 为后续 NIPT 最佳检测时点的确定奠定了基础。

5.2.4 综合风险模型与最佳 NIPT 时点优化

为确定不同 BMI 分组下的最佳 NIPT 检测时点, 使孕妇的潜在风险最小化, 本研究构建了一个综合风险模型 $R_{\text{total}}(T; G_i)$, 用以量化在孕周 T (单位: 天) 进行检测所面临的预期风险。

该模型由三个子风险项组成, 分别为 浓度不达标风险 $R_{\text{nc}}(T; G_i)$ 、误检风险 $R_{\text{mis}}(T; G_i)$ 和晚检风险 $R_{\text{late}}(T)$, 通过加权求和的方式形成总风险函数, 其通用形式为:。

$$R_{\text{total}}(T; G_i) = \alpha \cdot R_{\text{nc}}(T; G_i) + \beta \cdot R_{\text{mis}}(T; G_i) + \gamma \cdot R_{\text{late}}(T) \quad (3)$$

其中, 各风险项的权重系数满足加和为 1, 默认设置为 0.3、0.6 和 0.1。

这一设计既符合临床实践的逻辑, 也具有统计建模上的科学依据。首先, 浓度不达标风险反映了检测技术层面的限制: 若 Y 染色体浓度未达 4%, 则检测结果可能失真, 这是影响准确性的基础条件, 因此必须纳入。其次, 误检风险直接关系到检测结论与真实胎儿健康状况的一致性, 若误检率过高, 将导致严重的临床后果, 因此在风险函数中赋予最高权重 (0.6), 体现其核心地位。最后, 晚检风险代表因检测时间推迟而错过最佳干预窗口的概率。虽然该风险在统计建模中相对次要, 但在临床上依然不可忽视, 因此给予较低权重 (0.1), 确保优化结果不会偏向过晚时点。

权重系数的设定遵循“误检风险 > 浓度不达标风险 > 晚检风险”的原则, 分别取 0.6、0.3 和 0.1。这一分配兼顾了 检测准确性、达标可行性和临床时效性 三方面的平衡, 既保证了模型能够优先避免误检, 又能合理考量技术条件与时间窗口的约束, 使综合风险函数在医学意义与统计合理性上保持一致。

Step1: 浓度不达标风险 R_{nc} 模型

该风险衡量在某孕周天数 T 下, 男胎 Y 染色体浓度未达到 4% 阈值的概率。为准确估计该风险, 采用高斯核加权平均方法, 使得靠近 T 的样本点具有更高权重, 从而提升局部估计的准确性。带宽参数设为 14 天 (两周), 以保证模型在时点附近具有平滑性。

$$R_{\text{nc}}(T; G_i) = \frac{\sum_{j \in G_i} \omega_j(T) \cdot \mathbb{I}(C_{Yj} < 0.04)}{\sum_{j \in G_i} \omega_j(T)} \quad (4)$$

其中: $\mathbb{I}(C_{Yj} < 0.04)$ 为指示函数, 当条件 $C_{Yj} < 0.04$ 成立时取值为 1, 否则为 0。

$\omega_j(T)$ 是赋予组内第 j 个样本的权重, 由高斯核函数计算:

$$\omega_j(T) = \exp\left(-\frac{(T_j - T)^2}{2h^2}\right) \quad (5)$$

这里, T_j 是样本 j 的实际检测孕周天数, h 为带宽参数, 控制权重衰减的速度, 设定 $h = 14$ 天 (2 周), 意味着距离目标时点 T 超过 2 周的样本其影响将显著减小。

根据孕周天数划分孕期阶段（早期：≤12 周，中期：13-27 周，晚期：≥28 周）。在调用模型求解时，对每个 BMI 分组的三个时期分别计算浓度不达标风险。结果如下：




图 8 各 BMI 分组在不同学期的 Y 染色体不达标率

结果表明，不同 BMI 分组在孕早期（≤12 周）普遍存在较高的不达标率，而中期（13-27 周）显著下降。而样本量较少的高 BMI 组由于个别异常观测放大了不达标率。

Step2: 误检风险 R_{mis} 模型

该风险反映在时点 T 下，检测结果与胎儿实际健康状况不符的概率。

$$R_{mis}(T; G_i) = \frac{\sum_{j \in G_i} \omega_j(T) \cdot M_j}{\sum_{j \in G_i} \omega_j(T)} \quad (6)$$

其中， M_j 是二值变量，表示样本 j 是否被误检（ $M_j=1$ 表示误检， $M_j=0$ 表示未误检）。由于晚期（≥28 周）的样本已在数据清洗中剔除，因此模型仅针对早期与中期进行估计。计算方式与浓度不达标风险相似，同样基于高斯核加权。




图 9 各 BMI 分组在不同孕期的误检率

结果显示，部分分组在孕早期的误检风险高于中期，而在高 BMI 分组中，由于样本量不足导致误检率为零，这并不能说明其无风险，而是数据不足的表现。

Step3: 晚检风险 R_{late} 模型

该风险用于衡量检测时间过晚，错过最佳干预与治疗窗口的可能性。

$$R_{late}(T) = \begin{cases} 0 & T \leq T_{early} (10 \text{ 周}) \\ \left(\frac{T/7 - 10}{27 - 10}\right)^p & T_{early} < T < T_{late} (27 \text{ 周}) \\ 1 & T \geq T_{late} \end{cases} \quad (7)$$

其中， T 为孕周天数， p 为风险增长指数，设定 $p=1.5$ 以反映风险随孕周推后而加速上升。

具体建模时，将 27 周之后的检测风险设定为 1，而在 10 - 27 周之间采用一个随孕周增长逐渐加速的风险函数（指数 $p=1.5$ ）进行建模。这样既体现了早检有利于风险降低的临床逻辑，也避免了推荐时点落在不可取的孕晚期区间。

Step4: 优化建模与算法实现

对于每个 BMI 分组 G_i ，其最佳检测时点 T_i ，可以通过求解以下约束优化问题得到：

$$\begin{aligned} \min_T f(T) &= R_{total}(T; G_i) \\ \text{s.t.} \quad g_1(T) &= T - T_{min}^{(i)} \geq 0 \\ g_2(T) &= T_{max}^{(i)} - T \geq 0 \end{aligned} \quad (8)$$

其中， $f(T)$ 是定义的综合风险函数； $T_{min}^{(i)}$ 和 $T_{max}^{(i)}$ 分别是各个分组 G_i 中所有样本孕周天数的下界和上界，此约束确保了推荐时点位于已有数据的可靠范围内。（最优时间点肯定得在已有样本的时间跨度里面选吧，不然根据越早越好岂不是全选 10 周）

接下来采用序列二次规划（SQP）算法族中的 SLSQP（Sequential Least Squares Quadratic Programming）算法进行问题求解。

a. 拉格朗日函数与 KKT 条件

该约束优化问题的拉格朗日函数 $\mathcal{L}(T, \lambda_1, \lambda_2)$ 定义为：

$$\mathcal{L}(T, \lambda_1, \lambda_2) = f(T) - \lambda_1 g_1(T) - \lambda_2 g_2(T) \quad (9)$$

其中， λ_1, λ_2 是对应于约束 $g_1(T)$ 和 $g_2(T)$ 的拉格朗日乘子（非负）。

该问题的一阶必要性条件（Karush-Kuhn-Tucker, KKT 条件）为：

$$\begin{aligned} \nabla_T \mathcal{L}(T^*, \lambda_1^*, \lambda_2^*) &= \nabla f(T^*) - \lambda_1^* \nabla g_1(T^*) - \lambda_2^* \nabla g_2(T^*) = 0 \\ \lambda_1^* g_1(T^*) &= 0 \\ \lambda_2^* g_2(T^*) &= 0 \\ g_1(T^*) &\geq 0 \\ g_2(T^*) &\geq 0 \\ \lambda_1^*, \lambda_2^* &\geq 0 \end{aligned} \quad (10)$$

任何局部最优解 T^* 都必须满足上述 KKT 条件。

b. SLSQP 算法的迭代过程

SLSQP 算法通过迭代求解一系列二次规划（QP）子问题来逼近原问题的解。在第 k 次迭代中，算法执行以下步骤：

首先，在当前迭代点上，对目标函数进行二阶泰勒展开，并对约束条件进行一阶线性化，从而构造近似的二次规划模型；其次，求解该二次规划子问题，得到搜索方向与步长候选解；然后，通过线搜索方法在该方向上确定最优更新幅度，以保证目标函数下降并满足约束条件；最后，更新迭代点并检验收敛性，包括一阶最优性条件是否满足、约束是否得到有效逼近以及步长是否足够小。如果未收敛，则以新的迭代点为基准重复上述步骤。该过程在保证收敛性的同时，能够处理等式与不等式约束，并在连续迭代中逐步逼近全局或局部最优解。

Step5: 算法调用与结果

算法的初始值设为该分组孕周范围的中点：

$$T^{(0)} = \frac{T_{\min}^{(i)} + T_{\max}^{(i)}}{2} \quad (11)$$

最终求得的最优解 T_i^* 转换为孕周（周）后，即为该 BMI 分组推荐的最佳 NIPT 检测时点：

$$\text{最佳检测时点（周）} = \frac{T_i^*}{7} \quad (12)$$

基于综合风险模型的优化结果显示，不同 BMI 分组的最佳 NIPT 检测时点存在差异。前三个分组的最佳检测时点均集中在孕早期 11~13 周，其中 BMI 较低的两组（[26.6,30.0）、[30.0,32.5）最佳时点分别为 12.73 周和 12 周，而中等 BMI 组（[32.5,37.4）则更早，约为 11.43 周。相比之下，高 BMI 组（[37.4,46.9）的最佳检测时点明显延后，约为 16.9 周，显示出高 BMI 孕妇在早期检测中存在更大浓度不达标风险，需要推迟检测以获得可靠结果。总体来看，四个分组的最小风险值均较低（0.0767–0.107），表明分组优化策略有效降低了误检与不达标概率。

检测误差分析进一步验证了这一结果：在各分组中，最佳检测时点前后样本的达标率差异均未达到统计显著水平（ $p > 0.05$ ），说明模型推荐的时点在稳健性上具有较好的一致性。值得注意的是，尽管部分组别在时点前后的达标率存在一定差异（如

[32.5,37.4) 组早于时点达标率略高），但置信区间均跨越零，差异不具统计意义。因此，综合风险模型推荐的最佳时点能够在保证准确性的同时，有效平衡检测过早导致的不达标风险与过晚带来的治疗延迟风险，为不同 BMI 孕妇群体提供了个性化的检测时机参考。

5.2.5 检测误差对优化结果稳健性的蒙特卡洛评估

为检验综合风险模型在不确定性条件下的稳健性，我们采用蒙特卡洛模拟方法对模型结果进行了敏感性分析。在模拟过程中，主要考虑了两类不确定性来源：一是测量误差，包括在 Y 染色体浓度 (C_Y) 中加入标准差为 0.01 的对数正态误差，以避免产生负值；在孕妇 BMI 中加入标准差为 0.5 的正态扰动；在孕周天数 T 中加入标准差为 2 天的正态扰动。二是模型不确定性，即对风险函数的权重参数引入标准差为 0.1 的正态扰动，并在扰动后重新归一化以保证权重和为 1。

模拟重复 N=50 次，每次模拟均需在扰动后的数据条件下重新进行 BMI 分组与最优检测时点的优化计算。通过对各分组最佳检测时点 T_i^* 及 BMI 分组边界的均值、标准差与变异系数进行统计汇总，可以系统地评估模型结果在误差与参数扰动条件下的稳定性，从而为临床应用提供更加可靠的参考依据。




图 10 蒙特卡洛评估结果

图中表明，模型在不同运行条件下表现出良好的稳定性，核心结论具有较高的鲁棒性。

四个 BMI 分组（组 1 至组 4）的最佳检测时点均值分布于 12.77 周至 16.65 周之间，所有值均落在临床认可的孕早期至孕中期时间窗口内。具体而言，组 1、组 2 和组 3 的推荐时间较为接近（12.77-13.08 周），而组 4 的推荐时间相对较晚（16.65 周）。通过变异系数（CV）评估各组结果的波动性发现，组 2 的变异性最大（ $CV=0.245$ ），其箱线图也显示其数据分布相对分散，四分位距较宽。组 1 的稳定性最高（ $CV=0.123$ ），其推荐时间最为集中。组 2 和组 4 的变异系数分别为 0.194 和 0.157，处于可接受范围内。这表明，尽管存在一定波动，但模型为各 BMI 分组所推荐的最佳检测时点总体上是可靠的。

五个分组边界（b1-b5）的均值从 26.62 至 47.15，依次递增，形成了连续且无重

叠的 BMI 区间，符合临床分类逻辑。边界值 $b1 (26.62 \pm 0.45)$ 和 $b5 (47.15 \pm 0.39)$ 的变异性极小，标准差分别为 0.45 和 0.39，这保证了整个 BMI 数据区间的起始和终止锚点非常稳定。内部边界中， $b4 (36.81 \pm 0.71)$ 的变异性相对最大，其箱线图的上 whisker 较长，表明存在少量较高值的离群点。然而，考虑到个体差异变化以及在边界 4 右侧的组 4 样本量较少，其存在波动幅度是可接受的，同时其不影响分组的整体有效性。所有边界点的分布均呈现明显的单峰形态，进一步证明了分组阈值确定的可靠性。

综上所述，敏感性分析结果表明，虽然因为 BMI 存在跨度大，且样本数量分布不均导致部分分组存在稍高的变异性，但模型的核心输出参数在不同次模拟中保持稳定，波动范围有限。这证实了本研究方法具有良好的鲁棒性，所得出的最佳检测时点建议和 BMI 分组标准是可靠且可信的。

5.2.6 总结

我们根据男胎孕妇 Y 染色体浓度的最早达标时间的分布使用 K-means 聚类算法对 BMI 进行分组，共分为 4 组，即 $[26.62, 29.98)$, $[29.98, 32.55)$, $[32.55, 37.43)$, $[37.43, 46.88]$ 。同时定义孕妇可能的潜在风险为三重风险，以综合风险最小的时间点作为各组最佳的 NIPT 点，依次为 12.57 周、11.7 周、11.43 周、16.82 周。并进行了敏感性分析，结果表明模型在不同运行条件下表现出良好的最佳检测时点与 BMI 分组边界的稳定性，核心结论具有较高的鲁棒性。

5.3 问题三的求解

5.3.1 数据预处理

本道题基于个体差异风险，因此需要对各个孕妇进行独立建模，在初始的表格中，有 61 个检测是孕妇序列相同，检查批次相同但是结果不同的。我们对它进行去重，只取其同次检查的两者较后的一次数据，并且对多次检测的孕妇取特征平均值作为个体代表值。

5.3.2 基于风险聚类与决策树映射的 BMI 分组

在问题三中，我们的目标是综合考虑孕妇个体差异（身高、体重、年龄等因素）、检测误差以及胎儿 Y 染色体浓度达标比例，从而在不同 BMI 水平下合理分组，并给出各分组的最佳 NIPT 检测时点，使孕妇潜在风险最小化。为此，我们建立了以 风险评分 (risk_score) 为核心的分组与映射方法，具体包括以下两个步骤。

Step1: 基于肘部法则的 K-Means 风险聚类

首先，我们构建了综合风险评分 (risk_score)，将浓度不达标概率、误检概率及检测延迟风险进行加权整合，以量化每位孕妇的总体检测风险。随后，利用 K-Means 算法对风险评分进行无监督聚类。K-Means 的目标是最小化样本点到簇中心的平方距离和，从而保证簇内的紧凑性和簇间的差异性。




图 11 孕产妇队列中风险评分的分布

在确定聚类数时，我们引入了 肘部法则（Elbow Method）。该方法通过计算不同 K 值下的惯性（Inertia，即所有点到其簇中心的平方和），并绘制随 K 增长的下曲线。当 K 较小时，Inertia 会迅速下降；当 K 较大时，Inertia 下降幅度减缓。曲线中的转折点即为最佳聚类数。在本研究中，曲线在 $K=3$ 处出现明显“肘部”，因此选择 $K=3$ 。




图 12 孕产妇风险分层中的肘部法则分析确定最佳聚类数量

聚类结果将孕妇群体分为三类：

- 低风险组（标签=0）：达标时间最早，风险评分最低；
- 中风险组（标签=1）：达标时间居中，风险适中；
- 高风险组（标签=2）：达标时间最晚，风险评分最高。

Step2: 基于决策树的 BMI 映射

为了将风险类别与临床可操作的指标联系起来，我们进一步采用 决策树方法，将孕妇的平均 BMI 值（avg_bmi）映射为对应的风险分组标签（risk_category）。




图 13 孕产妇 BMI 与风险评分的关联分析

决策树通过信息熵与信息增益的计算，自动选择最优的分裂点，使得 BMI 的不同区间能够最大程度地区分三类风险人群。最终得到的划分规则具有直观的 if-else 结构，例如：“若 $BMI \leq \text{阈值} 1$ ，则判定为低风险组；若 $\text{阈值} 1 < BMI \leq \text{阈值} 2$ ，则为中风险组；若 $BMI > \text{阈值} 2$ ，则为高风险组”。

这一过程具有双重优势：其一，避免了人工设定分界点可能带来的主观偏差；其二，生成的分组结果既保证了统计意义上的最优性，又易于临床医生理解与应用。换言之，BMI 分组标准不仅来源于数据驱动的建模结果，同时也符合医学实践的解释逻辑。

5.3.3 基于多目标优化与增强混合效应模型的最佳 NIPT 时点确定

在问题三的进一步研究中，我们引入了多目标优化的思路，综合考虑期望风险与不确定性风险，以确定不同 BMI 分组的最佳 NIPT 检测时点。具体而言，我们将综合风险函数定义为：

$$\text{目标函数} = \alpha \cdot E(R) + (1 - \alpha) \cdot U(R), \alpha = 0.5 \quad (13)$$

其中， $E(R)$ 表示期望风险， $U(R)$ 表示不确定性风险，二者权重相同，体现对检测准确性与稳健性的双重关注。

Step1: 增强版混合效应模型的选择与构建

考虑到数据具有纵向结构，每位孕妇可能存在多次检测记录，结果之间存在个体内相关性，因此我们采用了增强版混合效应模型（Enhanced Mixed-Effects Model）。该模型同时包含固定效应与随机效应，能够在量化孕周、BMI、年龄等系统性因素影响的同时，保留个体差异。模型设定为：

$$Y_{ij} = \underbrace{\beta_0 + \beta_1 \cdot \text{Week}_{ij} + \beta_2 \cdot \text{BMI}_{ij} + \beta_3 \cdot \text{Age}_i + \beta_4 \cdot \text{GC}_{ij} + \dots}_{\text{固定效应}} + \underbrace{u_i}_{\text{随机截距}} + \underbrace{\epsilon_{ij}}_{\text{随机误差}} \quad (14)$$

其中：

- 因变量：Y 染色体浓度；
- 自变量：[孕周天数、孕妇 BMI、年龄、怀孕次数、生产次数、GC 含

量];

- 假设：每位孕妇的基线浓度 $\beta_0 + u_i$ 存在差异，且随机效应 u_i 服从正态分布；

- 估计方法：最大似然估计（ML）或受限最大似然估计（REML）。

模型结果显示：组间方差 =0.000722，组内方差 =0.000286，组内相关系数（ICC）=0.717，表明总体变异中有 71.7% 可由个体间差异解释，这也验证了采用个体建模的合理性。

Step2: 最小孕周的推导

在模型参数求解后，我们可以预测任意孕周下的 Y 染色体浓度均值 $E(Y_{ij})$ 。进一步利用标准正态分布的累积分布函数（CDF， Φ 函数），反推出每位孕妇在不同孕周下浓度达标的概率。

$$P(Y_{ij} \geq 0.04) = 1 - \Phi\left(\frac{0.04 - (\beta_0 + \beta_1 \cdot \text{Week}_{ij} + \dots)}{\sqrt{\sigma_u^2 + \sigma_\epsilon^2}}\right) \quad (15)$$

当该概率首次超过 95% 时，所对应的孕周 t 被定义为该孕妇的最小可检测孕周。该方法为确定个体化的检测起点提供了明确的量化依据。

Step3: 风险函数与优化方法

结合临床现实：若首次检测失败，需等待 14 天后重测，这会带来额外风险。基于此，我们定义了两类风险：

期望风险：

$$E(R) = P(Y \geq 4\%) \cdot T + (1 - P(Y \geq 4\%)) \cdot (T + 14) \quad (16)$$

不确定性风险：

$$U(R) = 1 - P(Y \geq 4\%) \quad (17)$$

在优化中，采用 Chebyshev 标量化方法，对两类风险分别归一化，并通过最小化“最大遗憾值”的方式，寻找一个能够兼顾期望风险与不确定性风险的最优检测时点 t^* 。

$$\min_t [\max(z_{\text{risk}}(t), z_{\text{unc}}(t))] \quad (18)$$

最终，我们在各 BMI 分组下得到相应的最佳检测时点，具体结果如下：




图 14 各 BMI 分组最佳 NIPT 检测时间分析

该建模框架不仅克服了传统单目标方法的局限性，而且通过混合效应建模与多目标优化结合，能够在个体差异与临床可操作性之间实现平衡，为孕妇个体化 NIPT 时点的推荐提供了坚实的理论支持。

5.3.4 敏感性分析

在本研究中，我们进一步考察了不同 BMI 分组下，重测间隔参数对最佳 NIPT 检测时机的敏感性。结果表明，不同分组的反应存在显著差异。对于低 BMI 组和中 BMI 组，在重测间隔由 7 天延长至 21 天的范围内，其最佳检测时点始终保持不变，分别稳定在 15.8 周和 16.8 周。这说明这两类孕妇的检测时机对后续检测频率并不敏感，表现出较强的稳健性和鲁棒性。

相比之下，高 BMI 组则表现出明显的敏感性。随着重测间隔的延长，其最优检测时点从 18.6 周提前至 18.2 周，前移幅度约为 0.46 周（约 3.2 天）。这一趋势表明，当重测间隔较长时，优化算法会倾向于选择更早的初始检测时间，以降低因失败后需等待较长时间而带来的风险。这也反映出高 BMI 孕妇在检测策略制定中需要更加精细化的时点调整，以在检测成功概率与时间成本之间取得平衡。




图 15 参数敏感性分析

总体来看，该敏感性分析揭示了不同 BMI 分组在检测时机稳定性上的差异：低、中 BMI 组表现稳定，不受检测策略参数影响；而高 BMI 组对重测间隔高度敏感，提示在临床实践中需要对其制定更灵活的检测与重测方案。

5.3.5 总结

基于多因素混合效应建模与多目标优化分析，我们将孕妇按 BMI 划分为三组，区间分别为[20.7, 30.4]、[30.4, 33.7]和[33.9, 46.9]，并确定各组最佳 NIPT 检测时点依次为 15.85 周、16.76 周和 18.48 周。该分组及时点方案显著降低了因检测过早或过晚带来的潜在风险，兼顾临床可行性与个体差异，为高精度、低风险的产前筛查提供了可靠依据。

5.4 问题四的求解

5.4.1 数据预处理

在问题四的建模过程中，我们首先针对女胎样本进行了特异性处理。由于女胎不具备 Y 染色体信号，故移除了与 Y 染色体相关的特征（包括 Y 染色体 Z 值与 Y 染色体浓度），以避免无效变量对模型拟合的干扰。对于 BMI 缺失值（仅一例），我们采用样条插值方法进行补充，利用该孕妇在其他检测时点的 BMI 记录进行拟合与插值，从而保持数据的完整性与合理性。与此同时，将“IVF 妊娠”变量转化为分类变量（自然受孕=0，IVF=1），以便模型能够更有效地识别不同妊娠方式对检测结果可能产生的影响，并提升模型的性能与可解释性。最后，依据题目要求，将 21 号、18 号和 13 号染色体的非整倍体检测结果作为预测标签：若样本中检测到相应的异常（即检测有病），则记为 1；若未检测到异常（即检测无病），则记为 0。通过以上处理，最终构建了适用于后续建模的干净、结构化数据集，为分类模型的训练和验证奠定了基础。

5.4.2 基于随机森林特征筛选与 AdaBoost 分类的染色体异常检测建模

Step1: 随机森林模型与特征筛选

在本研究中，我们首先考虑对二分类问题（染色体异常与否）进行特征重要性分析。由于相关性指标（如 Spearman 系数）对于二分类任务的适用性有限，我们转而

采用随机森林模型来评估各特征对标签的贡献率。随机森林是一种典型的集成学习方法，其基本思想是通过构建多棵决策树，并利用多数投票（分类问题）或平均（回归问题）的方式得到最终预测结果，从而显著提升模型的泛化能力和鲁棒性。具体而言，若森林中包含 N 棵树，每棵树对样本的预测结果记为 $h_i(x)$ ，则随机森林的最终输出可表示为：

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_N(x)\} \quad (19)$$

其中，**mode** 表示多数投票机制。

在特征重要性计算中，随机森林通过统计分裂节点的基尼不纯度下降量来衡量特征的贡献度。每次分裂前后的基尼不纯度下降值被归因于用于分裂的特征，累计得到的下降量越大，说明该特征对模型预测结果的贡献越大。




图 16 随机森林特征重要性排序

通过计算并排序特征重要性分数，我们筛选出排名前十的关键变量：'X 染色体浓度', '13 号染色体的 GC 含量', '18 号染色体的 GC 含量', '21 号染色体的 GC 含量', '年龄', '被过滤掉读段数的比例', '孕妇 BMI', '重复读段的比例', '13 号染色体的 Z 值', 'GC 含量'，作为后续建模的核心自变量。

Step2: AdaBoost 模型与优化

在完成特征筛选后，我们对比了多种分类模型的性能，包括逻辑回归、支持向量机、K 近邻、决策树、随机森林、AdaBoost、梯度提升树、XGBoost 与 LightGBM 等。结果显示，集成学习方法整体表现优于传统单模型，尤其是 AdaBoost 在召回率和 F1 分数上的表现最为突出，能够有效缓解胎儿染色体异常检测中正负样本极度不平衡的挑战。




图 17 各分类算法 F1 分数对比

AdaBoost (Adaptive Boosting) 的核心思想是通过迭代训练多个弱分类器（如决策树桩），并在每一轮迭代中增加对被误分类样本的关注，从而逐步提升整体性能。具体而言：

- 初始化所有样本的权重，确保各样本在初始阶段被平等对待；
- 在每一轮迭代中，训练一个弱分类器，并计算其加权错误率；
- 根据错误率计算该分类器的权重，错误率越低则权重越高；
- 更新样本权重，增加误分类样本的权重，使下一轮分类器更关注“难样本”；
- 最终通过加权多数投票，将所有弱分类器组合为一个强分类器。

该方法的自适应性使得模型能够在保持整体精度的同时显著降低假阴性率，这对于临床场景中避免漏诊具有重要意义。

Step3: 阈值调优与 ROC 分析

为了进一步优化 AdaBoost 模型的分类性能，我们基于 ROC 曲线对分类阈值进行了调整。ROC 曲线描绘了不同阈值下真正例率 (TPR) 与假正例率 (FPR) 的权衡关系，其曲线越接近左上角，说明模型性能越优。AUC-ROC (曲线下面积) 用于量化模型整体性能，数值越接近 1 越好。




图 18 AdaBoost 模型 ROC 曲线

分析结果表明，默认阈值 0.5 并非最优。在综合考虑 TPR 与 FPR 的权衡后，选择阈值 0.448 能够显著提高召回率，从而降低漏诊风险。该优化在保持较高整体准确率的同时，进一步提升了模型在临床实际应用中的可靠性。

再利用该阈值重新训练模型，得到混淆矩阵为：




图 19 AdaBoost 模型混淆矩阵(使用最佳值 0.448)

基于性能指标分析，该 AdaBoost 模型在胎儿染色体异常检测任务中展现出了良好的综合性能。模型在保持较高准确率（86.84%）的同时，实现了较高的召回率（66.67%），这意味着能够有效识别出三分之二的真实染色体异常病例，这对于避免漏诊具有重要的临床价值。虽然精确率相对较低（42.11%），产生了一定的假阳性，但通过将决策阈值从默认的 0.5 优化至 0.448，在召回率和精确率之间取得了更好的平衡，F1 分数达到 0.5161。高达 0.8779 的 AUC-ROC 值表明模型具备优秀的整体区分

能力，而 0.5335 的 AUC-PR 值在如此高度不平衡的数据集中也属合理表现。总体而言，该模型是一个可靠且有效的辅助诊断工具，特别适合于产前筛查中的初筛阶段。

5.4.3 敏感性分析

• 超参数敏感性分析

从分析结果来看，AdaBoost 模型对超参数表现出良好的稳定性。`n_estimators` 在 50-150 范围内，`learning_rate` 在 0.1-0.5 范围内都能保持较好的性能，F1 分数变化范围相对较小（约 0.61-0.70），这表明模型对超参数的选择不特别敏感，在实际应用中具有较好的鲁棒性和易用性。




图 20 超参数敏感性分析

• 特征重要性分析

特征重要性分析显示，13 号染色体的 GC 含量(0.2357)和 X 染色体浓度(0.2127)是最重要的两个特征，这与生物学预期相符，因为染色体异常检测主要依赖这些遗传标记。孕妇 BMI (0.1745) 和年龄 (0.1301) 也显示出较高重要性，说明母体因素在预测中扮演重要角色，这为临床诊断提供了有价值的参考。

• 特征移除敏感性分析

特征移除实验表明，X 染色体浓度的移除导致 F1 分数下降最多 (-0.275)，证实了其在预测中的关键作用。有趣的是，移除 18 号和 21 号染色体的 GC 含量以及 13 号染色体的 Z 值反而略微提升了性能 (+0.028)，这可能暗示这些特征存在一定的冗余性或噪声，需要在特征工程中进一步优化。




图 22 特征移除敏感性分析

● 数据噪声鲁棒性分析

模型对数据噪声表现出中等敏感性，当噪声水平从 0.01 增加到 0.3 时，F1 分数下降 0.075。虽然性能有所下降，但下降幅度相对温和，表明模型具有一定的抗噪声能力。在实际应用中，这意味着即使数据存在一定测量误差，模型仍能保持相对稳定的性能。

5.4.4 总结

我们首先利用随机森林模型对全部候选特征进行重要性评估，筛选出对异常判定贡献最大的前 10 个变量作为核心自变量。随后，为解决胎儿染色体异常样本极度不平衡的问题，建立了 AdaBoost 集成分类模型，通过迭代训练弱分类器并自适应调整样本权重，以增强对难分类异常样本的识别能力。进一步地，通过 ROC 曲线分析与分类阈值调优，将默认阈值从 0.5 调整为 0.448。最终，模型在女胎染色体异常检测中表现出较高综合性能：准确率 86.84%、召回率 66.67%、F1 分数 0.5161，AUC-ROC 达到 0.8779，AUC-PR 为 0.5335，显示其具备可靠的临床辅助诊断能力，尤其适用于产前筛查的初筛阶段。

六、模型的优缺点与改进

6.1 模型的优点

本建模过程具有多层次、系统化的特点，能够充分结合孕妇个体差异与测序数据特征，实现对 NIPT 检测的全方位分析。首先，通过 Spearman 秩相关、Logit 回归与 GAM 等统计方法识别关键影响因素，为变量选择提供科学依据，并捕捉非线性效应。其次，在男胎 Y 染色体浓度分析中，采用插值、聚类、混合效应模型及多目标优化，能够量化误检风险、不达标风险和晚检风险，并为不同 BMI 分组推荐个性化最佳检测时点，兼顾准确性与稳健性。再次，对于女胎染色体异常判定，引入随机森林特征筛选与 AdaBoost 集成学习，并结合阈值优化，有效提升了在样本高度不平衡情况下对异常样本的识别能力，保证了临床应用的可靠性与可操作性。最后，建模过程中考虑测量误差与不确定性，使方法在实际应用中更稳健。

6.2 模型的缺点

尽管本建模框架综合考虑了多种因素和不确定性，但仍存在一定局限性。首先，模型在女胎异常判定中，精确率相对较低，仍可能产生一定的假阳性，增加后续临床复检负担。其次，混合效应模型和多目标优化方法对数据量和计算资源要求较高，在

数据不足或高维特征下可能出现过拟合或模型稳定性下降。再者，模型的部分参数（如聚类分组数量、阈值调优）具有一定的主观性，需要结合实际临床经验进行微调，可能影响普适性。最后，对于极端 BMI 或特殊孕妇群体，模型的预测精度和风险评估能力尚需进一步验证。

6.3 模型的改进

针对上述不足，未来可从以下方面改进模型：一是引入更多高质量、多中心的临床数据，以增强模型的泛化能力和稳健性；二是对女胎异常判定，可结合深度学习方法（如多模态神经网络）进一步提升对异常样本的识别能力，同时减少假阳性率；三是优化混合效应模型和多目标优化算法，降低计算复杂度，并可考虑自动化超参数调优，提高模型稳定性和可操作性；四是针对极端 BMI 或特殊孕妇群体，建立分层或自适应模型，使检测时点和风险评估更加个性化和精细化，从而进一步提高临床应用价值。

七、 参考文献

- [1] Deng C, Liu J, Liu S, Liu H, Bai T, Jing X, Xia T, Liu Y, Cheng J, Wei X, Xing L, Luo Y, Zhou Q, Zhu Q and Liu S (2023) Maternal and fetal factors influencing fetal fraction: A retrospective analysis of 153,306 pregnant women undergoing noninvasive prenatal screening. *Front. Pediatr.* 11:1066178. doi: 10.3389/fped.2023.1066178
- [2] Panchalee T, Vossaert L, Wang Q, Crovetti BR, McCombs AK, Wapner RJ, Van den Veyver IB, Beaudet AL. The effect of maternal body mass index and gestational age on circulating trophoblast yield in cell-based noninvasive prenatal testing. *Prenat Diagn.* 2020 Oct;40(11):1383-1389. doi: 10.1002/pd.5755. Epub 2020 Aug 5. PMID: 32452065; PMCID: PMC7688572.
- [3] Deng C, Liu S. Factors Affecting the Fetal Fraction in Noninvasive Prenatal Screening: A Review. *Front Pediatr.* 2022 Jan 27;10:812781. doi: 10.3389/fped.2022.812781. PMID: 35155308; PMCID: PMC8829468.
- [4] Hui L, Bianchi DW. Fetal fraction and noninvasive prenatal testing: What clinicians need to know. *Prenat Diagn.* 2020 Jan;40(2):155-163. doi: 10.1002/pd.5620. Epub 2019 Dec 10. PMID: 31821597; PMCID: PMC10040212.
- [5] Gazdarica J, Forgacova N, Sladeczek T, Kucharik M, Budis J, Hyblova M, et al. (2024) Insights into non-informative results from non invasive prenatal screening through gestational age, maternal BMI, and age analyses. *PLoS ONE* 19(3): e0280858. <https://doi.org/10.1371/journal.pone.0280858>
- [6] 蓝志衡.DNA 序列分布比率法在无创产前胎儿染色体非整倍体检测中的应用[D].华南理工大学,2020.DOI:10.27151/d.cnki.ghnlu.2020.005132.

附录

斯皮尔曼相关性分析

```
# ===== 斯皮尔曼相关性分析 =====  
  
import pandas as pdimport numpy as npfrom scipy.stats import spearmanr  
  
# 读取数据  
  
df = pd.read_excel(r"男胎怀孕检测数据.xlsx")  
  
# 选择分析列  
  
selected_cols = ['年龄', '身高', '体重', '孕妇 BMI', '孕周天数', 'Y 染色体浓度']  
  
# 创建相关系数矩阵  
  
spearman_m = pd.DataFrame(index=selected_cols, columns=selected_cols)  
p_m = pd.DataFrame(index=selected_cols, columns=selected_cols)  
  
# 计算斯皮尔曼相关系数和p 值for i, col1 in enumerate(selected_cols):  
    for j, col2 in enumerate(selected_cols):  
        if i == j:  
            spearman_m.loc[col1, col2] = 1.0  
            p_m.loc[col1, col2] = 0.0  
        elif i < j:  
            v_data = df[[col1, col2]].dropna()  
            if len(v_data) >= 3:  
                corr, p_value = spearmanr(v_data[col1], v_data[col2])  
                spearman_m.loc[col1, col2] = corr  
                spearman_m.loc[col2, col1] = corr  
                p_m.loc[col1, col2] = p_value  
                p_m.loc[col2, col1] = p_value  
  
# 输出结果  
  
print("斯皮尔曼相关系数矩阵:")print(spearman_m.round(3))print("\nP 值矩阵:")print(p_m.round(4))
```

GAM 模型

```
# ===== 广义加性模型(GAM) =====  
  
import statsmodels.api as smfrom patsy import dmatriximport warnings  
  
warnings.filterwarnings('ignore')  
  
# 准备数据  
  
features = ['孕妇 BMI', '孕周天数', '年龄']  
target = 'Y 染色体浓度'  
df_clean = df[features + [target]].dropna()  
  
# 创建样条基  
  
df_spline = df_clean.copy()  
spline_terms = []  
  
for var in features:  
    knots = np.quantile(df_spline[var].dropna(), [0.25, 0.5, 0.75])  
    spline_basis = dmatrix(f"cr({var}, knots=knots)",  
                           {var: df_spline[var]},  
                           return_type='dataframe')
```

```

spline_cols = [f'{var}_sp{i}' for i in range(spline_basis.shape[1])]
spline_basis.columns = spline_cols
df_spline = pd.concat([df_spline, spline_basis], axis=1)
spline_terms.extend(spline_cols)

# 构建并拟合 GAM 模型
formula = f'{target} ~ {' + '.join(spline_terms)}'
X = df_spline[spline_terms]
X = sm.add_constant(X)
y = df_spline[target]

model_gam = sm.OLS(y, X).fit()

# 输出模型结果
print(model_gam.summary())

```

逻辑回归

```

# ===== 逻辑回归分析 =====
from sklearn.metrics import roc_auc_score, confusion_matrix

# 准备二分类数据
cutoff_value = df_clean[target].quantile(0.4)
df_clean['Y 浓度分类'] = (df_clean[target] > cutoff_value).astype(int)

# 选择特征
logistic_features = ['年龄', '孕妇 BMI', '孕周天数']
target_binary = 'Y 浓度分类'

# 拟合逻辑回归模型
X_logistic = df_clean[logistic_features]
X_logistic = sm.add_constant(X_logistic)
y_logistic = df_clean[target_binary]

logistic_model = sm.Logit(y_logistic, X_logistic)
logistic_results = logistic_model.fit()

# 输出模型结果和评估 print(logistic_results.summary())
y_pred_proba = logistic_results.predict(X_logistic)
auc_score = roc_auc_score(y_logistic, y_pred_proba)
print(f"AUC 得分: {auc_score:.4f}")

```

增强版混合效应模型类

```

class EnhancedPregnancyModel:
    """增强版孕期预测模型核心类"""

    def __init__(self, min_concentration=0.04):
        self.min_concentration = min_concentration

```

```

self.trained_model = None
self.model_output = None

def load_and_process_data(self, data_source):
    """载入并处理数据"""
    data = pd.read_excel(data_source)
    healthy_male_data = data[data['胎儿是否健康'] == '是'].copy()

    # 选择相关特征
    feature_columns = ['孕妇代码', '孕周天数', '孕妇 BMI', 'Y 染色体浓度', '年龄',
                       '怀孕次数', '生产次数', 'GC 含量']
    existing_columns = [col for col in feature_columns if col in healthy_male_data.columns]
    processed_data = healthy_male_data[existing_columns].dropna()

    return processed_data.rename(columns={
        '孕妇代码': 'subject_id',
        '孕周天数': 'week',
        '孕妇 BMI': 'bmi',
        'Y 染色体浓度': 'y_concentration',
        '年龄': 'age',
        '怀孕次数': 'pregnancy_count',
        '生产次数': 'delivery_count',
        'GC 含量': 'gc_content'
    })

def assess_multicollinearity(self, dataframe):
    """评估多重共线性"""
    numerical_features = ['week', 'bmi', 'age', 'pregnancy_count', 'delivery_count', 'gc_content']

    valid_features = [feat for feat in numerical_features if feat in dataframe.columns]

    if len(valid_features) < 2:
        return valid_features

    X_data = add_constant(dataframe[valid_features])
    vif_results = pd.DataFrame({
        "特征项": X_data.columns,
        "VIF 值": [variance_inflation_factor(X_data.values, i) for i in range(len(X_data.columns))]
    })

    # 移除高 VIF 特征
    high_vif_features = vif_results[vif_results['VIF 值'] > 10]['特征项'].tolist()
    if 'const' in high_vif_features:

```

```

        high_vif_features.remove('const')

    return [feat for feat in valid_features if feat not in high_vif_features]

def train_mixed_effects_model(self, dataframe):
    """训练混合效应模型"""
    valid_features = self.assess_multicollinearity(dataframe)
    model_formula = 'y_concentration ~ ' + ' + '.join(valid_features)

    # 拟合混合效应模型
    self.trained_model = mixedlm(model_formula, dataframe, groups=dataframe['subject_id'], r
e_formula='1')
    self.model_output = self.trained_model.fit()

    return self.model_output

def predict_y_concentration(self, feature_dict, gestation_week):
    """预测 Y 染色体浓度"""
    if self.model_output is None:
        raise ValueError("请先完成模型训练")

    model_params = self.model_output.params
    predicted_value = model_params.get('Intercept', 0)
    predicted_value += model_params.get('week', 0) * gestation_week

    for feature, value in feature_dict.items():
        if feature in model_params.index:
            predicted_value += model_params[feature] * value

    return predicted_value

```

K-means + 决策树 的风险分组类

```

import pandas as pd
import numpy as np
from sklearn.cluster import KMeans
from sklearn.tree import DecisionTreeClassifier, plot_tree
import matplotlib.pyplot as plt

class RiskGroupingModel:
    """风险分组核心模型 (K-means + 决策树)"""

    def __init__(self):
        self.kmeans_model = None
        self.tree_model = None

```



```

self.bmi_thresholds = None

def load_data(self, file_path):
    """加载风险评分数据"""
    df = pd.read_csv(file_path)
    return df[['subject_id', 'risk_score', 'avg_bmi', 'avg_age']].dropna()

def find_optimal_k(self, risk_scores, max_k=8):
    """使用肘部法则确定最佳 K 值"""
    inertias = []
    for k in range(2, max_k + 1):
        kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
        kmeans.fit(risk_scores.reshape(-1, 1))
        inertias.append(kmeans.inertia_)

    # 计算二阶导数找肘点
    second_derivs = []
    for i in range(1, len(inertias) - 1):
        deriv = inertias[i-1] - 2*inertias[i] + inertias[i+1]
        second_derivs.append(deriv)

    optimal_k = np.argmax(second_derivs) + 2 # +2 因为从 k=2 开始
    return optimal_k

def cluster_risk_groups(self, df, n_clusters=4):
    """K-means 风险分组"""
    risk_scores = df['risk_score'].values.reshape(-1, 1)

    self.kmeans_model = KMeans(n_clusters=n_clusters, random_state=42, n_init=10)
    df['risk_group'] = self.kmeans_model.fit_predict(risk_scores)

    # 按风险得分排序分组
    group_means = df.groupby('risk_group')['risk_score'].mean()
    sorted_groups = group_means.sort_values().index
    group_mapping = {old: new for new, old in enumerate(sorted_groups)}
    df['risk_group'] = df['risk_group'].map(group_mapping)

    return df

def train_decision_tree(self, df, features=['avg_bmi', 'avg_age']):
    """训练决策树映射 BMI 到风险分组"""
    X = df[features]
    y = df['risk_group']

```

```

self.tree_model = DecisionTreeClassifier(max_depth=3, random_state=42)
self.tree_model.fit(X, y)

# 提取决策边界 (BMI 阈值)
self._extract_bmi_thresholds()

return self.tree_model

def _extract_bmi_thresholds(self):
    """从决策树提取 BMI 分割阈值"""
    if self.tree_model is None:
        return None

    # 获取决策树结构
    tree = self.tree_model.tree_
    feature_names = ['avg_bmi', 'avg_age']

    bmi_thresholds = []
    for i in range(tree.node_count):
        if tree.feature[i] == 0: # avg_bmi 特征
            bmi_thresholds.append(tree.threshold[i])

    self.bmi_thresholds = sorted(set(bmi_thresholds))
    return self.bmi_thresholds

def predict_risk_group(self, bmi, age):
    """预测风险分组"""
    if self.tree_model is None:
        raise ValueError("请先训练决策树模型")

    return self.tree_model.predict([[bmi, age]])[0]

def get_bmi_groups(self):
    """获取 BMI 分组区间"""
    if not self.bmi_thresholds:
        return None

    groups = []
    thresholds = [-np.inf] + self.bmi_thresholds + [np.inf]

    for i in range(len(thresholds) - 1):
        groups.append((thresholds[i], thresholds[i + 1]))

    return groups

```

随机森林特征重要性

```
# ===== 随机森林特征重要性部分 =====

import pandas as pd
import numpy as np
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder

# 读取数据
df = pd.read_excel("女胎数据.xlsx", sheet_name="Sheet1")

# 选择特征列和标签列
exclude_cols = ['序号', '孕妇代码', '末次月经', '检测日期', '胎儿是否健康', '标签', '染色体的非整倍体', '检测孕周', '怀孕次数']

feature_cols = [col for col in df.columns if col not in exclude_cols and col != '标签']

# 处理分类变量
le = LabelEncoder()
df['IVF 妊娠'] = le.fit_transform(df['IVF 妊娠'])

# 处理缺失值
numeric_cols = df[feature_cols].select_dtypes(include=[np.number]).columns
df[numeric_cols] = df[numeric_cols].fillna(df[numeric_cols].median())

# 定义X和y
X = df[feature_cols]
y = df['标签']

# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 训练随机森林模型
rf = RandomForestClassifier(n_estimators=100, random_state=42)
rf.fit(X_train, y_train)

# 获取特征重要性
importance = rf.feature_importances_
feature_importance_df = pd.DataFrame({
    '特征': feature_cols,
    '重要性': importance}).sort_values(by='重要性', ascending=False)

print("="*50)
print("随机森林特征重要性排序（前10个最重要特征）")
print("="*50)
print(feature_importance_df.head(10).to_string(index=False))
```

最小生成树

```
# ===== AdaBoost 拟合部分 =====

from sklearn.ensemble import AdaBoostClassifier
```

```

from sklearn.preprocessing import StandardScaler
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score

# 选择最重要的10个特征
selected_features = [
    'X 染色体浓度', '13 号染色体的 GC 含量', '18 号染色体的 GC 含量', '21 号染色体的 GC 含量',
    '年龄', '被过滤掉读段数的比例', '孕妇 BMI', '重复读段的比例', '13 号染色体的 Z 值', 'GC 含量']

# 处理缺失值 for col in selected_features:
    if df[col].isnull().sum() > 0:
        df[col] = df[col].fillna(df[col].median())

# 定义 X 和 y
X = df[selected_features]
y = df['标签']

# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)

# 数据标准化
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# 训练 AdaBoost 模型
ada = AdaBoostClassifier(n_estimators=100, random_state=42)
ada.fit(X_train_scaled, y_train)

# 预测
y_pred = ada.predict(X_test_scaled)
y_pred_proba = ada.predict_proba(X_test_scaled)[: , 1]

# 计算性能指标
accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred, zero_division=0)
recall = recall_score(y_test, y_pred, zero_division=0)
f1 = f1_score(y_test, y_pred, zero_division=0)
auc_score = roc_auc_score(y_test, y_pred_proba)

print("\n" + "="*50)
print("AdaBoost 模型性能指标")
print("="*50)
print(f"准确率: {accuracy:.4f}")
print(f"精确率: {precision:.4f}")
print(f"召回率: {recall:.4f}")
print(f"F1 分数: {f1:.4f}")
print(f"AUC-ROC: {auc_score:.4f}")

```

多目标优化检测

```
# ===== 多目标优化检测时机核心代码 =====
```

```

import pandas as pd
import numpy as np
from sklearn.cluster import KMeans
from sklearn.tree import DecisionTreeClassifier
class DetectionTimingOptimizer:
    """多目标优化检测时机求解器"""

    def __init__(self, risk_data_path, output_directory):
        self.risk_data_path = risk_data_path
        self.output_directory = output_directory
        self.risk_assessments = None
        self.optimization_outputs = None

    def import_risk_assessments(self):
        """导入风险评估数据"""
        self.risk_assessments = pd.read_csv(self.risk_data_path)
        return self.risk_assessments

    def execute_risk_categorization(self, num_categories=3):
        """执行风险评估分类（风险层级划分）"""
        # 使用K-means 对达标时间进行聚类
        kmeans_model = KMeans(n_clusters=num_categories, random_state=42)
        risk_categories = kmeans_model.fit_predict(self.risk_assessments[['achievement_time']].
values)

        # 添加风险分类标签
        self.risk_assessments['risk_category'] = risk_categories

        # 按风险评分排序，确保标签含义一致
        category_means = self.risk_assessments.groupby('risk_category')['achievement_time'].mean().sort_values()
        category_mapping = {original_label: new_label for new_label, original_label in enumerate(
category_means.index)}
        self.risk_assessments['risk_category'] = self.risk_assessments['risk_category'].map(category_mapping)

        return self.risk_assessments

    def map_to_bmi_classifications(self):
        """将风险分类映射到 BMI 分类"""
        # 使用决策树进行映射
        X_features = self.risk_assessments[['avg_bmi']].values
        y_labels = self.risk_assessments['risk_category'].values

```

```

# 训练决策树模型
tree_model = DecisionTreeClassifier(max_depth=2, random_state=42)
tree_model.fit(X_features, y_labels)

# 获取 BMI 分割阈值
bmi_thresholds = tree_model.tree_.threshold[tree_model.tree_.threshold != -2]
bmi_thresholds = sorted(bmi_thresholds)

# 创建 BMI 分类函数
def assign_bmi_classification(bmi_value):
    if bmi_value <= bmi_thresholds[0]:
        return 0
    elif bmi_value <= bmi_thresholds[1]:
        return 1
    else:
        return 2

self.risk_assessments['bmi_class'] = self.risk_assessments['avg_bmi'].apply(assign_bmi_classification)
self.risk_assessments['BMI 分组 ID'] = self.risk_assessments['bmi_class']

return bmi_thresholds

def compute_optimal_detection_timings(self, use_multiobjective=True):
    """计算各类别的最佳检测时机（多目标优化方法）"""
    if use_multiobjective:
        # 使用多目标优化引擎
        optimization_results = self.optimization_engine.optimize_all_categories(self.risk_assessments)

    # 转换为 DataFrame 格式
    timing_results = []
    for category_id, result in optimization_results.items():
        category_data = self.risk_assessments[self.risk_assessments['BMI 分组 ID'] == category_id]

        category_stats = {
            'bmi_group': category_id,
            'optimal_detection_time': result['optimal_t'] / 7, # 转换为孕周
            'optimal_detection_time_days': result['optimal_t'], # 保持天数
            'sample_count': result['group_size'],
            'mean_bmi': result['avg_bmi'],
            'bmi_range': f"{category_data['avg_bmi'].min():.1f}-{category_data['avg_bmi'].max():.1f}",

```



```

        'strategy': result['strategy'],
        'min_risk': result['min_risk'],
        'p_target': result['p_target'],
        'coverage_quantile': result['coverage_quantile'],
        'min_gap_days': result['min_gap_days']
    }
    timing_results.append(category_stats)

self.optimization_outputs = pd.DataFrame(timing_results)

else:
    # 分位数方法作为备选方案
    quantile_value = 0.75
    results_data = []

    for category_id in sorted(self.risk_assessments['BMI 分组 ID'].unique()):
        category_data = self.risk_assessments[self.risk_assessments['BMI 分组 ID'] == category_id]

        # 计算该类别的分位数作为安全保障检测时机
        optimal_timing = np.percentile(category_data['achievement_time'], quantile_value
* 100)

        category_stats = {
            'bmi_group': category_id,
            'optimal_detection_time': optimal_timing,
            'sample_count': len(category_data),
            'mean_achievement_time': category_data['achievement_time'].mean(),
            'std_achievement_time': category_data['achievement_time'].std(),
            'mean_bmi': category_data['avg_bmi'].mean(),
            'bmi_range': f"{category_data['avg_bmi'].min():.1f}-{category_data['avg_bmi']
'].max():.1f}",
            'mean_success_prob': category_data['current_success_prob'].mean()
        }

        results_data.append(category_stats)

    self.optimization_outputs = pd.DataFrame(results_data)

return self.optimization_outputs

```