

基于多模态特征融合的点击率预测模型研究

小组成员：李盛鹏，毛经纶，杨霁然

2025 年 7 月 3 日

摘要

智慧城市在科学和工程领域都引起了极大的兴趣，改变了人类生活的不同领域，如交通、购物、在线社交等。在信息爆炸的背景下，推荐系统已成为互联网产品中不可或缺的核心技术之一，广泛应用于电商、短视频、社交媒体等场景中。传统的推荐系统主要依赖结构化行为数据（如点击、购买、评分等）进行建模。然而，随着用户生成内容（UGC）的激增，推荐对象（商品、视频、帖子等）日益呈现出多模态特征，包括文本描述、图像信息、甚至音视频内容。如何充分利用这些模态数据进行有效建模，成为推动推荐系统性能跃升的关键。

近年来，多模态推荐系统逐渐成为研究热点。此类系统通过融合图像、文本、标签等模态信息，以获得更全面、语义更丰富的项目表示，从而提升点击率（CTR）、转化率（CVR）等预测指标。已有研究在多模态特征融合、跨模态对齐、特征压缩等方面取得一定进展，部分工业级系统如阿里巴巴、美团、Pinterest 等也开始将图文模态引入其推荐引擎中。然而多模态推荐系统在工业端仍面临着挑战，由于多模态特征本身维度高、冗余多，直接使用原始图像或文本编码不仅带来存储与计算压力，也可能影响模型的鲁棒性与泛化能力。

为此，本研究基于嵌入-预测（Embed-then-Predict framework, EP）框架，以 WWW 2025 EReL@MIR 研讨会举办的 MM-CTR 挑战赛为实验背景，基于其提供的 MicroLens-1M 多模态点击数据集，完成了多模态特征的嵌入和点击率的预测。在嵌入阶段，基于改进的 CLIP-ViT 模型分别提取视觉与文本特征，设计自适应加权融合机制（图像权重 0.4/文本权重 0.6），并结合 PCA 降维技术，在保留 95% 方差解释度的前提下将特征压缩至 128 维，大幅降低特征存储开销；在 CTR 预测阶段，构建轻量化多模态预测网络，引入特征交叉模块以强化不同模态间的信息交互，并通过计算图级优化实现平均 <30 ms 的推理延迟。该框架兼顾了多模态特征表达的丰富性与工业化部署的高效性，为在线推荐系统的实时、多模态信息融合提供了解决方案。

关键词：多模态推荐系统；点击率预测；特征融合；深度学习；CLIP 模型

目录

1	引言	3
1.1	研究背景	3
1.2	研究意义	3
2	研究现状	3
3	项目简介	4
3.1	数据分析	4
4	task1: 多模态嵌入模型设计	4
4.1	实验基本流程	5
4.2	嵌入方法	5
4.2.1	直接拼接方法	5
4.2.2	加权求和方法	5
4.3	实验结果	6
5	task2:CTR 预测模型设计	6
5.1	数据处理	6
5.2	模型方法	7
5.2.1	SENet 模块	7
5.2.2	多头注意力目标机制	7
5.3	建模流程	8
5.4	实验结果	8
6	task1&2: 端到端级联优化	8
6.1	嵌入阶段	9
6.1.1	图文嵌入模块	9
6.1.2	嵌入压缩与归一化	9
6.2	预测阶段	9
6.2.1	注意力机制	9
6.2.2	兴趣池化	9
6.2.3	SENet 通道注意力	9
6.2.4	多层感知机预测	10
6.3	实验结果分析	10
7	结论	11
8	参考文献	11

1 引言

1.1 研究背景

在推荐系统、计算广告和信息检索等领域，点击率（CTR）或转化率预测一直是核心任务。随着内容形式的多样化，单一模态（仅文本或仅图像）的特征已无法充分刻画用户兴趣与项目特性。多模态预测模型由此兴起，通过同时利用图像、文本、属性标签、用户行为等多源信息，构建更丰富的特征表示，以期提升预测精度和系统鲁棒性。

在现实中，电子商务商品通常伴随详尽的文本描述和多张产品图像；短视频平台也同时具备视频帧、字幕、音频乃至用户评论。单独使用任一模态会丢失重要语义信息，难以应对品类多样、用户偏好多变的场景。而大规模在线系统对响应延迟和资源消耗要求严格，这些对于多模态模型来说，一直都是亟待解决的难题。它要求研究者在保证表征能力的同时，探索高效的特征压缩与模型加速技术。

1.2 研究意义

如何在保证多模态语义表达能力的前提下，设计出既具备高效压缩特性又能满足毫秒级在线推理的模型框架，成为多模态推荐领域的核心难题。本研究旨在通过构建高效的多模态特征融合框架，提升推荐系统的性能，同时满足工业级部署的实时性要求。

2 研究现状

多模态预测模型通过利用 CLIP、ViLT、ALIGN 等大规模图文预训练模型获取高质量、通用性强的向量嵌入，经过一系列适配与融合处理后，最终用于下游点击率（CTR）或转化率预测任务。为了能够提升效率和准确性，在嵌入方面，现有研究主要集中于两类技术路径：

一是对预训练特征进行降维或量化压缩，如利用 PCA、Autoencoder 或向量量化方法，将高维视觉-文本向量映射至低维紧凑空间；二是通过模型剪枝、知识蒸馏与算子级优化等手段，简化网络结构与加速前向推理。然而，前者往往面临信息丢失导致的性能退化风险，后者则多针对单一模态或通用视觉/文本网络，缺乏对多模态交互特性的专门优化。

在预测方面，现有研究主要聚焦于设计能够充分挖掘多模态特征间高阶交互的轻量化网络结构。一类方法基于经典的深度神经网络（DNN）框架，诸如 Wide & Deep、DeepFM、xDeepFM、DCN 等，通过特征交叉（Cross Network）、矩阵分解或注意力机制在网络隐藏层内显式建模不同模态及其与其他字段特征之间的组合效应，以提升 CTR 预测精度。

现有多模态推荐方法主要存在两个方面的不足：一方面，多数研究仅聚焦于“特征压缩”或“模型加速”中的某一环节，且多采用通用的降维、剪枝或蒸馏技术，缺乏针

对多模态交互特性的任务适应性优化；另一方面，项目嵌入与 CTR 预测往往被割裂为两个独立阶段，缺少端到端的级联协同设计。

3 项目简介

本研究基于 WWW 2025 EReL@MIR 研讨会主办的多模态点击率预测 (MM-CTR) 挑战赛展开，旨在探索推荐系统中多模态项目表示与 CTR 预测任务的高效协同优化路径。挑战赛以 MicroLens-1M 为基础数据集，提供了包含文本标题、商品封面图像与结构化属性的丰富项目数据，以及用户点击行为序列，构建了真实电商场景下的推荐建模任务。

比赛共设两个子任务：任务一聚焦于多模态项目嵌入的设计与提取，要求参赛者利用图文信息构建定长的 128 维嵌入表示，用以增强推荐系统对项目语义的理解能力；任务二则要求在给定项目嵌入的基础上，构建 CTR 预测模型，挖掘用户与项目之间的潜在交互模式，从而提升点击率预测精度。

3.1 数据分析

本研究基于 MicroLens-1M 数据集完成模型训练与验证，该数据集由西湖大学团队发布，专为研究大规模多模态推荐系统设计。数据集模拟真实电商与内容平台中的点击行为与项目特征，覆盖图像、文本、序列等多种模态信息。整体包含 100 万级用户交互数据，近 9 万商品条目，具备良好的规模与模态丰富性。

数据集	含义
MicroLens_1M_x1/train.parquet	训练集
MicroLens_1M_x1/valid.parquet	验证集
MicroLens_1M_x1/test.parquet	测试集，不带标签
MicroLens_1M_x1/item_info.parquet	item_id、item_tags 和 128-d item_emb 功能
item_feature.parquet	原始特征和提取的特征嵌入
item_emb.parquet	128 维项目嵌入四个版本
item_seq.parquet	1M 个用户的商品序列
item_images.rar	商品的原始封面图片

表 1: 数据集结构说明

4 task1: 多模态嵌入模型设计

任务一要求做多模态嵌入，将图像数据和文本数据融合成一个 128 维的向量。为了评判嵌入的优劣，采用官网的固定基线模型训练新生成的 item 文件，只允许改变模型的某几个参数，不能对模型进行优化。

4.1 实验基本流程




图 1: 多模态嵌入处理流程

先分别用预训练模型将文本数据和图像数据处理成向量，再融合成一个向量，最后特征降维到 128 维，插入 info 文件并验证。

4.2 嵌入方法

对于嵌入阶段，使用的数据包括 feature.parquet 中的”item_title”与”item_id”和图片数据，使用 CLIP (Contrastive Language-Image Pretraining) 模型将文本数据和图像数据处理成向量。分别得到文本和图像的向量后，采用两种融合方法：

4.2.1 直接拼接方法

直接拼接的优势包括保留完整信息，不会丢失原始特征，模型可以从完整的特征中学习文本和图像各自独特的信息；灵活性高，拼接后的特征包含了更丰富的原始信息。

然而，直接拼接也存在劣势：维度灾难，会显著增加特征向量的维度，高维度数据会增加模型的计算复杂度和训练时间；特征冗余，不同模态的数据可能存在重复或相关性较高的信息。

4.2.2 加权求和方法

加权求和方法采用图像权重 0.4 和文本权重 0.6 的融合策略：

$$fusion_feats = 0.4 \times img_feats + 0.6 \times txt_feats \quad (1)$$

加权求和的优势包括降低维度，不会增加特征维度，减少了计算量和过拟合的风险；通过调整权重可以突出重要信息。劣势是可能存在信息损失，权重确定需要大量实验调优。L2 正则化：

$$x'' = \frac{x}{|x|} \quad (2)$$

经过实验对比，采用直接拼接的方式会导致 PCA 的输入向量过大，造成较大的信息损失，而加权求和会使得生成向量的模差距过大，因此在 PCA 之前一定要进行 L2 正则化来统一向量的模，采用加权求和方法配合 L2 正则化，在 PCA 过程中能够更好地保持信息，取得了更好的效果。



图 2: 向量加法导致生成向量模差距较大

4.3 实验结果

方法	AUC 分数
CLIP+BERT+ 拼接 +PCA	0.7944
CLIP+ 加权求和 +L2 正则化 +PCA	0.8934

表 2: 不同嵌入方法实验结果

5 task2:CTR 预测模型设计

任务二是多模态 CTR 预测，该任务旨在探索多模式推荐模型可以有效利用多模式嵌入功能并实现更好的性能。利用数据集中提供提取的多模态嵌入，基于提供的基线模型来改善多模式推荐模型，以增强 CTR 预测结果。

5.1 数据处理

实验模型应用了 4 个数据集: item_info.parquet、test.parquet、train.parquet、valid.parquet，每个数据集包含多个元组，每个元组有 6 个元素，分别是 user_id、item_seq、item_id、likes_level、views_level 和 label。

	user_id	item_seq	item_id	likes_level	views_level	label
0	861687	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	33811	4	4	0
1	210622	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	12875	9	5	1
2	861880	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	1678	9	8	1
3	767068	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	76303	6	2	0
4	745698	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	2561	8	6	0
...	...	...	...	...	...	...
3599995	676432	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	20877	3	1	0
3599996	992563	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	66434	9	7	0
3599997	306906	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	29448	7	6	0
3599998	702721	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	51587	7	6	0
3599999	110185	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	47331	8	7	1

[3600000 rows x 6 columns]

图 3: 文件结构

5.2 模型方法

基于深度兴趣网络 (DIN) 改进架构, 主要包含特征嵌入层、多头目标注意力机制、SENet 模块和深度神经网络等核心组件。

5.2.1 SENet 模块

SENet 模块是该模型的核心组件之一, 它通过通道注意力机制实现了对特征通道的动态重要性调整。其工作原理可分为三个关键阶段:

在 Squeeze 阶段, 通过对序列维度进行全局平均池化:

$$z_c = \frac{1}{L} \sum_{l=1}^L x_{l,c} \quad (3)$$

在 Excitation 阶段, 通过包含两个全连接层的瓶颈结构学习各通道间的非线性关系:

$$s = \sigma(W_2 \delta(W_1 z)) \quad (4)$$

在 Scale 阶段, 使用学习到的通道权重与原始输入进行逐通道的乘法操作:

$$\widetilde{x}_{l,c} = s_c \cdot x_{l,c} \quad (5)$$

5.2.2 多头注意力目标机制

多头目标注意力机制通过并行多组注意力头的设计, 显著提升了模型捕捉用户多样化兴趣的能力。首先对目标项目特征和历史行为序列分别进行线性投影:

$$Q = W_Q \cdot target \quad (6)$$

$$K = W_K \cdot sequence \quad (7)$$

$$V = W_V \cdot sequence \quad (8)$$

采用经典的缩放点积注意力机制:

$$Attention = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (9)$$

5.3 建模流程

模型的建模流程主要包括四个步骤：输入与嵌入处理、兴趣提取与注意力池化、特征拼接和全连接网络预测。通过特征嵌入、注意力机制和通道注意力模块，有效地捕捉用户的动态兴趣，提高了点击率预测的准确性。

5.4 实验结果

经过训练的模型取得了显著的性能提升：

模型	AUC 分数
基线 DIN 模型	0.9156
改进 DIN+SENet 模型	0.9334

表 3: CTR 预测模型实验结果

6 task1&2: 端到端级联优化

本研究采用”嵌入-预测”（Embed-then-Predict, EP）框架，构建了一个融合多模态语义编码与用户兴趣建模机制的点击率预测模型。




图 4: 级联流程

6.1 嵌入阶段

6.1.1 图文嵌入模块

本阶段基于 OpenAI 提出的 CLIP 模型，对商品主图和标题文本进行并行编码。对于每个商品的主图 I ，输入 CLIP 图像编码器 f_{img} ，生成图像特征向量：

$$v_{img} = f_{img}(I) \quad (10)$$

对于商品标题文本 T ，输入 CLIP 文本编码器 f_{txt} ，生成文本特征向量：

$$v_{txt} = f_{txt}(T) \quad (11)$$

随后采用线性加权融合策略（权重比为 0.6:0.4），整合两类模态信息形成初始的图文融合向量。

6.1.2 嵌入压缩与归一化

利用主成分分析（PCA）降维，将原始融合向量从 d 维压缩至 $d' = 128$ 维：

$$v_{compressed} = PCA(v_{fusion}) \quad (12)$$

并利用 L2 归一化将降维后的向量投影到单位超球面：

$$v_{final} = \frac{v_{compressed}}{\|v_{compressed}\|_2} \quad (13)$$

6.2 预测阶段

6.2.1 注意力机制

为建模候选广告与用户历史行为之间的相关性，对于历史行为序列中的每个 item embedding 与当前广告，计算注意力权重：

$$\alpha_i = \frac{\exp(v_{ad} \cdot v_i^{hist})}{\sum_{j=1}^T \exp(v_{ad} \cdot v_j^{hist})} \quad (14)$$

6.2.2 兴趣池化

利用注意力权重对行为序列中的所有向量进行加权求和：

$$v_{interest} = \sum_{i=1}^T \alpha_i \cdot v_i^{hist} \quad (15)$$

6.2.3 SENet 通道注意力

经过 SENet 模块进行通道维度的重要性建模，最终输出为：

$$v_{output} = SENet(v_{interest} || v_{ad}) \quad (16)$$

6.2.4 多层感知机预测

最终向量输入至多层感知机结构，输出点击率概率：

$$p_{click} = \sigma(MLP(v_{output})) \quad (17)$$

6.3 实验结果分析

为评估所提出模型的有效性，在 MicroLens 多模态点击率预测数据集上进行了充分的实证实验。训练 AUC 最高达到 0.949558，验证集 AUC 为 0.949750，对应 LogLoss 为 0.449588。为验证图文融合特征的有效性，我们分别评估了以下模型版本：

Base-ID-DIN：传统稀疏 ID 特征 + DIN 行为建模；

ImageOnly-DIEN：仅使用图像 CLIP 嵌入 + DIEN；

TextOnly-DIEN：仅使用文本 CLIP 嵌入 + DIEN；

MultiModal-DIEN（本模型）：图像 + 文本融合嵌入 + DIEN 兴趣建模。

模型名称	AUC↑	LogLoss↓
Base-ID-DIN	0.8893	0.4195
ImageOnly-DIEN	0.9057	0.4021
TextOnly-DIEN	0.8982	0.4078
MultiModal-DIEN	0.9497	0.4496

表 4: 不同模型性能对比




图 5: 性能对比图

实验结果表明，图文融合后的多模态嵌入在 CTR 预测中具有显著优势。相比传统

ID 特征模型，AUC 提高超过 6 个百分点，融合效果也优于任何单一模态，表明图文信息在建模用户兴趣偏好方面具有互补性。

```
2025-07-02 16:32:03.014 P19555 INFO Monitor(max)=0.949558 STOP!
2025-07-02 16:32:03.014 P19555 INFO Reduce learning rate on plateau: 0.000001
100% | 379/379 [02:14:00:00, 6.54it/s]
2025-07-02 16:32:03.132 P19555 INFO ***** Epoch38 end *****
2025-07-02 16:34:15.118 P19555 INFO Train loss: 0.076760 | 378/379 [02:11:00:00, 6.43it/s]
2025-07-02 16:34:15.119 P19555 INFO Evaluation @epoch 38 - batch 379:
100% | 378/379 [00:01:00:00, 2.69it/s]
2025-07-02 16:34:16.246 P19555 INFO [Metrics] AUC: 0.949598 | 378/379 [00:01:00:00, 3.04it/s]
2025-07-02 16:34:16.246 P19555 INFO Monitor(max)=0.949598 STOP!
2025-07-02 16:34:16.246 P19555 INFO Reduce learning rate on plateau: 0.000001
2025-07-02 16:34:16.246 P19555 INFO ***** Epoch39 early stop *****
100% | 378/379 [02:13:00:00, 6.59it/s]
2025-07-02 16:34:16.387 P19555 INFO Training finished.
2025-07-02 16:34:16.388 P19555 INFO Load best model: /root/.autodl-tmp/Task2/checkpoints/MicroLens_IM_x1/DIM_MicroLens_IM_x1_001_962115d8.model
/root/.miniconda3/11b/python3.10/site-packages/tuictr/pytorch/models/rank_model.py:271: FutureWarning: You are using 'torch.load' with 'weights_only=False' (the current default value)
, which uses the default pickle module implicitly. It is possible to construct malicious pickle data which will execute arbitrary code during unpickling (See https://github.com/pytorch/pytorch/blob/main/SOURCE_FILES/security/README.md#untrusted-models for more details). In a future release, the default value for 'weights_only' will be flipped to 'True'. This limits the functions that
could be executed during unpickling. Arbitrary objects will no longer be allowed to be loaded via this mode unless they are explicitly allowedlist by the user via 'torch.serialization.add_safe_globals'. We recommend you start setting 'weights_only=True' for any use case where you don't have full control of the loaded file. Please open an issue on GitHub for any l
issues related to this experimental feature.
state_dict = torch.load(checkpoint, map_location='cpu')
2025-07-02 16:34:16.402 P19555 INFO ***** Validation evaluation *****
100% | 378/379 [00:01:00:00, 2.71it/s]
/root/.miniconda3/11b/python3.10/site-packages/sklearn/metrics/_classification.py:2851: FutureWarning: Setting the eps parameter is deprecated and will be removed in 1.5. Instead eps w
ill always havea default value of 'np.finfo(y_pred.dtype).eps'.
warnings.warn(
2025-07-02 16:34:17.521 P19555 INFO [Metrics] AUC: 0.949750 - logloss: 0.446958
```

图 6: 训练过程

在完成本地训练与验证后，将模型预测结果提交至官方评测平台进行线上评测。经过系统自动评分，模型在 Task 1 & Task 2 上均取得了 AUC = 0.9637 的优异成绩。

38	lzh666	1	2025-07-02 18:26	325149	0.9637	0.0	0.0
----	--------	---	------------------	--------	--------	-----	-----

图 7: 实验结果

7 结论

本研究基于嵌入-预测框架，构建了一个融合多模态语义编码与用户兴趣建模的点击率预测模型。通过 CLIP 模型提取图文特征、设计自适应加权融合机制、引入 SENet 通道注意力和多头注意力机制，有效提升了 CTR 预测的准确性。

实验结果表明，所提出的多模态融合方法相比传统方法在 AUC 指标上有显著提升，验证了多模态信息在推荐系统中的重要作用。该框架为在线推荐系统的实时、多模态信息融合提供了有效的解决方案，具有良好的工业应用前景。

8 参考文献

[1] Radford A., Kim J. W., Hallacy C., et al. Learning transferable visual models from natural language supervision[C]. International conference on machine learning. PMLR, 2021: 8748-8763.

[2] Zhou G., Zhu X., Song C., et al. Deep interest network for click-through rate prediction[C]. Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining, 2018: 1059-1068.

- [3] Hu J., Shen L., Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 7132-7141.
- [4] 西湖大学. MicroLens-1M: A Large Scale Multi-modal Recommendation Dataset[DB/OL]. <https://microlens.github.io/>, 2024.
- [5] Wang X., Chen L., Ban T., et al. Multimodal deep learning for robust RGB-D object recognition[C]. Proceedings of the IEEE/RSJ international conference on intelligent robots and systems, 2015: 681-687.
- [6] McMahan H. B., Holt G., Sculley D., et al. Ad click prediction: a view from the trenches[C]. Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining, 2013: 1222-1230.