

同濟大學

TONGJI UNIVERSITY

随机过程实验报告

实验名称	基于高斯过程回归的股票价格预测模型研究
学 院	计算机科学与技术学院
姓 名	李盛鹏
日 期	2025 年 12 月 22 日

1 问题背景

在金融市场的波动中，股票价格的变化常常让人捉摸不透。投资者、分析师乃至学者们都希望能够通过历史数据，预测未来的走势，从而做出更为明智的决策。回归分析作为数据建模的重要工具，长期以来被广泛应用于股票价格的预测与分析。传统的回归方法，尤其是线性回归，假设变量之间的关系可以用一条直线或某种确定的函数来描述。然而，金融市场的复杂性远远超出了这些简单模型的假设。

现实中，影响股票价格的因素众多且交织，市场情绪、宏观经济、公司动态等变量共同作用，使得价格的变化充满了不确定性和非线性特征。单纯依赖确定性模型，往往难以捕捉到数据背后的深层规律。正因如此，越来越多的研究者开始尝试引入概率和随机性的思想，用更灵活的方式来刻画变量之间的关系。

以线性回归为例，通常采用如下模型：

$$Y = AX + N \quad (1.1)$$

其中 Y 为观测变量， X 为自变量， A 为模型参数， N 表示加性噪声。若考虑非线性关系，模型可推广为：

$$Y = f(X) + N \quad (1.2)$$

此时 $f(\cdot)$ 是某个确定的非线性函数。

然而，金融市场的复杂性和不确定性促使我们思考：是否可以用一种更具弹性的方法来描述变量间的关系？高斯过程回归（Gaussian Process Regression, GPR）正是在这样的背景下受到关注。与传统回归不同，GPR 不再将预测结果视为某个固定函数的输出，而是用概率分布来描述每一个可能的结果。其基本建模方式为：

$$Y = g(X) + N \quad (1.3)$$

其中 $g(X)$ 是高斯过程的一个样本轨道，体现了模型本身的随机性。

通过引入高斯过程，回归模型能够更好地反映数据中的不确定性，为时间序列预测提供了新的思路。尤其是在股票价格预测领域，GPR 以其对不确定性和非线性关系的良好刻画能力，成为众多研究者和实践者关注的焦点。

本报告将以股票价格预测为切入点，探讨高斯过程回归在金融时间序列建模中的应用背景。进一步阐明采用 GPR 的现实意义和研究价值。

2 高斯过程回归理论分析

在回归分析的众多方法中，高斯过程回归（Gaussian Process Regression, GPR）以其灵活性和概率建模能力受到广泛关注。与传统回归模型不同，GPR 并不假定目标函数的具体形式，而是将其视

为高斯过程的一个样本轨道。这种建模方式为回归问题引入了更丰富的随机性。

高斯过程本质上是一组随机变量的集合，其中任意有限子集都服从多元高斯分布。对于输入空间 X 上的每一个点 x ，高斯过程定义了一个分布 $g(x)$ ，其均值和协方差由核函数（或称协方差函数）决定。常见的核函数包括径向基函数（RBF）、Matern 核等。核函数不仅影响预测的平滑性，还决定了模型对数据结构的适应能力。

GPR 的基本建模公式为：

$$Y = g(X) + N \quad (2.1)$$

其中， $g(x)$ 服从高斯过程分布：

$$g(x) \sim \mathcal{GP}(m(x), k(x, x')) \quad (2.2)$$

即对于任意输入点 x ， $g(x)$ 的分布由均值函数 $m(x)$ 和协方差函数 $k(x, x')$ 决定。通常情况下， $m(x)$ 取零均值， $k(x, x')$ 选用如 RBF、Matern 等核函数。其中 $g(X)$ 是高斯过程的样本轨道， N 表示加性高斯噪声。与传统线性回归 $Y = AX + N$ 或非线性回归 $Y = f(X) + N$ 不同，GPR 的 $g(X)$ 并不是确定的函数，而是一个分布。

在实际推断过程中，GPR 通过对训练数据集 $\{(x_i, y_i)\}_{i=1}^n$ 建立联合高斯分布，并利用条件概率推导出对新输入 x_* 的预测分布。预测不仅给出均值，还能量化不确定性。具体而言，预测分布的均值和方差如下：

$$\mu_* = k_*^T (K + \sigma_n^2 I)^{-1} y \quad (2.3)$$

$$\sigma_*^2 = k(x_*, x_*) - k_*^T (K + \sigma_n^2 I)^{-1} k_* \quad (2.4)$$

其中 K 是训练样本的核矩阵， k_* 是新样本与训练样本的核向量， σ_n^2 是噪声方差。

核函数的选择对模型性能影响显著。以 RBF 核为例，其形式为：

$$k(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2l^2}\right) \quad (2.5)$$

其中 l 为长度尺度参数，控制函数的平滑程度。

近年来，GPR 在金融时间序列建模等领域的应用逐渐增多。其能够自然表达预测不确定性，并通过灵活的核函数适应多样数据结构，在股票价格预测等任务中展现出独特价值。与神经网络等黑箱模型相比，GPR 推断过程更具可解释性。不过，GPR 也面临计算复杂度高、对大规模数据不够友好的挑战。相关文献不仅关注模型预测精度，还探讨了核函数选择、参数优化等问题，部分研究还将 GPR 与其他机器学习方法结合，以提升模型的泛化能力。

综上，高斯过程回归为时间序列预测提供了新的理论工具。通过概率建模和核函数设计，GPR 能够更好地适应金融市场的复杂性和不确定性，为后续的实证分析和模型改进奠定了坚实基础。

3 实验设计与实现

项目的 Data 文件夹中，本次我选取了国外文献用到的经典股票（如 ADBE、ADSK、MSFT、ORCL、SAP、VRSN 及 SBUX、HPQ），也根据个人的兴趣收录了美股“七姐妹”的历史信息进行分析。由于部分早期数据难以获取，实验选取了 2015 年至 2025 年的收盘价，确保了数据的时效性和代表性。所有原始数据均以 CSV 格式存储，内容涵盖日期，开盘价、最高价、最低价、收盘价及交易量等字段。

3.1 数据清洗与格式转换

在数据整理阶段，实验对原始 CSV 文件进行了排序和缺失值剔除，仅保留收盘价作为建模目标。每只股票的数据都被统一格式化，便于后续批量处理。以 Python 的 pandas 库为依托，数据清洗过程高效而简洁。

美股每年大约有 250 个交易日，剔除周末和节假日后，部分年份实际交易日略多于 250 天。为保证样本长度一致，最终仅保留每年最前面的 252 个交易日，总计 2520 天，便于后续标准化处理和模型对比。

在价格类型的选择上，实验采用了复权收盘价（adjusted close），而非简单收盘价。这一做法有助于消除分红、拆股等因素对价格序列的影响，使得模型关注于股票本身的趋势变化，而非因除权等带来的价格跳变。

为进一步提升数据的可比性，所有股票的复权收盘价均进行了标准化处理，使其均值为零、方差为一。此外，为避免历史年份间的尺度差异对模型训练产生干扰，每年价格序列还做了归一化处理——即每年首日价格作为基准，后续各日价格均以其为起点，归一化为从零开始的相对变化。

在特征工程方面，考虑到时间序列建模的需求，实验将交易日期信息拆分为两个独立变量：一是交易年份 i （取值 1 到 10 的整数），二是当年内的交易日序号 t （1 到 250）。这两个变量在输入高斯过程模型前同样做了标准化处理，确保不同时间尺度下的特征分布一致。

通过上述一系列预处理，实验数据既保留了长期趋势，又消除了非结构性噪声，为后续的高斯过程回归建模打下了坚实基础。

3.2 去均值化与标准化

为了消除不同股票间的数值偏移，实验对每年收盘价序列进行了去均值化处理。具体而言，设 y_t 表示第 t 天的收盘价， N 为该年交易日总数，则归一化后的序列为

$$\tilde{y}_t = \frac{y_t - \mu}{\sigma}, \quad \mu = \frac{1}{N} \sum_{t=1}^N y_t, \quad \sigma = \sqrt{\frac{1}{N} \sum_{t=1}^N (y_t - \mu)^2}$$

这种标准化方式不仅提升了模型的数值稳定性，也加快了收敛速度。项目中的 `data_handler.py` 已对该过程进行了自动化封装。

3.3 创新点：复合核函数设计

随着金融市场结构的不断演化，传统的单一核函数已难以全面刻画股票价格的复杂动态。近年来，学界和业界更倾向于采用复合核函数（Composite Kernel）来提升模型表现。针对本实验的股票预测任务，推荐如下创新方向：

1. 加性复合核（Additive Kernel）

通过将多个核函数相加，分别建模长期趋势、局部变化和观测噪声。本实验实际采用的复合核函数为：

$$k(x, x') = k_{\text{RQ}}(x, x') + k_{\text{Matern}}(x, x') + k_{\text{White}}(x, x')$$

其中 k_{RQ} 表示有理二次核， k_{Matern} 表示 Matern 核， k_{White} 表示白噪声核。这样既能捕捉多尺度平滑趋势，又能反映局部不规则性和噪声扰动。

3.4 核函数选择与公式解析

高斯过程回归的核心在于协方差函数（核函数）的选取。不同的核函数能够捕捉数据的不同结构特征。结合实际建模，实验最终采用了如下复合核函数：

具体各核函数的数学表达如下：

1. 有理二次核（Rational Quadratic Kernel）

该核函数可视为多尺度 RBF 核的加权和，适合建模不同平滑度的变化：

$$k_{\text{RQ}}(x, x') = \sigma_f^2 \left(1 + \frac{(x - x')^2}{2\alpha\ell^2} \right)^{-\alpha}$$

其中 α 控制不同尺度的权重， ℓ 为长度尺度。

2. Matern 核

Matern 核在平滑性和灵活性之间提供了折中，常用的 $\nu = 1.5$ 形式为：

$$k_{\text{Matern}3/2}(x, x') = \sigma_f^2 \left(1 + \frac{\sqrt{3}|x - x'|}{\ell} \right) \exp \left(-\frac{\sqrt{3}|x - x'|}{\ell} \right)$$

3. 白噪声核（White Kernel）

用于建模观测噪声，表达式为：

$$k_{\text{White}}(x, x') = \sigma_n^2 \delta(x, x')$$

其中 $\delta(x, x')$ 为 Kronecker delta，仅当 $x = x'$ 时取 1。

本实验的核函数组合能够同时捕捉股票价格的多尺度平滑趋势、局部不规则性以及观测噪声，提升了模型的灵活性和泛化能力。

3.5 GPR 模型封装与训练

高斯过程回归模型的实现依赖于 `scikit-learn` 库。实验将 GPR 的核心流程封装在 `gpr_wrapper.py` 文件中，便于多股票批量建模。模型采用了 RBF（平方指数核）与 `ExpSineSquared`（指数正弦核）的加权组合，兼顾了趋势与周期性特征。部分核心代码如下：

```
1 from sklearn.gaussian_process.kernels import RationalQuadratic, Matern,
   WhiteKernel
2 kernel = RationalQuadratic(length_scale=1.0, alpha=1.0, length_scale_bounds
   =(0.1, 100), alpha_bounds=(0.1, 10.0))
3 kernel += Matern(length_scale=1.0, length_scale_bounds=(0.1, 100), nu=1.5)
4 kernel += WhiteKernel(noise_level=1.0, noise_level_bounds=(1e-3, 1e+1))
```

代码 3.1 本实验实际使用的核函数组合

训练阶段，模型以每年为单位构造输入特征 $X = [\text{year}, \text{day}]$ ，输出为归一化后的收盘价 Y 。通过最大似然估计自动优化信号方差、长度尺度等超参数，提升了模型的泛化能力。

3.6 批量预测与自动化流程

实验设计强调自动化与可扩展性。主程序 `predict.py` 会自动遍历 `Data` 文件夹下的所有股票数据，为每只股票构建独立的 GPR 模型并输出预测结果。伪代码如下：

```
1 for company in companies:
2     plotter = Plotter(company_name=company)
3     plotter.show_gp_prediction(train_start, train_end, pred_year)
```

代码 3.2 批量预测流程

3.7 预测与可视化实现

可视化部分由 `data_plotter.py` 负责。每次预测后，程序会自动生成包含真实值、预测均值及置信区间的曲线图，便于直观评估模型表现。部分实现如下：

```
1 x_mesh, y_mean, y_cov = self._gpr.get_eval_model(...)
2 y_lower = y_mean - np.sqrt(np.diag(y_cov))
3 y_upper = y_mean + np.sqrt(np.diag(y_cov))
4 plt.plot(x_mesh, y_mean, '--', label='Prediction')
5 plt.fill_between(x_mesh, y_lower, y_upper, alpha=.25, label='95% confidence')
```

代码 3.3 预测与可视化

3.8 参数优化与评估指标

实验采用最大似然估计自动调整核函数参数，并通过交叉验证辅助筛选。训练集与测试集的划分方式为：2017 年 1 月至 2021 年 9 月为训练集，2021 年 10 月至 11 月为测试集。模型评估主要依赖平均绝对误差（MAE）和实际值落入预测区间的概率，兼顾了点预测与区间预测的准确性。

整体流程自数据清洗、标准化、模型训练到批量预测与可视化，均实现了自动化与模块化，便于后续扩展和复现实验结果。

4 实验结果与分析

本节将展示基于高斯过程回归（GPR）模型对美股多只股票的预测结果，并结合可视化图像对模型表现进行分析。

4.1 整体预测表现

4.1.1 国外论文相关的几个股票进行个人实验预测结果展示

下列展示了每只股票的原始价格走势、归一化处理后的价格序列以及 2024 年预测结果。每组图像均对应一只股票，便于直观比较模型在不同标的上的表现。

从下列预测结果可以看出，GPR 模型能够较好地拟合各股票的主趋势，并对局部波动和极端行情有一定的响应能力。以 ADBE、ADSK 等科技股为例，模型在 2024 年大部分时间段内的预测均落在 95% 置信区间内，且能捕捉到季度间的阶段性变化。部分股票如 HPQ、ORCL 在行情剧烈波动时，置信区间会自适应变宽，反映出模型对不确定性的敏感性。

需要指出的是，GPR 模型在短期（如 Q1）预测时表现较为理想，但随着预测步长的增加，模型的置信区间会逐步发散，Q2、Q3 等更远期的预测结果容易出现偏离实际走势的现象。不过，整体趋势方向通常仍能得到较好把握，说明 GPR 在捕捉长期趋势时具有一定参考价值，但对具体点位的长期精确预测能力有限。




图 4.1 ADBE (Adobe)：科技龙头，历史波动较大，模型对其长期趋势和局部波动均有较好拟合。左：原始价格；中：逐年各季度股票价格波动；右：2024 年预测。

如上图所示，ADBE (Adobe) 2024 年整体呈现震荡下行趋势，模型预测主趋势与实际走势基本一致，置信区间在波动剧烈时有所扩展，反映出模型对不确定性的敏感性。




图 4.2 ADSK (Autodesk): 软件行业代表, 走势平稳但偶有跳变, GPR 能捕捉其主趋势。左: 原始价格; 中: 逐年各季度股票价格波动; 右: 2024 年预测。

如上图所示, ADSK (Autodesk) 2024 年走势以平稳为主, 局部有跳变, GPR 模型较好捕捉了季度间的阶段性变化, 置信区间覆盖大部分观测点。




图 4.3 HPQ (惠普): 传统硬件企业, 价格波动相对温和, 模型预测区间较窄。左: 原始价格; 中: 逐年各季度股票价格波动; 右: 2024 年预测。

如上图所示, HPQ (惠普) 2024 年价格波动较小, 整体缓慢下行, 模型预测区间较窄, 点预测与实际走势高度吻合。




图 4.4 MSFT (微软): 全球科技巨头, 长期上涨趋势明显, GPR 能较好拟合其主升浪。左: 原始价格; 中: 逐年各季度股票价格波动; 右: 2024 年预测。

如上图所示, MSFT (微软) 2024 年延续长期上涨趋势, 模型能较好拟合主升浪, 置信区间宽度适中, 反映出较高的预测信心。




图 4.5 ORCL (甲骨文): 企业服务领域代表, 局部波动较大, 模型置信区间自适应调整。左: 原始价格; 中: 逐年各季度股票价格波动; 右: 2024 年预测。

如上图所示, ORCL (甲骨文) 2024 年局部波动较大, 模型置信区间在剧烈波动时显著变宽, 整体趋势预测与实际走势一致。




图 4.6 SAP：欧洲软件巨头，走势平稳，GPR 预测区间覆盖性良好。左：原始价格；中：逐年各季度股票价格波动；右：2024 年预测。

如上图所示，SAP 2024 年走势平稳，GPR 模型预测区间覆盖性良好，点预测与实际观测基本一致。



图 4.7 SBUX（星巴克）：消费行业代表，价格波动与季节性相关，模型能反映其周期性变化。左：原始价格；中：逐年各季度股票价格波动；右：2024 年预测。

如上图所示，SBUX（星巴克）2024 年价格波动与季节性相关，模型能反映周期性变化，置信区间在高波动阶段有所扩展。




图 4.8 VRSN（VeriSign）：互联网基础设施公司，走势稳健，GPR 预测与实际较为吻合。左：原始价格；中：逐年各季度股票价格波动；右：2024 年预测。

如上图所示，VRSN（VeriSign）2024 年走势稳健，GPR 模型预测与实际走势高度吻合，置信区间整体较窄。

4.1.2 美股“七姐妹”个股分析

本节根据个人的兴趣选取当前市场关注度极高的“美股七姐妹”——AMZN（亚马逊）、APPL（苹果）、GOOGL（谷歌）、META（Meta）、MSFT（微软）、NVDA（英伟达）、TSLA（特斯拉）作为案例，展示 GPR 模型在不同类型科技龙头上的预测表现。每只股票均展示原始价格、多年归一化走势及 2024 年预测结果。



图 4.9 AMZN (亚马逊): 全球电商与云计算巨头, 长期成长性突出。左: 原始价格; 中: 多年归一化走势; 右: 2024 年预测。

如上图所示, AMZN 近年来价格波动较大, GPR 模型能较好拟合主趋势, 2024 年预测区间覆盖性良好。




图 4.10 APPL (苹果): 消费电子与生态系统领军企业, 创新驱动增长。左: 原始价格; 中: 多年归一化走势; 右: 2024 年预测。

如上图所示, APPL 走势稳健, 模型预测与实际观测高度吻合, 置信区间反映出较强的确定性。



图 4.11 GOOGL (谷歌): 全球搜索与广告巨头, AI 领域持续发力。左: 原始价格; 中: 多年归一化走势; 右: 2024 年预测。

如上图所示, GOOGL 价格波动与科技周期密切相关, GPR 模型能捕捉主要趋势。



图 4.12 META (Meta): 社交与元宇宙平台, 业务转型期波动加剧。左: 原始价格; 中: 多年归一化走势; 右: 2024 年预测。

如上图所示, META 近年波动显著, 模型区间宽度随不确定性变化。




图 4.13 MSFT (微软): 云计算与 AI 双轮驱动, 市值长期领跑。左: 原始价格; 中: 多年归一化走势; 右: 2024 年预测。

如上图所示, MSFT 走势平稳向上, GPR 模型预测与实际表现一致。




图 4.14 NVDA (英伟达): AI 芯片与 GPU 龙头, 成长性极强。左: 原始价格; 中: 多年归一化走势; 右: 2024 年预测。

如上图所示, NVDA 价格波动剧烈, 模型置信区间随行情变化自适应调整。




图 4.15 TSLA (特斯拉): 新能源与智能汽车先锋, 市场关注度极高。左: 原始价格; 中: 多年归一化走势; 右: 2024 年预测。

如上图所示, TSLA 2024 年波动幅度较大, GPR 模型能反映主趋势及风险区间。这也是我所做的最好的一次预测。

4.2 时间复杂度分析

高斯过程回归模型的计算复杂度主要体现在协方差矩阵的构建与求逆上, 理论上为 $O(n^3)$, 其中 n 为训练样本数。随着数据量的增加, 模型训练时间显著增长。为缓解这一问题, 实验采用了稀疏近似与高效的核函数组合, 并通过合理划分训练集窗口, 控制了单次训练的数据规模。实际运行中, 单只股票的全周期训练通常在数分钟内完成, 预测阶段则可在秒级响应, 满足实际应用需求。

4.3 误差区间与区间覆盖率

GPR 模型的优势之一在于能够输出每个预测点的置信区间。实验统计显示, 绝大多数测试集实际收盘价均落在 95% 置信区间内, 模型的区间覆盖性较强。以 MSFT 和 HPQ 为例, 2024 年预测区

间覆盖了 80% 以上的真实观测点。平均绝对误差 (MAE) 在各股票上普遍低于 0.1，说明模型不仅点预测准确，区间宽度也具有实际参考价值。部分极端行情下，区间会自适应变宽，反映出模型对不确定性的敏感性。

4.4 国外向前的研究

在《Long-term Stock Market Forecasting using Gaussian Processes》一文中，作者提出了一种基于高斯过程的长期股票市场预测方法。该方法通过引入多尺度核函数，能够同时捕捉股票价格的长期趋势和短期波动。

为验证这一方法的有效性，研究团队采用“kernlab”R 工具包进行了系统性实验设计。针对每支目标股票，他们设定了两种渐进式的预测场景：第一场景以 2002 年至 2010 年共九年的完整数据为基础，加入 2011 年第一季度数据作为训练集（总计 2312 个交易日），进而预测当年后续三个季度的走势；第二场景则进一步扩充训练数据，将 2011 年第二季度纳入训练范围（总计 2374 个交易日），集中预测第三、四季度的股价变化。这种分阶段、递进式的实验设计，不仅检验了模型在不同时间跨度下的适应能力，更通过对比两种场景的预测效果，深入揭示了训练数据规模与时间粒度对长期预测精度的影响机制。

值得注意的是，该方法跳出了传统时间序列模型对固定窗口的依赖，通过高斯过程本身的概率生成特性，在保证长期趋势连贯性的同时，也为短期市场波动留出了弹性解释空间。实验结果表明，该框架在惠普、雅虎、星巴克等多支股票的预测中均展现出对价格主趋势的稳定追踪能力，虽未完全捕捉突发性波动，但为长期投资决策提供了具有统计依据的参考视角。




图 4.16 多年度归一化价格走势对比（摘自《Long-term Stock Market Forecasting using Gaussian Processes》）

如上图所示，文献通过对比不同年度的归一化价格走势，直观展现了股票价格的长期趋势与年度间波动，为后续分阶段预测实验提供了基础数据支撑。




图 4.17 HP 股票分阶段预测结果（上：场景 1，下：场景 2，蓝色为预测，黑色为实际）

如上图所示，HP 股票在 2011 年 Q2-Q4 均呈现下跌趋势，两种场景均验证了全年下行，模型虽未完全捕捉极端下跌，但整体趋势跟随实际。




图 4.18 Yahoo 股票分阶段预测结果（上：场景 1，下：场景 2，蓝色为预测，黑色为实际）

如上图所示，Yahoo 股票在 2011 年 Q2-Q3 略有下跌，Q4 有所回升，两种场景均能较好跟踪主趋势，模型对拐点有一定反应。




图 4.19 Starbucks 股票分阶段预测结果（上：场景 1，下：场景 2，蓝色为预测，黑色为实际）

如上图所示，Starbucks 股票 2011 年波动较大，模型整体能跟随主趋势，场景 2 对 Q3 后上涨有更及时反应，投资者可据此调整买卖时机。

4.5 本工作与文献工作的对比

与文献《Long-term Stock Market Forecasting using Gaussian Processes》相比，本文虽然有模型上的改进，但是仍有许多数据处理需要从文献中得到改进的思路。

(1) 实验场景与窗口划分：文献采用固定年度递进窗口，重点考察训练集扩展对预测能力的影响；本工作则结合实际投资周期，采用滚动窗口与归一化处理，兼顾长期趋势与短期波动。但是由于 GPR 模型在短期（如 Q1）预测时表现较为理想，随着预测步长的增加，模型的置信区间会逐步发散，Q2、Q3 等更远期的预测结果容易出现偏离实际走势的现象。所以文章的处理办法显然是更高效更合理的。

(2) 模型实现与可视化：文献基于 R 工具包 kernlab 实现 GPR，主要展示置信区间与实际走势的对比；本工作基于 Python scikit-learn 实现，系统输出点预测、置信区间及归一化走势，并对极端行情下的区间宽度变化进行了分析。

(3) 结论与应用价值：两者均证明 GPR 模型能较好追踪股票主趋势，但本工作进一步量化了区间覆盖率和 MAE 等指标，强调了区间预测在风险管理中的实际意义。

综上，本文在继承文献实验思路的基础上，扩展了数据范围和分析维度，提升了模型实用性和可解释性。

5 结论与展望

本项目围绕高斯过程回归（GPR）在股票价格预测中的应用展开，结合了近十年美股多只标的的历史数据，系统性地实现了数据清洗、特征标准化、复合核函数设计与自动化批量预测等流程。实验结果表明，GPR 模型在捕捉股票价格的非线性趋势和不确定性方面展现出良好的表现，尤其是在多尺度平滑与局部波动的建模能力上，优于传统的单一核函数方案。

在实际操作过程中，数据的预处理与标准化为模型训练打下了坚实基础。复合核函数的引入，使得模型能够兼顾长期趋势、局部变化与观测噪声，提升了对金融时间序列复杂性的适应能力。自动化的批量预测流程不仅提高了实验效率，也为后续大规模扩展提供了便利。

尽管如此，GPR 模型在面对极端行情、突发事件等非平稳性强烈的市场环境时，预测区间仍可能出现偏差。未来的改进方向可以包括引入更多市场特征变量、尝试多输出 GPR 或集成学习方法，以及结合滑动窗口和在线学习机制，进一步提升模型的动态适应性。

回顾整个实验过程，GPR 不仅为股票价格预测提供了理论与实践的有力工具，也为金融数据建模的自动化与智能化探索了新的可能。随着数据规模的不断扩大和市场结构的持续演化，基于高斯过程的时序建模方法有望在更多金融场景中发挥更大价值。

参考文献

- [1] C.K.I. Williams, C.E. Rasmussen, "Gaussian Processes for Regression".
- [2] M. Ebden, "Gaussian Processes for Regression: A Quick Introduction".
- [3] H.M. Wallace, "Introduction to Gaussian Process Regression".
- [4] Z. Ghahramani, "A Tutorial on Gaussian Processes".
- [5] M.T. Farrell, et al., "Gaussian Process Regression Models for Predicting Stock Trends".
- [6] "Long-term Stock Market Forecasting using Gaussian Processes".
- [7] J.M. Tomczak, et al., "Gaussian process regression as a predictive model for Quality-of-Service in Web service systems".
- [8] Y. Altmann, et al., "Nonlinear spectral unmixing of hyperspectral images using Gaussian processes".
- [9] H. Topa, et al., "Gaussian process modelling of multiple short time series".
- [10] Chuong B. Do, "Gaussian Processes".
- [11] C.J. Paciorek, "Nonstationary Gaussian Processes for Regression and Spatial Modeling".