

基于 **HBase** 的二手车交易数据分析

一、 设计 Hbase 表 car_sales (25)

1. 创建表 car_sales, 包含以下列族:

- info (car_id, brand, owner_name, status)
- sale (city, price, sale_date)

2. RowKey 设计 (关键点):

- 必须支持两种主要查询:
- 按城市查询所有销售记录
- 按销售日期范围查询

二、 将生成的 car_sales.csv 文件的数据批量导入数据库 (20)

1. 编写 Python 脚本 (使用 happybase + hbase 命令行)

或 Java 程序:

- 读取 CSV 文件
- 按照设计的 RowKey 生成 HFile
- 执行 completebulkload 导入 HBase

2. 替代方案 (如果环境不支持 HFile 生成):

- 使用 importtsv 工具配合预分区完成 BulkLoad

3. 性能对比:

- 先用普通 put 插入同样数据, 记录耗时
- 再用 BulkLoad, 记录耗时

提交内容: 脚本代码、执行命令、耗时对比截图

三、 过滤器组合查询 (20)

1. 使用 HBase Shell 或 API, 实现以下查询 (每个查询必须使用 Filter):

- 查询北京地区价格在 20 万以上的二手车
- 查询比亚迪品牌且状态为 pending 的车辆
- 查询车主名字以“张”开头的记录

提交内容: 每个查询的命令和结果截图, 并解释 Filter 的作用

四、 版本控制 (15)

1. 利用 HBase 的特性:

- 版本控制: 对 C1001 车辆, 将价格从 12.5 改为 13.0, 再改为 14.0, 查询该车辆的所有历史价格版本 (3 个)
- 原子操作: 使用 checkAndPut 实现: 只有当车辆状态为 'pending' 时, 才允许将状态改为 'sold'。演示成功和失败两种场景

提交内容: 命令/API 代码、执行结果截图、解释为什么需要原子操作

五、 小规模性能分析与优化 (20)

假设该表未来会扩展到 100 万条数据, 当前单机 HBase 出现以下问题:

- 按 sale_date 范围查询 (扫描 5000 条) 慢

- 写入速度不稳定，有时单个 Region 写入慢

1. 要求分析原因并建议哪些 HBase 配置参数调整：

- 当前 RowKey 设计是否有利于范围扫描？
- 是否存在写热点？

2. 给出优化方案（修改配置或调整设计）：

- 如何调整 RowKey 使日期范围查询更快？
- 是否需要增加 Region 数量？如何操作 split？