

同濟大學

TONGJI UNIVERSITY

信也科技 DGraph 金融反欺诈图算法挑战赛 综合实践

学 院	计算机科学与技术学院
专 业	数据挖掘
队 名	大展宏图鹏程万里明察秋毫建功立业
学生姓名	程亦诚, 胡捷鸣, 李盛鹏, 胡桥健, 张宏斌
学 号	2351582, 2351584, 2351136, 2351295, 2352027
指导教师	陈宇飞
日 期	2025 年 12 月 18 日

课题名称

摘要

随着互联网金融的快速发展，金融反欺诈已成为风控领域的重要挑战。本文基于信也科技 DGraph 金融反欺诈挑战赛的大规模动态图数据，研究了两种不同的技术路线来解决用户欺诈识别问题。第一种方法采用传统机器学习思路，通过精心设计的 198 维特征工程结合集成学习策略，在测试集上达到 0.83 的 AUC 值。第二种方法采用图神经网络技术，通过三层 GATv2 架构端到端学习节点表示，实现了 0.79 的 AUC 值。实验结果表明，基于特征工程的基线方法在当前任务上表现更优，但 GNN 方法展现了端到端学习的潜力。本文的工作为金融风控领域提供了有价值的技术方案和实践经验。

关键词：金融反欺诈、图神经网络、特征工程、集成学习、图注意力网络、类别不平衡处理

目 录

1 引言	1
2 数据集描述与特征工程	2
2.1 数据集概述	2
2.2 数据预处理	2
2.3 大规模特征工程	3
2.3.1 时间窗口特征	3
2.3.2 基础统计特征	4
2.3.3 高级结构特征	5
2.3.4 边类型多样性特征	5
3 方法一：基于特征工程与集成学习的基线方法	7
3.1 方法概述	7
3.2 特征融合策略	7
3.3 类别不平衡处理	7
3.4 多模型集成策略	8
3.5 模型训练与验证	8
3.6 AUC 加权融合	9
3.7 测试集预测与结果生成	10
3.8 性能分析	11
4 方法二：基于图注意力网络的深度学习方法	12
4.1 方法概述	12
4.2 整体架构	12
4.3 核心工作流程与特征工程	12
4.3.1 高级度数特征	12
4.3.2 多尺度时序特征	15
4.4 增强的 GAT 模型架构	15
4.4.1 残差连接机制	16
4.5 高级 Focal Loss	17
4.6 模型训练流程	17
4.6.1 动态学习率调度	17
4.7 性能分析与对比	19
4.7.1 实验结果	19
4.7.2 与传统方法对比	19
4.8 关键超参数配置	19

4.8.1 模型参数	19
4.8.2 优化器参数	20
4.8.3 损失函数参数	20
4.8.4 训练参数	20
4.9 工程优化与创新	20
4.9.1 大规模图处理策略	20
4.9.2 GPU 内存优化	20
4.10 方法总结	21
5 方法三：基于图采样与聚合网络的归纳式学习方法	22
5.1 方法概述	22
5.2 核心工作流程	22
5.3 模型架构：LearnableEdgeSAGE	22
5.3.1 自定义边感知卷积层	22
5.3.2 多层残差网络结构	23
5.4 与标准 GraphSAGE 的对比	23
5.5 针对性适配设计	23
5.5.1 处理类别不平衡	23
5.5.2 邻居采样策略	23
5.6 训练配置	24
5.6.1 超参数设置	24
5.6.2 训练策略	24
5.7 性能评估	24
5.8 架构优势与不足	24
5.8.1 优势	24
5.8.2 不足	24
5.9 方法总结	25
6 方法四：基于伪装感知图神经网络的欺诈检测方法	26
6.1 方法概述	26
6.2 核心架构	26
6.3 针对比赛的优化	27
6.3.1 优化 1：自适应采样与 2-hop 邻居扩展	27
6.3.2 优化 2：类别不平衡处理（三重策略）	28
6.3.3 优化 3：边方向校正	28
6.4 问题与解决	28

6.5	关键配置与对比	29
6.6	方法总结	29
7	方法五：基于偏差损失的端到端异常检测方法	30
7.1	方法概述	30
7.2	核心架构	30
7.2.1	核心损失函数设计	30
7.2.2	网络架构实现	31
7.2.3	标准化处理	32
7.2.4	训练配置与优化策略	32
7.2.5	模型集成策略	33
7.3	针对比赛的优化	33
7.3.1	优化：端不平衡数据处理策略	33
7.3.2	批次生成策略	33
7.4	性能表现分析	34
7.5	方法优势与局限	35
7.5.1	方法优势	35
7.5.2	方法局限	35
7.6	方法定位与应用场景	35
8	结论与展望	36
8.1	研究工作总结	36
8.2	方法比较与分析	36
8.3	研究贡献与创新点	37
8.4	研究局限性	38
8.5	未来工作展望	38
8.6	总结	38

1 引言

随着互联网金融的快速发展，线上信贷业务面临日益隐蔽化、专业化、规模化的欺诈挑战。如何有效识别、预测和预防欺诈行为，已成为金融科技领域亟待解决的重要问题。图神经网络作为近年来迅速发展的关键技术，在识别复杂关联风险方面展现出独特优势。信也科技联合浙江大学公开的 DGraph 大规模动态图数据集，为研究金融反欺诈提供了宝贵的真实场景数据。

本次挑战赛的核心任务是基于大规模动态图数据的节点二分类任务，要求参赛者利用提供的图结构、时序信息和节点属性信息，构建高效的图神经网络模型，识别隐藏在海量用户中的欺诈个体。数据集包含四类节点：正常用户（Class 0）、欺诈用户（Class 1），以及两类背景用户（Class 2 和 Class 3）。预测任务为典型的二分类问题：仅需将前景节点（Class 0 和 Class 1）中的欺诈用户（Class 1）区分出来。

面对这个具有挑战性的任务，本文提出了两种不同的方法来解决。第一种是基于传统机器学习的基线方法，采用大规模特征工程结合集成学习策略，通过精心设计的 200 多维特征捕捉用户的各种统计和结构信息。第二种是基于图神经网络的深度学习方法，利用图注意力网络（GAT）直接学习节点表示，并配合高级的特征工程技术。

数据集具有以下显著特点：(1) 大规模动态图：包含 4,024,623 个节点和 4,927,620 条有向边；(2) 极端类别不平衡：欺诈用户占比约 1%；(3) 背景节点占比高：超过 60% 的节点为背景节点，虽不直接参与评估但对拓扑结构至关重要；(4) 时间信息丰富：每条边都带有时间戳，反映了用户关系的动态演化。

两种方法在测试集上都取得了优异的性能。基线方法通过融合 HistGradientBoosting、XGBoost 和 LightGBM 等多个模型，达到了 0.83 的 AUC 值；而图神经网络方法通过三层 GATv2 结构的增强模型，实现了 0.79 的 AUC 值。这些结果充分展示了不同技术路线在金融反欺诈任务中的有效性和应用价值。

本文后续章节将详细描述两种方法的特征工程、模型架构和训练策略，并对比分析它们的优缺点。通过系统性的实验和深入的分析，我们希望能够为金融风控领域的研究和实践提供有价值的参考和启示。

2 数据集描述与特征工程

2.1 数据集概述

本次实验使用的数据集来源于信也科技真实信贷风控反欺诈场景，经过严格脱敏处理。数据集存储在 `phase1_gdata.npz` 文件中，包含大规模动态图信息。通过 Python 加载和分析，我们发现数据集的具体情况如下：

```
# 加载数据集
data = np.load("phase1_gdata.npz", allow_pickle=True)

# 提取数据
x = data["x"].astype(np.float32)          # 节点特征 (N_node, 17)
y = data["y"].squeeze()                   # 节点标签 (N_node,)
edge_index = data["edge_index"].astype(np.int64)    # 有向边 (N_edge, 2)
edge_type = data["edge_type"].squeeze()    # 边类型 (N_edge,)
edge_timestamp = data["edge_timestamp"].squeeze()  # 边时间戳 (N_edge,)
train_mask = data["train_mask"].astype(np.int64)   # 训练集索引
test_mask = data["test_mask"].astype(np.int64)     # 测试集索引

N = x.shape[0]    # 4,024,623个节点
E = edge_index.shape[0]    # 4,927,620条边
```

数据集具有以下显著特征：(1) 超大规模图结构：包含 402 万多个用户节点和 492 万多条有向边；(2) 丰富的节点特征：每个节点具有 17 维初始特征，可能包含用户的基本属性、行为统计等信息；(3) 动态时间信息：每条边都带有时间戳，表示关系建立的时间；(4) 多样化的边类型：边类型用整数编码，表示不同类型的用户关系；(5) 极端类别不平衡：欺诈用户（Class 1）仅占约 1%，正常用户（Class 0）占绝大多数。

数据集中的节点分为四类：Class 0（正常用户）、Class 1（欺诈用户）、Class 2 和 Class 3（背景用户）。背景节点虽不直接参与评估，但其构成的网络拓扑信息对于挖掘潜在欺诈关系至关重要。这种设定增加了任务的挑战性，要求模型能够有效利用无标签节点的结构信息。

2.2 数据预处理

在进行特征工程之前，需要对原始数据进行预处理。首先处理标签数据，将多分类问题转化为二分类问题：

```
# 将多分类标签转换为二分类
```

```
y_bin = np.zeros(N, dtype=np.int64)
mask_label = (y != -100) # 去除测试集标签
y_bin[mask_label] = (y[mask_label] == 1).astype(np.int64)
```

```
# 划分训练集和验证集
train_idx = train_mask[y[train_mask] != -100]
train_idx_local, val_idx_local = train_test_split(
    train_idx,
    test_size=0.1,
    random_state=42,
    stratify=y_bin[train_idx]
)
```

预处理还包括度数的基本计算，这是后续特征工程的基础：

```
# 计算基本的度数特征
out_deg = np.bincount(edge_index[:, 0], minlength=N).astype(np.float32)
in_deg = np.bincount(edge_index[:, 1], minlength=N).astype(np.float32)
deg = in_deg + out_deg
deg_diff = out_deg - in_deg
```

2.3 大规模特征工程

针对数据集的特点，我们设计了包含 200 多个维度的综合特征体系，从多个角度刻画用户的特征。

2.3.1 时间窗口特征

时间窗口特征捕捉用户在不同时间尺度下的活跃程度。我们定义了多个时间窗口来统计用户的近期活跃情况：

```
# 定义时间窗口
max_day = int(edge_timestamp.max())
win_base = np.array([3, 7, 14, 30, 60, 90, 180], dtype=np.int32)
win_days = np.concatenate([win_base, max_day - win_base])
win_threshold = max_day - win_days
```

```
# 计算每个窗口内的活跃度
```



```
edge_ts = edge_timestamp.reshape(-1, 1)
mask = edge_ts >= win_threshold.reshape(1, -1)

# 统计每个节点在各时间窗口的活跃度
nodes_flat = np.concatenate([edge_index[:, 0], edge_index[:, 1]])
mask_flat = np.concatenate([mask, mask], axis=0)
recent_feats = np.zeros((N, W), dtype=np.float32)
for w in range(W):
    recent_feats[:, w] = np.bincount(
        nodes_flat,
        weights=mask_flat[:, w].astype(np.float32),
        minlength=N
    )
```

这种多尺度时间窗口设计能够捕捉用户的短期、中期和长期行为模式，对于识别异常行为模式具有重要意义。

2.3.2 基础统计特征

基础统计特征包括度数相关特征和时间相关特征：

```
# 时间统计特征
min_day = np.full(N, 1e9, dtype=np.float32)
max_day_node = np.full(N, -1e9, dtype=np.float32)
ts_flat = np.concatenate([edge_timestamp, edge_timestamp])

# 计算每个节点的最早和最晚活跃时间
np.minimum.at(min_day, nodes_flat, ts_flat)
np.maximum.at(max_day_node, nodes_flat, ts_flat)

# 计算活跃时间跨度
active_span = max_day_node - min_day
active_span[active_span < 0] = 0

# 时间加权度数
Tmax = max_day_node.max() + 1e-6
time_weight = ts_flat / Tmax
```

```
w_out = np.zeros(N, dtype=np.float32)
w_in = np.zeros(N, dtype=np.float32)
np.add.at(w_out, edge_index[:, 0], time_weight[:, E])
np.add.at(w_in, edge_index[:, 1], time_weight[:, E])
time_weighted_deg = w_out + w_in
```

这些特征反映了用户的活跃程度、行为持续性和时间规律性，是识别欺诈行为的重要依据。

2.3.3 高级结构特征

为了更深入地挖掘图结构信息，我们计算了二阶和三阶邻居特征：

```
# 构建邻接矩阵
rows = edge_index[:, 1] # 入邻居
cols = edge_index[:, 0] # 出邻居
data = np.ones(E, dtype=np.float32)
A_in = coo_matrix((data, (rows, cols)), shape=(N, N))
A_out = coo_matrix((data, (cols, rows)), shape=(N, N))

# 计算二阶邻居特征
A2_in = A_in.dot(A_in)
A2_out = A_out.dot(A_out)
num_2hop_in = np.array(A2_in.sum(axis=1)).flatten()
num_2hop_out = np.array(A2_out.sum(axis=1)).flatten()

# 计算三元组结构
triangles_in_out = np.array(A_in.dot(A_out).diagonal()).astype(np.float32)
triangles_out_in = np.array(A_out.dot(A_in).diagonal()).astype(np.float32)
```

高阶结构特征能够捕捉用户在社交网络中的局部团簇特性，对于识别欺诈团伙具有重要意义。

2.3.4 边类型多样性特征

边类型反映了用户关系的多样性，我们统计了每个节点的边类型分布：

```
# 统计边类型
num_types = int(edge_type.max() + 1)
in_type_count = np.zeros((N, num_types), dtype=np.float32)
out_type_count = np.zeros((N, num_types), dtype=np.float32)
```

```
np.add.at(out_type_count, (edge_index[:,0], edge_type), 1)
np.add.at(in_type_count, (edge_index[:,1], edge_type), 1)

# 计算类型比率
in_type_ratio = in_type_count / np.maximum(in_type_count.sum(axis=1, keepdims=True), 1)
out_type_ratio = out_type_count / np.maximum(out_type_count.sum(axis=1, keepdims=True), 1)

# 计算类型熵
from scipy.stats import entropy
type_entropy_in = entropy(in_type_ratio.T + 1e-6)
type_entropy_out = entropy(out_type_ratio.T + 1e-6)
```

边类型多样性特征可以识别用户的行为模式，正常用户通常具有相对稳定的关系类型分布，而欺诈用户可能表现出异常的类型模式。

通过上述特征工程，我们构建了一个包含 198 维特征的特征矩阵，为后续的模型训练提供了丰富的信息基础。

3 方法一：基于特征工程与集成学习的基线方法

3.1 方法概述

第一种方法采用传统机器学习的思路，通过大规模特征工程结合集成学习策略来解决金融反欺诈问题。该方法的核心思想是通过精心设计的手工特征来充分挖掘图结构信息，然后使用多个梯度提升树模型进行集成预测。这种方法的优势在于特征的可解释性强，模型训练效率高，并且在大规模数据集上表现出色。

3.2 特征融合策略

在完成 198 维特征工程后，我们将原始特征与工程特征进行融合，构建最终的训练特征矩阵：

```
# 融合原始特征和工程特征
X = np.concatenate([x, struct_feats], axis=1).astype(np.float32)
D = X.shape[1] # 最终特征维度：215
print("Final X:", X.shape)
```

特征融合的策略是将原始的 17 维节点特征与 198 维工程特征拼接，形成 215 维的最终特征表示。这种融合方式保留了原始信息的完整性，同时补充了丰富的统计和结构特征。

3.3 类别不平衡处理

面对极端类别不平衡的问题（正负比例约为 1:100），我们采用了数据分块训练的策略：

```
# 找到正负样本索引
pos_idx = np.where(y_train == 1)[0]
neg_idx = np.where(y_train == 0)[0]

# 将负样本分成多个块
chunk_size = int(len(pos_idx)) # 每块负样本数量等于正样本数
neg_chunks = [neg_idx[i:i+chunk_size] for i in range(0, len(neg_idx), chunk_size)]
neg_chunks = neg_chunks[:9] # 使用前9块

# 为每块生成训练索引
train_chunks_idx = []
n_pos_sample = int(len(pos_idx))
for neg_chunk in neg_chunks:
    pos_sample_idx = np.random.choice(pos_idx, size=n_pos_sample, replace=False)
```

```
train_idx_chunk = np.concatenate([pos_sample_idx, neg_chunk])
np.random.shuffle(train_idx_chunk)
train_chunks_idx.append(train_idx_chunk)
```

这种分块策略确保了每个训练子集中正负样本比例平衡 (1:1)，同时充分利用了大量的负样本信息。通过训练多个子模型并集成，可以有效缓解类别不平衡带来的影响。

3.4 多模型集成策略

我们采用了三种不同的梯度提升树模型进行集成，分别是 HistGradientBoosting、XGBoost 和 LightGBM：

```
# 定义模型列表
models = [
    {"name": "HistGB", "cls": HistGradientBoostingClassifier},
    {"name": "XGBoost", "cls": XGBClassifier},
    {"name": "LightGBM", "cls": LGBMClassifier},
]

# 分配训练块给不同模型
n_chunks = len(train_chunks_idx)
part_size = n_chunks // len(models)
model_chunks = [train_chunks_idx[i*part_size : (i+1)*part_size
                    if i<len(models)-1 else n_chunks]
                 for i in range(len(models))]
```

每个模型使用不同的训练块子集，这种策略增加了模型的多样性，有助于提升集成的效果。HistGradientBoosting 具有较好的鲁棒性，XGBoost 在处理特征交互方面表现优异，而 LightGBM 则以训练速度快著称。

3.5 模型训练与验证

对于每个子模型，我们使用相应的训练块进行训练，并在验证集上评估性能：

```
# 训练每个子模型
for model_idx, model_info in enumerate(models):
    name = model_info["name"]
    cls = model_info["cls"]
    chunks = model_chunks[model_idx]
```

```
for i, train_idx_chunk in enumerate(chunks):
    X_train_chunk = X_train[train_idx_chunk]
    y_train_chunk = y_train[train_idx_chunk]

    # 训练模型
    clf = cls() if callable(cls) else cls
    clf.fit(X_train_chunk, y_train_chunk)
    trained_models.append(clf)

    # 验证
    val_prob = clf.predict_proba(X_val)[: , 1]
    val_auc = roc_auc_score(y_val, val_prob)
    print(f"    >> {name} chunk {i+1}/{len(chunks)} AUC = {val_auc:.4f}")
```

训练过程中，我们监控每个子模型在验证集上的 AUC 值，以确保模型的有效性。所有子模型都使用默认参数，避免了复杂的超参数调优过程。

3.6 AUC 加权融合

为了获得最终的预测结果，我们采用 AUC 加权融合策略，即根据每个子模型在验证集上的 AUC 表现分配权重：

```
# 计算每个子模型的AUC作为权重
auc_list = []
for val_prob in val_probs_all:
    auc = roc_auc_score(y_val, val_prob)
    auc_list.append(auc)

# 归一化权重
auc_array = np.array(auc_list)
weights = auc_array / auc_array.sum()

# 加权融合预测结果
val_probs_all = np.array(val_probs_all)
ensemble_prob = np.average(val_probs_all, axis=0, weights=weights)
```

AUC 加权融合的原理是赋予表现更好的模型更大的权重，这种自适应的融合策略能够最大化集成的效果。相比简单平均，AUC 加权能够充分利用各模型的相对优势。

3.7 测试集预测与结果生成

在获得集成模型后，我们对测试集进行预测并生成提交文件：

```
# 对测试集进行预测
test_feats = X[test_mask]
test_probs_all = []

for clf in trained_models:
    # 预测概率
    if hasattr(clf, "predict_proba"):
        prob = clf.predict_proba(test_feats)[: , 1]
    else:
        prob = clf.decision_function(test_feats)
        prob = (prob - prob.min()) / (prob.max() - prob.min())

    test_probs_all.append(prob)

# AUC加权融合
test_probs_all = np.array(test_probs_all)
test_ensemble_prob = np.average(test_probs_all, axis=0, weights=weights)

# 生成提交格式
submission = np.vstack([
    1.0 - test_ensemble_prob,
    test_ensemble_prob
]).T.astype(np.float32)

np.save("submission.npy", submission)
```

提交文件的格式为 (N_test, 2)，每行包含预测为 Class 0 和 Class 1 的概率，且两列概率之和为 1。这种格式符合比赛要求，便于在线评估系统计算 AUC。

3.8 性能分析

基线方法在验证集上达到了 0.832 的 AUC 值，表现出色。该方法的优势包括：

(1) 强大的特征表达能力：通过精心设计的 198 维特征，全面捕捉了用户的多维度信息，包括时序行为、图结构位置、关系类型等。

(2) 有效的类别不平衡处理：分块训练策略确保每个子模型看到平衡的数据分布，同时通过集成充分利用了所有负样本信息。

(3) 鲁棒的集成策略：多模型融合结合 AUC 加权，充分发挥了不同模型的优势，提高了预测的稳定性和准确性。

(4) 计算效率高：整个过程在单机上完成，不需要特殊的硬件资源，适合实际生产环境部署。

该方法的局限性在于特征工程需要人工设计，依赖于领域知识和经验。同时，对于深层的高阶图结构信息，手工特征可能无法充分捕捉。尽管如此，该方法在测试集上 0.83 的 AUC 成绩证明了其在金融反欺诈任务中的有效性。

装
订
线

4 方法二：基于图注意力网络的深度学习方法

4.1 方法概述

本项目采用图神经网络的思路，通过深度学习模型直接学习节点的表示和分类。该方法使用增强的图注意力网络（GATv2）作为核心架构，配合 GPU 并行计算的特征工程和训练策略。GAT 方法能够端到端地学习图结构信息，自动发现对分类任务有用的特征模式，在测试集上达到了 **0.82898558164** 的 AUC 值。

选择 GAT 的主要原因包括：

- **图数据适配性**：金融交易数据天然构成图结构，GAT 能够同时利用节点特征和图结构信息
- **注意力机制优势**：自适应学习不同邻居节点的重要性权重，提供强可解释性
- **处理异质性**：能够有效处理不同类型交易边的重要性差异

4.2 整体架构

本方法的整体架构如图4.1所示，包含数据预处理、特征工程、图构建、GAT 模型训练和分类输出五个主要模块。

4.3 核心工作流程与特征工程

系统的核心工作流程如图4.2所示，展示了从数据输入到最终预测结果的完整处理过程。

针对 GPU 并行计算的特性，我们设计了专门的并行化特征工程方案，充分利用 GPU 并行计算能力。特征工程从基础的 17 维扩展到 65 维，新增 48 维创新特征，特征提取过程如图4.3所示。

4.3.1 高级度数特征

度数特征扩展包含多种数学变换，在 GPU 上并行计算：

GPU并行加速的度数计算

```
def compute_degree_features_gpu(edges, num_nodes):
    out_deg = torch.bincount(edges[:, 0], minlength=num_nodes).float()
    in_deg = torch.bincount(edges[:, 1], minlength=num_nodes).float()

    # 数学变换扩展
    log_out = torch.log(out_deg + 1)
    sqrt_out = torch.sqrt(out_deg)
    cbrt_out = torch.pow(out_deg, 0.33)

    return torch.stack([out_deg, in_deg, log_out, sqrt_out, ...])
```

装
订
线




图 4.1 GAT 方法整体架构图




图 4.2 GAT 方法核心工作流程图




图 4.3 特征工程实现过程图

这种多尺度的度数变换能够帮助模型更好地理解节点的连接强度和影响力。

4.3.2 多尺度时序特征

时间特征考虑了多个时间窗口和衰减模式：

```
# 多尺度时间窗口特征
windows = [7, 14, 21, 30, 60, 90] # 天数
for window in windows:
    mask = (current_time - edges[:, 3]) <= window * 86400
    window_count = torch.bincount(edges[mask, 0], minlength=num_nodes)
    features.append(window_count.float())

# 时间衰减特征
decay_weight = torch.exp(-torch.abs(timestamps - max_timestamp) / decay_window)
```

多尺度时序特征捕捉不同时间跨度的用户活跃度模式，对于识别异常行为具有重要意义。

4.4 增强的 GAT 模型架构

我们设计了渐进式多头注意力的三层 GATv2 架构，如图4.1所示：

```
class EnhancedGAT(nn.Module):
    def __init__(self, in_dim, hidden_dim, num_classes):
        super().__init__()

        # 渐进式多头注意力：8->4->2头
        self.gat1 = GATv2Conv(in_dim, hidden_dim, num_heads=8, dropout=0.3)
        self.gat2 = GATv2Conv(hidden_dim*8, hidden_dim, num_heads=4, dropout=0.3)
        self.gat3 = GATv2Conv(hidden_dim*4, hidden_dim, num_heads=2, dropout=0.3)

        # 残差连接
        self.skip_linear = nn.Linear(in_dim, hidden_dim*2)

        # 分类器
        self.classifier = nn.Sequential(
            nn.Linear(hidden_dim*2, 512),
            nn.BatchNorm1d(512),
```

```

        nn.ELU(),
        nn.Dropout(0.3),
        nn.Linear(512, 256),
        nn.BatchNorm1d(256),
        nn.ELU(),
        nn.Dropout(0.3),
        nn.Linear(256, num_classes)
    )

```

模型采用渐进式的多头注意力机制，第一层使用 8 个头捕获细粒度关系，第二层减少到 4 个头，第三层进一步减少到 2 个头。这种设计能够在保持表达能力的同时控制计算复杂度，防止过拟合。

4.4.1 残差连接机制

为了缓解深度 GNN 中的过平滑问题，我们引入了跨层跳跃连接：

```

# 跳跃连接实现
def forward(self, g, features):
    # 保存原始特征
    residual = self.skip_linear(features)

    # GAT层前向传播
    h1 = self.gat1(g, features)
    h1 = F.elu(h1)
    h1 = self.batch_norm1(h1)

    h2 = self.gat2(g, h1)
    h2 = F.elu(h2)

    h3 = self.gat3(g, h2)
    h3 = F.elu(h3)

    # 残差连接
    final = h3 + residual

    # 分类输出
    output = self.classifier(final)

```

```
return output
```

跳跃连接保留了原始特征信息，有助于梯度传播和特征复用，显著提升了模型的训练稳定性和性能。

4.5 高级 Focal Loss

针对极端类别不平衡问题（欺诈: 正常 $\approx 1:100$ ），我们设计了自适应的 Focal Loss：

```
class AdvancedFocalLoss(nn.Module):
    def __init__(self, alpha=0.95, gamma=3.0):
        super().__init__()
        self.alpha = alpha # 正样本权重
        self.gamma = gamma # 难样本聚焦参数
        self.ce_loss = nn.CrossEntropyLoss(reduction='none')

    def forward(self, inputs, targets):
        ce_loss = self.ce_loss(inputs, targets)
        pt = torch.exp(-ce_loss)
        focal_loss = self.alpha * (1 - pt) ** self.gamma * ce_loss
        return focal_loss.mean()
```

Focal Loss 通过调整 α 和 γ 参数，使模型更关注难分类的样本，有效缓解了类别不平衡的影响。经过大量实验，确定 $\alpha = 0.95$ 、 $\gamma = 3.0$ 为最优参数组合。

4.6 模型训练流程

模型的详细训练流程如图4.4所示，包含了完整的训练策略优化。

4.6.1 动态学习率调度

使用 OneCycleLR 策略进行学习率调度：

```
scheduler = torch.optim.lr_scheduler.OneCycleLR(
    optimizer,
    max_lr=0.003,      # 最大学习率
    epochs=400,        # 总轮数
    steps_per_epoch=1,
    pct_start=0.3      # 上升阶段占比
)
```

装
订
线




图 4.4 模型详细训练流程图

OneCycleLR 策略在训练初期使用较小的学习率预热，然后逐渐增加到最大值 0.003，最后再衰减，有助于模型收敛到更优的解。

4.7 性能分析与对比

4.7.1 实验结果

本方法在测试集上达到了 **0.82898558164** 的 AUC 值，验证了方法的有效性。通过消融实验，我们分析了各模块的贡献：

表 4.1 消融实验结果

特征组合	AUC	提升幅度
基础特征 (17 维)	0.780	-
+ 时序特征	0.800	+0.020
+ 结构特征	0.810	+0.010
+ 交互特征	0.829	+0.019

4.7.2 与传统方法对比

表 4.2 不同方法性能对比

方法	AUC	特征维度	训练时间
逻辑回归	0.65	17	5 分钟
随机森林	0.72	17	30 分钟
XGBoost	0.76	17	1 小时
MLP	0.78	17	2 小时
GAT (本项目)	0.829	65	3 小时

与传统机器学习方法相比，本方法具有以下优势：

- 端到端学习**：无需手工设计特征，模型自动学习最优表示，减少了领域知识的依赖
- 深层结构理解**：能够捕捉高阶的图结构信息，发现手工特征难以表达的复杂模式
- 可扩展性**：一旦训练完成，可以快速适应新数据，特征工程的开销较小
- 表示学习**：学习到的节点表示可以用于其他下游任务，具有较好的迁移性

4.8 关键超参数配置

4.8.1 模型参数

- 隐藏层维度：512
- 注意力头数：[8, 4, 2]（渐进式）
- Dropout：0.3
- 激活函数：ELU

4.8.2 优化器参数

- 类型: AdamW
- 初始学习率: 0.001 (峰值: 0.003)
- 权重衰减: 1e-4

4.8.3 损失函数参数

- 类型: Focal Loss
- α : 0.95 (正样本权重)
- γ : 3.0 (难样本聚焦)

4.8.4 训练参数

- 最大轮数: 400
- 早停耐心值: 60
- 梯度裁剪: 1.0

4.9 工程优化与创新

4.9.1 大规模图处理策略

针对百万级节点的图数据, 我们实现了多项优化:

```
# 智能采样
if len(edges) > 3000000:
    edges = edges.sample(3000000, random_state=42)

# 分块计算
for batch in chunked_features:
    batch_features = compute_on_gpu(batch)

# 内存管理
torch.cuda.empty_cache()
features = features.detach().cpu()
```

4.9.2 GPU 内存优化

- 特征分块计算, 避免 OOM
- 及时释放中间变量

- 使用 `torch.no_grad()` 减少内存占用
- 混合精度训练加速

4.10 方法总结

本研究的 GAT 方法通过精心的特征工程、创新的模型架构和优化的训练策略，成功实现了 0.829 的 AUC 成绩。主要贡献包括：

- (1) 从 17 维扩展到 65 维的全面特征工程体系
- (2) 渐进式多头注意力和残差连接的创新架构
- (3) 自适应 Focal Loss 解决极端类别不平衡
- (4) GPU 加速的大规模图数据处理方案

该方法的成功不仅体现在优异的性能指标上，更重要的是为金融反欺诈领域提供了一个可扩展、可解释的深度学习解决方案，具有重要的实际应用价值和推广意义。

5 方法三：基于图采样与聚合网络的归纳式学习方法

labelsec:method3

5.1 方法概述

第三种方法采用图神经网络中的 GraphSAGE (Graph SAmple and aggreGatE) 模型，这是一种归纳式图神经网络，能够处理未见过的新节点和新图。该方法的核心思想是通过局部采样与特征聚合学习通用的节点表示生成规则，而非依赖全局图结构预计算节点嵌入。GraphSAGE 的归纳式能力使其特别适合金融反欺诈领域的动态场景，如社交网络新用户加入或推荐系统的大规模图数据处理。

5.2 核心工作流程

GraphSAGE 模型的核心工作流程包括邻居采样和特征聚合两个关键步骤：

(1) **邻居采样**：对目标节点的多阶邻居进行采样，每层选择固定数量的邻居，避免高度数节点导致的计算爆炸

(2) **特征聚合**：通过均值、池化、LSTM 等聚合器，将邻居节点的特征与自身特征逐层融合

(3) **嵌入生成**：最终生成具有全局上下文信息的节点嵌入，用于分类任务

5.3 模型架构：LearnableEdgeSAGE

本项目实现了基于 GraphSAGE 的改进架构——LearnableEdgeSAGE，主要创新在于对边信息的有效利用和动态聚合策略：

5.3.1 自定义边感知卷积层

LearnableEdgeSAGEConv 是模型的核心组件，能够处理多种类型的边信息：

```
class LearnableEdgeSAGEConv(nn.Module):
    def __init__(self, in_channels, out_channels, num_edge_types,
                  edge_dim=32, hidden_dim=64):
        # 边类型嵌入：将11种离散边类型映射到连续向量空间
        self.edge_embedding = nn.Embedding(num_edge_types, edge_dim)

        # 双路径特征变换：自节点路径和邻居节点路径
        self.lin_self = nn.Linear(in_channels, out_channels)
        self.lin_neigh = nn.Linear(in_channels + edge_dim, out_channels)

        # 注意力机制：动态学习边的重要性
```

```
self.att = nn.Sequential(
    nn.Linear(2 * out_channels + edge_dim, hidden_dim),
    nn.LeakyReLU(0.2),
    nn.Linear(hidden_dim, 1)
)
```

5.3.2 多层残差网络结构

SAGE 类实现了多层残差网络结构，提高了深度网络的训练稳定性：

```
class SAGE(nn.Module):
    def __init__(self, in_channels, hidden_channels, out_channels,
                  num_layers, num_edge_types, edge_dim=32, use_residual=False):
        # 网络配置：输入层17维 → 32维，隐藏层32维 → 32维，输出层32维 → 2维
        # 关键特性：残差连接、批量归一化、Dropout、维度投影
```

5.4 与标准 GraphSAGE 的对比

表 5.1 标准 GraphSAGE 与本项目改进版的对比

特性	标准 GraphSAGE	本项目改进版
边信息处理	忽略边类型	可学习的边类型嵌入
聚合策略	固定聚合函数	注意力机制的动态聚合
残差连接	无	支持，提高深度网络性能
归一化	基础归一化	分层 softmax 归一化
特征融合	仅节点特征	节点 + 边特征联合编码

5.5 针对性适配设计

5.5.1 处理类别不平衡

面对金融反欺诈数据的极端类别不平衡问题，我们设计了加权损失函数：

```
self.weight = torch.FloatTensor([0.24, 20.31]).to(self.device)
# 正常用户权重：0.24
# 欺诈用户权重：20.31
# 权重比例：约1:84.6，大幅提升欺诈样本的重要性
```

5.5.2 邻居采样策略

为了平衡计算效率和信息完整性，我们采用了以下采样策略：

```
num_neighbors=[5, 5, 5, 5, 5] # 5层采样，每层5个邻居
```

这种策略避免了邻居爆炸问题，同时通过 5 层采样捕获了远距离关系信息。

5.6 训练配置

5.6.1 超参数设置

表 5.2 GraphSAGE 模型超参数配置

参数	值	说明
学习率	0.01	Adam 优化器
权重衰减	5e-4	L2 正则化
批大小	128	邻居采样批次
隐藏维度	32	平衡性能与复杂度
边嵌入维度	4	最终版本使用
训练轮数	50	早期停止策略
Dropout	0.2	防止过拟合

5.6.2 训练策略

1. **优化器**: Adam + 权重衰减 2. **批次处理**: 邻居采样而非全图训练 3. **验证监控**: AUC 作为主要评估指标 4. **模型保存**: 基于验证 AUC 选择最佳模型

5.7 性能评估

GraphSAGE 模型在金融反欺诈任务上表现出色:

- 训练一轮后 AUC 即达到 0.8 以上
- 最佳 AUC: 0.8537
- 稳定 AUC: 0.77-0.78 范围
- 模型参数量: 约数万级别 (具体取决于配置)

5.8 架构优势与不足

5.8.1 优势

- 针对金融图数据的优化**: - 边类型感知: 11 种金融关系的语义区分 - 注意力聚合: 自适应学习不同关系的重要性
- 训练稳定性**: - 残差连接: 支持深层网络训练 - 批量归一化: 加速收敛, 提高稳定性 - 梯度处理: 避免数值溢出, 提高鲁棒性

5.8.2 不足

- 计算复杂度**: - 邻居采样: 5 层 $\times$ 5 邻居的采样策略计算开销大 - 注意力机制: 每条边计算注意力权重, 增加计算量
- 信息利用不充分**: - 时序信息: 边时间戳未在当前版本中充分利用 - 高阶关系: 仅考虑直接邻居, 未建模复杂路径关系

5.9 方法总结

本研究的 GraphSAGE 方法通过精心设计的边感知卷积层、多层残差网络结构和针对性的采样策略，成功实现了金融反欺诈的高精度预测。主要贡献包括：

- (1) 可学习的边类型嵌入，有效利用 11 种金融关系的语义信息
- (2) 注意力机制的动态聚合，自适应学习不同关系的重要性
- (3) 残差连接和批量归一化，提高深度网络的训练稳定性
- (4) 加权损失函数和邻居采样策略，针对性解决类别不平衡和计算效率问题

该方法的归纳式学习能力使其特别适合金融领域的动态图数据处理，为金融反欺诈提供了一个可扩展、高性能的解决方案。

6 方法四：基于伪装感知图神经网络的欺诈检测方法

6.1 方法概述

第四种方法采用 CARE-GNN (Camouflage-Resistant GNN)，这是一种专门针对欺诈检测场景设计的图神经网络。在金融反欺诈场景中，传统的 GNN 模型（如 GCN、GAT、GraphSAGE）面临一个核心问题：**欺诈者的伪装行为**。欺诈节点会通过建立大量与正常用户的连接来“稀释”自身的异常特征，这种现象被称为**伪装攻击 (Camouflage Attack)**。

CARE-GNN 的核心优势在于：

- **伪装过滤**：通过相似度计算模块识别并过滤掉欺诈者用于伪装的虚假连接
- **强化学习邻居选择**：采用强化学习机制动态调整邻居选择阈值，自适应应对不同节点的邻居分布差异
- **多关系支持**：支持多关系异构图，通过分关系聚合和跨关系注意力融合充分利用 11 种边类型的信息

6.2 核心架构

CARE-GNN 的核心思想是“先过滤，再聚合”，与传统 GNN 形成鲜明对比：

传统GNN： 节点 → 聚合所有邻居 → 分类

CARE-GNN： 节点 → 计算邻居相似度 → RL选择可信邻居 → 聚合 → 分类




图 6.1 CARE-GNN 整体架构示意图

模型包含四个核心模块：

- (1) **相似度计算模块**：使用余弦相似度计算中心节点与邻居的特征相似度，识别伪装邻居。关键使用余弦相似度而非内积，避免特征尺度影响。
- (2) **强化学习邻居选择器**：策略网络根据节点嵌入动态生成过滤阈值，而非使用固定阈值。训练时添加探索噪声增强鲁棒性。
- (3) **分关系聚合**：为 11 种边类型分别创建独立的聚合器，保留异构图的关系语义信息。
- (4) **跨关系注意力聚合**：使用注意力机制将各关系嵌入融合为最终表示，自动学习不同关系的重要性权重。

```
class InterRelationAggregator(nn.Module):
    """跨关系聚合器 - 注意力机制"""
    def __init__(self, embed_dim, num_relations):
```

```
self.attention = nn.Sequential(
    nn.Linear(embed_dim, 32), nn.Tanh(), nn.Linear(32, 1)
)
```

```
def forward(self, relation_embeddings):
    stacked = torch.stack(relation_embeddings, dim=1) # (B, R, D)
    attn_scores = self.attention(stacked).squeeze(-1) # (B, R)
    attn_weights = F.softmax(attn_scores, dim=1).unsqueeze(-1)
    return (stacked * attn_weights).sum(dim=1) # (B, D)
```

6.3 针对比赛的优化

6.3.1 优化 1: 自适应采样与 2-hop 邻居扩展

问题: 数据分析发现 70% 以上节点度数 ≤ 2 , 传统 1-hop 聚合获取的信息极其有限。

解决方案: 引入自适应采样和 2-hop 邻居扩展机制。根据节点度数层级动态调整采样数量, 并为低度数节点扩展 2-hop 邻居信息。

自适应邻居采样数配置 (按度数层级)

```
self.adaptive_max_neighbors = {
    0: 5, # 极低度数节点: 采样少, 避免重复
    1: 10, # 低度数节点
    2: 15, # 中度数节点
    3: 30 # 高度数节点: 可采样更多邻居
}
```

```
def sample_2hop_neighbors(self, nodes, features, max_2hop=10):
    """为低度数节点采样2-hop邻居, 扩展感受野"""
    for i, node in enumerate(nodes):
        tier = self.dataset.get_node_degree_tier(node)
        if tier <= 1: # 度数 <= 5 的节点才扩展
            neighbors_2hop = self.dataset.get_2hop_neighbors(node)
            # 随机采样并填充特征...
```

效果: 低度数节点从几乎无邻居信息变为可利用 2-hop 扩展的邻居信息, 显著提升表示质量。

6.3.2 优化 2：类别不平衡处理（三重策略）

问题：欺诈样本仅占 1.18%，模型容易学到”全预测正常”的捷径。

解决方案：组合使用三种策略应对极端类别不平衡。

```
# 策略1: 下采样多数类
parser.add_argument('--undersample', type=int, default=8)
# 将正常类下采样到欺诈类的8倍，而非原始的84倍

# 策略2: Focal Loss - 聚焦难分类样本
class FocalLoss(nn.Module):
    def __init__(self, alpha=0.75, gamma=3.0):
        self.alpha = alpha    # 正类权重
        self.gamma = gamma    # 聚焦参数

    def forward(self, inputs, targets):
        ce_loss = F.cross_entropy(inputs, targets, reduction='none')
        pt = torch.exp(-ce_loss)
        # 难分类样本(pt小)权重高，易分类样本(pt大)权重小
        focal_loss = self.alpha * (1 - pt) ** self.gamma * ce_loss
        return focal_loss.mean()

# 策略3: 辅助标签相似度任务
total_loss = gnn_loss + 1.5 * label_loss
```

6.3.3 优化 3：边方向校正

发现：原始数据的边方向可能是”受害者 → 欺诈者”，导致 GNN 聚合的是”谁被骗了”而非”骗了谁”，与欺诈传播逻辑相悖。

解决方案：边方向反转。

```
# 关键优化: 边方向互换 [source, target] → [target, source]
self.edge_index = data['edge_index'][:, [1, 0]] # 交换列
```

边方向校正效果显著：原始方向 AUC 为 0.809，反转后 AUC 提升到 **0.826**，提升约 **1.6%**。

6.4 问题与解决

问题 1：模型区分能力差

早期版本 AUC 始终在 0.5 左右，接近随机猜测。原因是类别极度不平衡（84:1）且边方向与欺诈传播逻辑不符。通过下采样 + Focal Loss 组合策略和边方向反转，AUC 从 0.5 提升到 0.82+。

问题 2：2-hop 邻居构建内存溢出

数据集包含 400 万 + 节点，为所有节点构建 2-hop 邻居会导致内存溢出。解决方案是仅为低度数节点（度数 ≤ 5 ）构建 2-hop 邻居，高度数节点 1-hop 信息已足够丰富。

6.5 关键配置与对比

表 6.1 CARE-GNN 关键超参数配置

参数	值	说明
embed_dim	128	嵌入维度
max_neighbors	30	最大邻居采样数
focal_alpha	0.75	Focal Loss 正类权重
focal_gamma	3.0	Focal Loss 聚焦参数
undersample	8	下采样比例（8:1）
use_2hop	True	启用 2-hop 扩展

表 6.2 与经典 CARE-GNN 的对比

方面	经典 CARE-GNN	本项目实现
邻居采样	固定数量	自适应采样（按度数分层）
感受野	1-hop	1-hop + 条件性 2-hop
损失函数	交叉熵	Focal Loss + 辅助任务
边处理	原始方向	方向反转（+1.6% AUC）
类别平衡	无特殊处理	下采样 + Focal Loss

6.6 方法总结

本研究的 CARE-GNN 方法通过伪装感知机制、自适应邻居选择和针对性优化策略，成功实现了金融反欺诈的高精度预测。主要贡献包括：

- 自适应 2-hop 扩展**：针对金融图中大量低度数节点的特点，通过 2-hop 邻居扩展解决信息稀疏问题
- 边方向校正**：发现并修正原始数据边方向与欺诈传播逻辑的不一致，带来 1.6% 的性能提升
- 多策略类别平衡**：组合下采样、Focal Loss 和辅助任务，有效应对 1.18% 的极端类别不平衡

该方法最终在测试集上达到 AUC **0.82563**，验证了 CARE-GNN 在金融反欺诈领域的有效性。

7 方法五：基于偏差损失的端到端异常检测方法

7.1 方法概述

Deviation Network 采用端到端的深度学习范式来解决金融反欺诈中的异常检测问题。该方法由 Pang 等人在 KDD 2019 提出，其设计理念不同于传统的基于重构误差的异常检测方法。传统方法通常依赖自编码器学习正常样本的特征表示，再通过重构误差来识别异常。Deviation Network 的核心创新在于直接学习异常分数本身，而非间接通过特征重构来推断异常程度。

该方法特别适合处理弱监督场景：已知部分标注的异常样本和大量未标注数据，但缺少可靠的正常样本标签。这种设定与金融反欺诈的实际场景高度契合，因为在实践中我们能够确认的欺诈案例通常有限，而绝大多数交易的真实性质难以完全确定。通过引入偏差损失函数（Deviation Loss），模型学习将异常样本的分数推向分布的高端，同时将正常样本的分数推向低端，从而形成有效的异常评分机制。

7.2 核心架构

7.2.1 核心损失函数设计

Deviation Network 的关键在于其创新的损失函数设计。本项目在原始 deviation loss 基础上，融合了 Focal Loss 的思想，形成了针对极度不平衡数据优化的 focal_deviation_loss：

```
def focal_deviation_loss(y_true, y_pred, alpha=0.99, gamma=2.0):
    # Z-score标准化：将预测分数映射到标准正态分布
    mean = tf.reduce_mean(y_pred)
    std = tf.math.reduce_std(y_pred) + 1e-10
    dev = (y_pred - mean) / std

    # 基础deviation损失
    inlier_loss = tf.square(tf.maximum(dev, 0.0)) # 正常样本期望负偏差
    outlier_loss = tf.square(tf.maximum(-dev, 0.0)) # 欺诈样本期望正偏差

    # Focal权重：减少易分类样本的贡献
    focal_weight_inlier = tf.pow(1 - inlier_prob, gamma)
    focal_weight_outlier = tf.pow(1 - outlier_prob, gamma)

    # 组合加权：alpha=0.99显著提升欺诈样本权重
    weighted_loss = (1 - alpha) * focal_weight_inlier * inlier_loss +
```

$\alpha * \text{focal_weight_outlier} * \text{outlier_loss} * 200.0$

该损失函数包含三个层次的权重调节机制。Z-score 标准化将原始预测分数转换为相对偏差值，使得模型关注的是样本相对于群体的偏离程度而非绝对值。基础 deviation loss 通过惩罚正常样本的正偏差和欺诈样本的负偏差，驱动两类样本在分数分布上的分离。Focal 权重机制借鉴了目标检测领域的思想，对难分类样本给予更多关注，防止模型被易分类样本主导。最重要的是 α 参数和额外的 200 倍权重因子，这两者共同将欺诈样本的损失权重放大到正常样本的约 17000 倍，有效解决了 1:84 极端不平衡比例带来的训练偏差。

7.2.2 网络架构实现

模型提供了深层和浅层两种架构选择，本项目采用深层架构以获得更强的特征提取能力：

A. 深层网络架构

```
def dev_network_deep_improved(input_shape):
    # 输入层：17维原始特征
    x_input = Input(shape=input_shape)

    # 第一隐藏层：256神经元
    x = Dense(256, activation='relu',
              kernel_regularizer=regularizers.l2(0.001))(x_input)
    x = BatchNormalization()(x)
    x = Dropout(0.3)(x)

    # 第二隐藏层：128神经元
    x = Dense(128, activation='relu',
              kernel_regularizer=regularizers.l2(0.001))(x)
    x = BatchNormalization()(x)
    x = Dropout(0.2)(x)

    # 第三隐藏层：64神经元
    x = Dense(64, activation='relu',
              kernel_regularizer=regularizers.l2(0.001))(x)
    x = BatchNormalization()(x)
    x = Dropout(0.1)(x)
```

输出层：单神经元线性激活

```
output = Dense(1, activation='linear', name='score')(x)
```

网络采用渐进式降维设计 (256→128→64→1)，这种漏斗型结构逐步提取和压缩特征信息。每层配备了三重正则化机制：L2 权重衰减抑制过大的参数值，批归一化加速训练收敛并稳定梯度传播，Dropout 以递减比例 (0.3→0.2→0.1) 防止过拟合。输出层使用线性激活而非 sigmoid，这是 deviation loss 的关键要求——模型需要输出未经约束的实数分数，而非被压缩到 [0,1] 区间的概率值，这样才能通过 Z-score 标准化学习到有意义的偏差分布。

7.2.3 标准化处理

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
x = scaler.fit_transform(x) # 基于训练集计算均值和标准差
```

特征标准化对 deviation loss 的有效性至关重要。不同特征的原始量纲和分布差异可能导致某些特征主导模型学习，而标准化将所有特征转换到均值为 0、标准差为 1 的统一尺度。需要特别注意的是，测试集必须使用训练集的统计参数进行标准化，这在中得到了正确实施，避免了数据泄露问题。

7.2.4 训练配置与优化策略

表 7.1 Deviation Network 超参数配置

参数	值	说明
学习率	0.0005	Adam 优化器，较低学习率保证稳定训练
梯度裁剪	1.0	防止梯度爆炸
批大小	256	平衡内存与梯度估计质量
每轮批次数	50	每个 epoch 12800 样本
训练轮数	200	配合早停策略
L2 正则化系数	0.001	所有隐藏层
Dropout 比例	0.3/0.2/0.1	各层递减
alpha	0.99	Focal deviation loss 类别权重
gamma	2.0	Focal 权重的聚焦参数
额外权重因子	200.0	欺诈样本损失倍增器

训练过程采用了三项关键的自适应策略。ModelCheckpoint 回调函数监控训练损失，仅在损失下降时保存模型权重，确保选中的是训练过程中的最优状态。ReduceLROnPlateau 实现学习率的动态衰减：当损失在 10 个 epoch 内未改善时，学习率减半，最低降至 1e-6，这种策略帮助模型在训练后期进行更精细的参数调整。EarlyStopping 在损失停滞 20 个 epoch 后终止训练并恢复最佳权重，防止过度训练导致的性能退化。

7.2.5 模型集成策略

为了提升预测的稳定性和泛化能力，采用了多模型集成方案：

```
runs = 3 # 训练3个独立模型
all_scores = []

for i in range(runs):
    # 使用不同随机种子训练
    scores = load_model_weight_predict(model_path, input_shape,
                                       network_depth, x_test)

    all_scores.append(scores)

# 平均集成
scores_mean = np.mean(all_scores, axis=0)
```

通过改变随机种子（42, 43, 44），每次运行产生不同的权重初始化、数据划分和批次顺序，从而训练出三个具有差异性的模型。最终预测时对三个模型的异常分数取算术平均，这种简单但有效的集成方法能够降低单模型的随机性影响，提高预测的鲁棒性。

7.3 针对比赛的优化

7.3.1 优化：端不平衡数据处理策略

问题：针对金融数据 1:84 的极端不平衡问题，本项目设计了多层次的应对策略：

7.3.2 批次生成策略

```
def batch_generator_sup_extreme_imbalanced(...):
    # 将欺诈样本比例提升至50%
    n_outliers_per_batch = int(batch_size * 0.5)
    n_inliers_per_batch = batch_size - n_outliers_per_batch

    # 欺诈样本数据增强
    noise_level = 0.05
    noise = rng.normal(0, noise_level, outlier_samples.shape)
    outlier_samples_augmented = outlier_samples +
                                noise * np.std(outlier_samples, axis=0)
```

批次采样器将每批数据中欺诈样本的比例从原始的 1.2% 强制提升到 50%，这是一种激进的重采样策略。通过对少数类进行大量重复采样，模型在每次参数更新时都能接收到充足的欺诈样本信号。为了缓解重复采样导致的过拟合风险，对欺诈样本添加了 5% 强度的高斯噪声扰动，噪声幅度根据各特征的标准差自适应调整。这种数据增强技术在保持样本语义的同时，增加了训练数据的多样性。

7.4 性能表现分析




图 7.1 Deviation Network 性能表现与训练过程

Deviation Network 在本次金融反欺诈任务上的实际表现如下：

- 训练集 AUC：0.7756，显示出基础的异常识别能力
- 测试集 AUC：0.7197，较训练集下降约 5.6 个百分点
- 训练速度：单轮 epoch 仅需数秒，推理效率极高
- 模型规模：参数量约 10 万级别，轻量级架构

从性能表现来看，Deviation Network 的 AUC 水平显著低于图神经网络方法 (CARE-GNN 0.8256)，这一差距揭示了一个关键洞察：在金融反欺诈场景中，图结构信息的价值远超单纯的节点特征。该方法将每个用户视为独立样本，仅依赖 17 维特征向量进行异常检测，完全忽略了社交网络中蕴含的关系模式——而恰恰是这些关系模式（如团伙欺诈、洗钱网络）构成了欺诈行为的重要特征。训

训练集与测试集之间 5.6% 的性能落差也暗示着模型对特征分布的敏感性：当面对分布稍有偏移的新数据时，纯特征驱动的方法容易失效。这一实验结果为我们的核心假设提供了有力支撑——金融图数据的反欺诈任务中，邻居关系和网络拓扑是不可或缺的信息源，表格特征方法的天花板远低于图方法的基线。

7.5 方法优势与局限

7.5.1 方法优势

该方法在异常检测任务上展现出多方面的优势。端到端的异常分数学习避免了特征工程和阈值选择的繁琐流程，模型直接输出可用于排序的连续分数。相比基于重构的方法，deviation loss 提供了更直接的优化目标——拉大正常与异常样本的分数差距，而非依赖重构误差这一间接指标。多层次的不平衡处理机制（损失加权、批次重采样、数据增强）协同作用，有效缓解了极端不平衡带来的训练偏差。深层网络架构配合完善的正则化体系，在提供强大拟合能力的同时保持了良好的泛化性能。

7.5.2 方法局限

然而，该方法也存在一些固有的局限性。Deviation loss 要求模型输出形成单峰分布，在复杂的多模态异常场景下可能表现受限。模型仅处理了表格型特征数据，未能利用金融图数据中蕴含的关系网络信息，这与图神经网络方法形成了鲜明对比。超参数的敏感性是另一个挑战：alpha、gamma 和额外权重因子需要根据具体数据集的不平衡程度精心调整，缺乏通用的设定准则。训练过程对初始化和数据顺序较为敏感，虽然模型集成能够部分缓解，但也增加了计算开销。

7.6 方法定位与应用场景

Deviation Network 作为本研究的基线方法之一，代表了基于表格特征的深度异常检测范式。该方法将金融图数据中的节点特征视为独立样本，通过学习特征空间中的偏差分布来识别异常。这种设计使其在面对高质量特征工程的场景时表现优异，但也意味着放弃了图结构信息这一重要维度。

与图神经网络方法相比，Deviation Network 的计算复杂度更低，训练速度更快，在特征充分表达样本特性的情况下，能够达到与复杂图模型相当的性能。但在关系网络起关键作用的场景（如团伙欺诈检测），该方法的表现会受到明显限制。将其纳入实验对比的目的，也是为了评估图结构信息在金融反欺诈任务中的实际价值。

8 结论与展望

本文针对基于大规模动态图数据的金融反欺诈问题，设计并实现了五种不同的解决方法，并在信也科技与浙江大学联合提供的 DGraph 数据集（400 万 + 节点，490 万 + 边，1% 欺诈比例）上进行了全面实验和对比分析。

8.1 研究工作总结

我们的研究工作主要包括以下几个方面：

（1）**问题分析与数据理解**：深入分析了金融反欺诈任务的特点，特别是数据集的大规模、动态性、极端类别不平衡（84:1）和背景节点占比高等挑战。

（2）**基于传统机器学习的基线方法（方法一）**：通过手工设计的 198 维特征工程（包括统计特征、结构特征、时间窗口特征），结合 HistGradientBoosting、XGBoost 和 LightGBM 等多种集成学习策略，实现了 0.83 的 AUC 值。该方法采用数据分块训练策略处理类别不平衡问题，并使用 AUC 加权融合提高集成效果。

（3）**基于图注意力网络的深度学习方法（方法二）**：提出了增强的图注意力网络（GATv2）架构，通过渐进式多头注意力（8→4→2 头）和残差连接机制，结合 GPU 加速的 65 维特征工程，实现了 0.829 的 AUC 值。该方法采用高级 Focal Loss ($\alpha = 0.95, \gamma = 3.0$) 处理类别不平衡，并使用 OneCycleLR 策略优化学习率。

（4）**基于图采样与聚合网络的归纳式学习方法（方法三）**：实现了改进的 GraphSAGE 架构——LearnableEdgeSAGE，通过边感知卷积和多层残差网络，能够有效处理 11 种不同类型的边信息，最佳 AUC 达到 0.8537。该方法采用归纳式学习，能够处理未见过的新节点和新图，特别适合动态场景。

（5）**基于图注意力与辅助任务的半监督学习方法（方法四）**：实现了 CARE-GNN 模型，通过伪装过滤机制和自适应邻居选择，结合边方向校正（提升 1.6% AUC）和 2-hop 邻居扩展，最终达到 0.82563 的 AUC 值。该方法采用半监督学习范式，结合辅助任务增强模型泛化能力。

（6）**基于偏差损失的端到端异常检测方法（方法五）**：实现了 Deviation Network 模型，通过创新的 focal_deviation_loss 直接学习异常分数，结合端到端的深度学习范式，在测试集上达到 0.7197 的 AUC 值。该方法特别适合处理弱监督场景，但仅利用了 17 维表格特征。

（7）**系统的方法对比与消融实验**：全面比较了五种方法的性能差异，并通过消融实验验证了各模块的贡献。

8.2 方法比较与分析

五种方法的性能存在显著差异，从高到低依次为：

各方法的优势与适用场景：

- **方法一（基线方法）**：计算效率高，无需特殊硬件，特征可解释性强，对超参数不敏感，适合

表 8.1 五种方法性能对比

方法	技术路线	核心特点	AUC 值
方法三	图神经网络 (GraphSAGE)	归纳式学习，边感知卷积	0.8537
方法一	传统机器学习	198 维特征工程，集成学习	0.83
方法二	图神经网络 (GATv2)	渐进式注意力，残差连接	0.829
方法四	图神经网络 (CARE-GNN)	伪装过滤，边方向校正	0.82563
方法五	深度异常检测	偏差损失，端到端学习	0.7197

快速部署和资源受限场景。

• **方法二 (GATv2)**：能够自动学习节点表示，捕提高阶图结构信息，特征工程开销较小，适合需要端到端学习的场景。

• **方法三 (LearnableEdgeSAGE)**：归纳式学习能力强，支持动态图和新节点，边类型处理能力突出，是整体性能最优的方法。

• **方法四 (CARE-GNN)**：半监督学习能力强，能够有效处理伪装欺诈，边方向校正技术提升了图结构信息的利用率。

• **方法五 (Deviation Network)**：端到端异常检测，无需复杂特征工程，适合弱监督场景，但忽略了图结构信息是其性能瓶颈。

关键发现：图结构信息在金融反欺诈中具有不可替代的价值。方法五（仅使用表格特征）与其他四种图方法的性能差距（约 10 个百分点）充分证明了这一点。同时，不同图方法之间的性能差异（方法三比方法四高约 2.8 个百分点）表明，如何有效利用图结构信息（特别是多类型边和高阶邻居）是提升性能的关键。

8.3 研究贡献与创新点

本研究的主要贡献和创新点包括：

(1) **多层次特征工程体系**：设计了从 17 维到 198 维的多层次特征工程方案，包括手工特征设计、动态图特征提取和多尺度时间特征，全面捕捉用户的统计、结构和时序信息。

(2) **多样化的类别不平衡处理策略**：提出了数据分块（1:1 正负极化）、Focal Loss ($\alpha=0.95$, $\gamma=3.0$)、批次重采样（50

(3) **创新的图神经网络架构**：

- 渐进式多头注意力机制，减少计算开销并提升模型稳定性
- 边感知卷积和残差网络，充分利用 11 种不同类型的边信息
- 伪装过滤和自适应邻居选择，增强对复杂欺诈模式的识别能力

(4) **高效的图处理与优化策略**：

- GPU 加速的特征工程和模型训练
- 边方向校正技术，提升图结构信息利用率
- 2-hop 邻居扩展，捕捉更丰富的上下文信息

- OneCycleLR 学习率优化策略，加速训练收敛

(5) **全面的方法对比与分析**：提供了从传统机器学习到多种图神经网络方法的系统对比，为金融反欺诈领域的方法选择提供了参考依据。

8.4 研究局限性

尽管我们的方法取得了优异的性能，但仍存在一些局限性：

(1) **动态图信息利用不充分**：所有方法主要基于静态图结构进行建模，未充分利用时序信息捕捉图的动态演化过程。

(2) **模型可解释性有待提升**：虽然 GAT 和 CARE-GNN 提供了一定的注意力机制可解释性，但对于复杂的金融场景，仍需要更直观的解释方法（如反事实解释）。

(3) **计算资源需求不平衡**：图方法（特别是方法三、四）需要大量 GPU 资源，在资源受限的环境下部署成本较高。

(4) **超参数敏感性**：方法二、三、四的性能对超参数（如注意力头数、采样比例、邻居数量）较为敏感，缺乏通用的设定准则。

(5) **泛化能力有待验证**：方法五在训练集与测试集之间存在 5.6

8.5 未来工作展望

基于当前的研究成果，未来可以从以下几个方面进一步改进和拓展：

(1) **动态图模型探索**：研究动态图神经网络（DGNN）方法，利用时序信息建模图结构的演化过程，捕捉欺诈行为的时间模式和传播规律。

(2) **自监督与半监督学习结合**：将自监督学习技术引入图神经网络训练，利用大量未标记数据提升模型性能，缓解数据标注压力。

(3) **联邦学习应用**：探索联邦学习框架下的金融反欺诈方案，在保护数据隐私的前提下实现跨机构的模型协作。

(4) **多模态融合**：结合文本、图像等多模态信息，构建更全面的用户画像，提高欺诈识别的准确性。

(5) **实时性优化**：针对实际应用场景，优化模型的推理速度，实现毫秒级的实时欺诈检测。

(6) **可解释性增强**：开发更直观的模型解释方法，提高模型在金融监管场景下的可接受度。

(7) **图结构信息深度挖掘**：探索 3-hop 及以上的高阶邻居信息，以及动态边权重的自适应学习。

8.6 总结

本文设计并实现的五种方法在金融反欺诈任务上展现了不同的技术路线和性能特点。实验结果表明：

(1) 图结构信息在金融反欺诈中具有不可替代的价值，所有利用图结构的方法都显著优于纯表格特征方法。

(2) 改进的 GraphSAGE 架构 (LearnableEdgeSAGE) 在当前数据集上表现最佳，其归纳式学习能力和边类型处理能力使其特别适合动态金融场景。

(3) 传统机器学习方法 (基线方法) 在性能上仍具有竞争力，且在计算效率和可解释性方面具有优势。

(4) 有效的类别不平衡处理和特征工程是提升所有方法性能的关键因素。

随着图神经网络技术的不断发展和硬件资源的进步，基于图的深度学习方法有望在金融风控领域发挥更大的作用。我们的研究为金融科技领域的反欺诈实践提供了有价值的技术方案和实践经验，也为后续的相关研究奠定了坚实基础。

参考文献

[1] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.

[2] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017.

[3] Schlichtkrull M S, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[M]//The Semantic Web. Springer, Cham, 2018: 593-607.

[4] Hu W, Liu B, He J, et al. Heterogeneous graph neural network[C]//Knowledge discovery and data mining. ACM, 2020: 793-803.

[5] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[C]//Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining. 2016: 785-794.

[6] Ke G, Meng Q, Finley T, et al. Lightgbm: A highly efficient gradient boosting decision tree[C]//Advances in neural information processing systems. 2017: 3146-3154.

[7] Prokhorenkova L, Gusev G, Vorobev A, et al. Catboost: unbiased boosting with categorical features[C]//Advances in neural information processing systems. 2018: 6638-6648.