

GraphSAGE 模型参赛详情

算法概述

GraphSAGE (Graph SAmple and aggreGatE, 图采样与聚合) 是由斯坦福大学团队于 2017 年提出的归纳式图神经网络 (GNN) 核心模型, 旨在解决传统直推式 GNN (如 GCN) 无法处理 "未见过的新节点 / 新图" 的局限。其核心逻辑是 "不依赖全局图结构预计算节点嵌入, 而是通过局部采样与特征聚合学习通用的节点表示生成规则": 首先对目标节点的多阶邻居进行采样 (避免高度数节点导致的计算爆炸), 再通过均值、池化、LSTM 等聚合器, 将邻居节点的特征与自身特征逐层融合, 最终生成具有全局上下文信息的节点嵌入。GraphSAGE 的归纳式能力使其广泛应用于动态图 (如社交网络新用户加入)、大规模图 (如百万级节点的推荐系统) 等场景, 为 GNN 从 "静态场景" 走向 "动态、泛化场景" 提供了关键技术支撑。






Figure 1: Visual illustration of the GraphSAGE sample and aggregate approach.


核心工作流程



特征聚合过程



详细训练流程图



数据集描述

基本信息

- **数据来源:** CCF金融反欺诈比赛数据集
- **文件格式:** phase1_gdata.npz
- **任务类型:** 图节点分类（二分类：正常用户 vs 欺诈用户）

数据结构

节点特征：

- 形状：(N_node, 17)
- 特征维度：17维用户特征
- 数据处理：-1值替换为0

标签分布：

- 0：正常用户
- 1：欺诈用户
- 2, 3：背景用户（训练中可能忽略）
- 测试样本标签：-100

图结构：

- 边类型：11种有向边类型
- 时间特征：边连接日期（从1开始的整数，单位：天）
- 边数量：N_edge条有向边

数据特点

1. **类别不平衡:** 欺诈用户(标签1)占比极低，正常用户(标签0)占绝大多数
2. **异质边类型:** 包含11种不同类型的用户关系边
3. **时序信息:** 边带有时间戳信息，可用于时序分析
4. **有向图:** 边具有方向性，表示用户间的影响关系

模型架构

核心架构：LearnableEdgeSAGE


项目采用了基于GraphSAGE的改进架构，主要创新在于：

1. 自定义边感知卷积层 (LearnableEdgeSAGEConv)

```
class LearnableEdgeSAGEConv(nn.Module):
    def __init__(self, in_channels, out_channels, num_edge_types,
                 edge_dim=32, hidden_dim=64):
```

核心组件:

- 1. 边类型嵌入 (Edge Type Embedding)
 - 使用 `nn.Embedding` 将11种离散边类型映射到连续向量空间
 - 嵌入维度: 32维 (可配置)
- 2. 双路径特征变换
 - 自节点路径: `lin_self` - 处理节点自身特征
 - 邻居节点路径: `lin_neigh` - 处理邻居节点+边特征
- 3. 注意力机制
 - 输入: [源节点特征, 目标节点特征, 边特征] 的拼接
 - 架构: 2层MLP + LeakyReLU激活
 - 输出: 边重要性权重, 用于邻居聚合
- 4. 归一化策略
 - 按目标节点进行softmax归一化
 - 数值稳定性处理: 减去最大值后计算exp
 - 防止除零错误: 添加小常数1e-8



2. 多层残差网络结构

```
class SAGE(nn.Module):
    def __init__(self, in_channels, hidden_channels, out_channels,
                 num_layers, num_edge_types, edge_dim=32, use_residual=False):
```

网络配置:

- 输入层：17维 → 32维
- 隐藏层：32维 → 32维（多层）
- 输出层：32维 → 2维（二分类）
- 层数：5层可配置

关键特性:

- 1. **残差连接**：解决深度网络梯度消失问题
- 2. **批量归一化**：每层后使用BatchNorm1d稳定训练
- 3. **Dropout**：0.2的dropout率防止过拟合
- 4. **维度投影**：当输入输出维度不匹配时自动添加线性投影

与标准GraphSAGE的对比

特性	标准GraphSAGE	本项目改进版
边信息处理	忽略边类型	可学习的边类型嵌入
聚合策略	固定聚合函数	注意力机制的动态聚合
残差连接	无	支持，提高深度网络性能
归一化	基础归一化	分层softmax归一化
特征融合	仅节点特征	节点+边特征联合编码

针对性适配设计

1. 处理类别不平衡

损失函数设计:

```
self.weight = torch.FloatTensor([0.24, 20.31]).to(self.device)
```

- 正常用户权重：0.24
- 欺诈用户权重：20.31
- 权重比例：约1:84.6，大幅提升欺诈样本的重要性

备选损失函数:

```
def focalLoss(output, target, gamma=2, alpha=0.25):
```

- Focal Loss：聚焦难分类样本

- 参数：gamma=2, alpha=0.25
- 当前使用：加权交叉熵损失

2. 邻居采样策略

```
num_neighbors=[5, 5, 5, 5, 5] # 5层采样，每层5个邻居
```

设计考虑:

- 避免邻居爆炸：每层限制5个邻居
- 保持多跳信息：5层采样捕获远距离关系
- 内存友好：batch_size=128控制显存使用

训练配置

超参数设置

参数	值	说明
学习率	0.01	Adam优化器
权重衰减	5e-4	L2正则化
批大小	128	邻居采样批次
隐藏维度	32	平衡性能与复杂度
边嵌入维度	4	最终版本使用
训练轮数	50	早期停止策略
Dropout	0.2	防止过拟合

训练策略

1. **优化器**: Adam + 权重衰减
2. **批次处理**: 邻居采样而非全图训练
3. **验证监控**: AUC作为主要评估指标
4. **模型保存**: 基于验证AUC选择最佳模型
5. **交互式训练**: 支持手动停止和保存

性能评估

评估指标

- **主要指标:** AUC（欺诈用户识别能力）
- **辅助指标:** 训练损失、验证损失
- **输出格式:** (N, 2)概率矩阵，前两类的概率分布

性能表现

根据提交历史：

- **最佳AUC:** 0.8537（可能存在过拟合）
- **稳定AUC:** 0.77-0.78范围
- **模型参数量:** 约数万级别（具体取决于配置）

架构优势

1. 针对金融图数据的优化

- **边类型感知:** 11种金融关系的语义区分
- **注意力聚合:** 自适应学习不同关系的重要性

2. 训练稳定性

- **残差连接:** 支持深层网络训练
- **批量归一化:** 加速收敛，提高稳定性
- **梯度处理:** 避免数值溢出，提高鲁棒性

架构不足

1. 计算复杂度

- **邻居采样:** 5层×5邻居的采样策略计算开销大
- **注意力机制:** 每条边计算注意力权重，增加计算量
- **内存占用:** 需要存储中间特征和注意力分数

2. 信息利用不充分

- **时序信息:** 边时间戳未在当前版本中充分利用
- **高阶关系:** 仅考虑直接邻居，未建模复杂路径关系

- **特征工程:** 17维特征的预处理相对简单

3. 模型简化

- **边嵌入维度:** 最终版本使用4维，可能损失部分信息
- **隐藏维度:** 32维相对较小，可能限制模型表达能力
- **层数限制:** 5层可能不足以捕获远距离依赖

4. 训练策略限制

- **类别不平衡处理:** 仅使用加权损失，未采用过采样等其他技术
- **正则化:** 仅使用dropout和weight_decay，未使用更先进的正则化方法
- **超参数调优:** 手动设置，未系统优化

改进建议

1. 架构优化

- 考虑更高效的注意力机制（如GATv2）
- 增加时序建模能力
- 融合高阶图结构信息

2. 训练策略

- 实现自动超参数优化
- 添加更多正则化技术
- 采用更先进的类别不平衡处理方法

3. 工程优化

- 实现分布式训练支持
- 优化内存使用效率
- 添加模型压缩和量化支持