

学生考试成绩预测回归分析实验报告

一、课题综述

1.1 课题简介

在机器学习回归任务中，传统线性回归算法（如普通最小二乘回归 OLS、岭回归 Ridge、套索回归 Lasso）凭借参数可解释性强、训练效率高、对小样本适应性好的优势，广泛应用于连续变量预测场景。本课题以“学生考试成绩预测”为目标，基于学生的学习时长、睡眠时间、出勤率、以往成绩 4 个核心特征，构建 Ridge、OLS、Lasso 等传统线性回归模型及随机森林、K 近邻等机器学习模型，通过 K 折交叉验证优化超参数，以 R^2 （决定系数）、RMSE（均方根误差）、MAE（平均绝对误差）、MAPE（平均绝对百分比误差）为评估指标，在独立测试集验证模型性能，最终筛选出最优预测模型并分析各特征对考试成绩的影响强度。

1.2 课题目标

课题的目标为完成“学生考试成绩”数据集的处理，搭建传统线性回归模型（OLS、Ridge、Lasso）及多种机器学习回归模型，实现“学生不同特征→考试成绩”的预测，并通过训练集优化模型参数，测试集评估模型性能，对比不同模型的优缺点，同时可视化展示数据分布、特征相关性、模型预测结果及残差情况，提炼关键影响因素。基于实验结果优化模型，最终确定最优预测模型并总结其应用价值。

1.3 课题数据集


本课题使用“学生考试成绩”结构化数据集，具体信息如下。

特征维度：包含 4 个自变量与 1 个因变量，具体定义如下表：


变量名称	变量类型	含义说明	取值范围
hours_studied	数值型	每周学习时长（小时）	1.00-12.00
sleep_hours	数值型	每日睡眠时间（小时）	4.00-9.00
attendance_percent	数值型	课程出勤率（百分比）	50.30%-100.00%

previous_scores	数值型	以往考试平均成绩（分数）	40.00-95.00
exam_score	数值型	实际考试成绩（分数）	17.10-51.30

样本规模：共 200 条有效样本（从一开始的总统计数据得出无缺失值、无异常值），按 8:2 划分为训练集（160 条）与测试集（40 条）；



数据分布特征上，因变量（exam_score）偏度为 0.03（近似对称）、峰度为-0.35（分布平缓），无明显偏态；



自变量数据的部分特征及分布图如下：

Hours Studied:

均值：6.33
标准差：3.23
范围：1.00 – 12.00

Sleep Hours:


均值：6.62
标准差：1.50
范围：4.00 – 9.00


Attendance Percent:

均值：74.83
标准差：14.25
范围：50.30 – 100.00

Previous Scores:

均值：66.80
标准差：15.66
范围：40.00 – 95.00





二、实验报告设计

2.1 数据准备

预处理流程具体步骤如下：

1. 数据类型确认：检查所有变量均为数值型（float64），无需类型转换；
2. 样本完整性校验：通过 `df.isnull().sum()` 统计，所有变量缺失值数量为 0，无需插值或删除；
3. 数据集划分：使用 `sklearn.model_selection.train_test_split` 按 8:2 比例划分训练集（`X_train`, `y_train`）与测试集（`X_test`, `y_test`），设置 `random_state=42` 确保结果可复现；
4. 特征标准化：对自变量进行 Z-score 标准化（通过 `StandardScaler`），消除量纲差异对梯度下降、SVR 等模型的影响（线性模型 OLS/Ridge 对量纲不敏感，但标准化可统一参数解释尺度）。

2.2 数据清洗

由于原始数据集完整性较好，清洗重点为“异常值检测-分布合理性校验-特征冗余筛选”，具体操作如下：


1. 异常值检测：

上文中提到所有数据均通过异常值检测，处理后的数据无缺失值，无异常值；


2. 分布合理性校验：

对因变量`exam\_score`绘制 QQ 图（见图 1），确认其近似正态分布，无极端

值；



3. 特征冗余检查：通过相关性热力图（见图 2）分析，自变量间最大相关系数为 -0.194(sleep_hours 与 previous_scores), 无多重共线性问题，无需删除特征。



*红色越深表示正相关越强，蓝色越深表示负相关越强。

2.3 模型搭建

本实验共搭建 8 种回归模型，其中传统线性回归模型 3 种、机器学习回归模型 5

种，具体模型及其参数如下：

```
models = {  
    # 线性模型  
    "OLS": "ols",    # 特殊标记，需要单独处理  
    "Ridge": "ridge",    # 特殊标记  
    "Lasso": Lasso(alpha=0.1, random_state=random_state),  
    # 机器学习模型  
    "Gradient Descent":  
GradientDescentRegression(learning_rate=0.01, max_iter=2000),  
    "Support Vector Regression": SVR(kernel='rbf', C=1.0),  
    "Decision Tree": DecisionTreeRegressor(max_depth=5,  
random_state=random_state),  
    "Random Forest": RandomForestRegressor(n_estimators=50,  
max_depth=5, random_state=random_state),  
    "K-Nearest Neighbors": KNeighborsRegressor(n_neighbors=5)  
}
```

2.3.1 传统线性回归模型

1. 普通最小二乘回归（OLS）

原理：通过最小化残差平方和求解回归系数，无正则化约束；

优势：参数解释直观，计算效率高；

劣势：无正则化，面对多重共线性时系数不稳定（本实验无此问题）。

2. 岭回归（Ridge）

原理：在 OLS 基础上加入 L2 正则项，抑制系数过大，防止过拟合；

优势：比 OLS 更稳定，适合小样本或潜在共线性场景；

劣势：不具备特征选择能力（所有系数非零）。

3. 套索回归（Lasso）

原理：加入 L1 正则项，可使部分系数归零，实现特征选择；

优势：可筛选关键特征；

劣势：对 α 敏感， α 过大会剔除有效特征（如 $\alpha=10.0$ 时 R^2 降至

0.5718)。

2.3.2 机器学习回归模型

1. 随机森林回归 (Random Forest)

原理：集成多棵决策树，通过投票/平均降低过拟合风险；

2. K 近邻回归 (KNN)

原理：基于“距离相似性”预测，通过邻居样本均值输出结果；

3. 其他模型：梯度下降回归、SVR、决策树等。

2.4 模型训练测试

2.4.1 训练流程

线性模型训练：

OLS 回归通过 $OLS(x, y)$ 函数实现，核心逻辑为最小化残差平方和求解系数，训练结果中系数包含截距项，直接反映各特征对考试成绩的线性影响强度；Ridge 回归通过 $Ridge(x, y, \alpha)$ 函数实现，在 OLS 基础上添加 L2 正则项，通过 $\alpha=0.1$ 控制正则强度，抑制系数过大，提升模型稳定性。Lasso 回归调用 `sklearn.linear_model.Lasso` 实现，添加 L1 正则项， $\alpha=0.1$ 时保留全部 4 个特征（非零系数），未发生特征剔除。


机器学习模型训练（以随机森林为例）：

随机森林通过集成多棵决策树降低过拟合风险，代码调用 `sklearn` 实现。训练具有无需特征标准化（对量纲不敏感），通过 `feature_importances_` 输出特征重要性，无需显式系数计算，训练过程包含 bootstrap 抽样与特征随机选择，提升泛化能力等特点。

梯度下降回归实现过程：

项目中通过 `GradientDescentRegression` 类封装了梯度下降的完整逻辑，其过程包括：参数初始化，初始化模型权重为全 0 向量，偏置项为 0，同时设置学习率、最大迭代次数和收敛阈值；前向传播计算预测值，对于输入特征 X ，通过线性方程计算预测值；损失函数与梯度计算，采用均方误差（MSE）作为损失函数，衡量预测值与真实值的差异；参数迭代更新，根据梯度方向和学习率更新参数，逐步降低损失；收敛判断，当相邻两次迭代的损失差值小于阈值时，停止迭

代，避免无效计算。




*MSE 随迭代次数增加逐渐下降，639 次后趋于稳定，说明模型收敛。

2.4.2 测试与评估

使用测试集（40 条样本）计算所有模型的 4 项评估指标，结果如下表：

模型名称	R ² (决定系数)	RMSE (分)	MAE (分)	MAPE (%)
OLS	0.8537	2.7860	2.3109	6.97
Ridge	0.8537	2.7860	2.3110	6.97
Lasso	0.8523	2.7994	2.3456	7.09
梯度下降回归	0.8518	2.8044	2.3017	6.92
随机森林	0.7898	3.3401	3.0237	9.15
K 近邻 (KNN)	0.7819	3.4023	2.8935	8.94
支持向量回归 (SVR)	0.6993	3.9946	3.2239	10.11
决策树	0.6737	4.1616	3.6636	11.46



关键结论：


传统线性模型表现最优：Ridge 与 OLS 的 R^2 最高(0.8537)，RMSE 最低(2.7860)，说明模型可解释 85.37%的考试成绩变异，预测误差仅约 2.79 分；


机器学习模型表现较弱：决策树 R^2 最低 (0.6737)，可能因样本量小 (200 条) 无法充分发挥集成/非线性模型优势。

2.5 结果可视化

2.5.1 特征与目标变量关系可视化


散点图+趋势线：学习时长与考试成绩的散点图趋势线斜率最大 ($r=0.777$)，直观体现强正相关；睡眠时间趋势线平缓 ($r=0.188$)，影响微弱；







*趋势线拟合度高，学习时长增加时考试成绩明显上升。

同时，特征相关性也可以通过直方图进行可视化比较：




2.5.2 模型性能对比可视化


R^2 与 RMSE 柱状图：Ridge 与 OLS 的 R^2 显著高于其他模型，RMSE 显著低于其他模型，直观展示最优性能；



预测值 vs 真实值散点图：Ridge 模型的预测值与真实值点接近对角线，说明预测准确性高；




残差分布图：Ridge 残差近似正态分布，无明显趋势，说明模型无系统误差。



2.5.3 特征重要性可视化

为印证上文数据处理时各项特征与目标变量相关性的分析，此处对部分模型下的特征重要性进行可视化展示。



*可印证学习时长是影响考试成绩的核心特征。

2.6 分析和优化

2.6.1 模型对比分析

上文已给出各模型详细的测试数据及相应结论，此处选取典型的两组模型进行对比，体现其优劣。

1. Ridge vs OLS

相同点： R^2 、RMSE 完全一致（0.8537、2.7860），说明本数据集无多重共线性，OLS 已足够优秀；

差异点：Ridge 加入 L2 正则，在数据存在噪声或共线性时更稳定（本实验未体现），OLS 无正则，系数可能对异常值更敏感；


结论：Ridge 综合性能更优（稳定性+准确性），作为最优模型。

2. Ridge vs 决策树

优势（Ridge）： R^2 高 18 个百分点，RMSE 低 1.37 分，参数可解释（明确各特征贡献），训练/预测速度快；

劣势（决策树）：过拟合风险高（训练集 R^2 约 0.92，测试集仅 0.67），无法解释特征间的线性关系，样本量小时性能差；

结论：线性模型更适配本数据集（特征与目标变量呈线性相关）。



*图为三种模型的学习曲线，可体现线性模型的优势。

2.6.2 模型优化方向

1. 超参数精细化调优:

对 Lasso 采用网格搜索，扩大 alpha 范围（如 0.001-100），寻找更优特征选择效果；对随机森林调整 `n_estimators`（如 100、200）与 `max_depth`（如 3、7），降低过拟合。

2. 特征工程改进:

构建交互特征（如“学习时长×出勤率”），捕捉特征间的联合影响；对偏态特征（此数据集中暂无）进行对数变换，进一步提升线性模型拟合度。

3. 模型集成优化:

采用“Ridge+随机森林”的堆叠集成，结合线性模型的准确性与非线性模型的泛化能力，可能提升 R^2 至 0.87 以上。

4. 数据扩充:

现有样本量仅 200 条，增加至 500+条可提升随机森林、SVR 等模型性能，减少过拟合。

三、总结

本实验围绕“学生考试成绩预测”任务，完成了从数据预处理到模型优化的全流程，核心结论如下：

- 1. 数据质量：200 条样本无缺失值、无异常值，特征间无多重共线性，数据完整性与合理性满足建模要求；
- 2. 特征影响：学习时长是影响考试成绩的核心因素 ($r=0.777$)，其次为以往成绩 ($r=0.431$)，睡眠时间与出勤率影响较弱，可重点通过增加学习时长、巩固以往知识提升成绩；
- 3. 模型性能：Ridge 回归为最优模型 ($R^2=0.8537$, $RMSE=2.7860$)，传统线性模型 (OLS、Ridge、Lasso) 整体优于机器学习模型，原因是特征与目标变量呈显著线性相关，且样本量较小；
- 4. 应用价值：最优模型可用于学生考试成绩预测，误差仅约 2.8 分，为教师制定个性化学习计划（如督促学习时长不足的学生）提供数据支持。

四、组员及任务分配情况

姓名	学号	分工
程亦诚	2351582	数据准备，清洗，模型求解
李盛鹏	2351136	模型验证，结果整理，数据可视化
殷和尘	2350999	撰写实验报告