

同濟大學

TONGJI UNIVERSITY

机器学习实验报告

实验名称	购物中心客户细分分析报告
学 院	计算机科学与技术学院
姓 名	李盛鹏, 殷和尘, 程亦诚
日 期	2025 年 12 月 20 日

1 项目背景

1.1 实验背景

企业积累的大量客户交易数据需要有效利用, 聚类分析可以根据客户消费金额、频率、品类等特征, 自动划分相似群体, 帮助理解客户结构。

1.2 实验目标

本项目以零售客户数据为对象, 应用 K-means 和 DBSCAN 两种聚类算法进行客户分群。我们对原始数据做预处理, 选取核心特征, 训练聚类模型, 并通过多种指标评估效果。最后可视化展示分群结果, 分析不同群体的消费行为特征。

2 实验设计与实现

2.1 实验设计

实验流程包括数据预处理、特征选择、模型训练和结果评估几个阶段。我们选取反映消费行为的核心特征, 用 K-means 和 DBSCAN 两种算法分群, 再通过可视化和评估指标比较效果。

2.2 数据集与预处理

2.2.1 数据集

实验使用某英国零售企业 2010-2011 年的交易数据, 共 4338 名客户。主要特征包括年龄、年收入、累计消费金额、购买频次、平均客单价、消费评分、产品种类数等。另外识别出 559 名异常客户, 用于评估模型鲁棒性。

2.2.2 预处理

数据清洗包括缺失值处理和异常值检测。选取消费频次、总消费额、平均客单价等核心特征, 并进行 Z-score 标准化, 消除量纲影响。




图 2.1 客户特征分布情况

图2.1展示了各特征变量的分布情况，可以看出不同特征具有不同的分布形态，部分特征存在长尾现象，这也是进行标准化处理的必要性所在。




图 2.2 特征相关性矩阵

图2.2展示了各特征之间的相关性。从热力图可以看出，总消费金额与购买频次、平均客单价等特征存在较强的正相关关系，这符合业务直觉。同时，某些特征之间的相关性较弱，说明它们能够从不同维度刻画客户行为，为聚类分析提供了多样化的信息。

2.3 模型搭建

本实验采用两种主流聚类算法进行客户分群：K-Means 和 DBSCAN。

2.3.1 K-Means 模型

K-Means 是一种基于距离的聚类方法，适用于数据分布较为均匀的场景。其核心思想是将数据划分为 K 个簇，使得簇内样本点到簇中心的距离平方和最小。




图 2.3 K-Means 算法原理示意图

图2.3展示了 K-Means 算法的基本原理。算法迭代地进行两个步骤：（1）分配步骤：将每个样本分配到最近的簇中心；（2）更新步骤：重新计算每个簇的中心位置。这一过程不断重复直至收敛。

实验中通过肘部法则和轮廓系数自动选择最优簇数量（n_clusters），一般在 3 至 5 之间。主要超参数如下：

```
1 KMeans(  
2     n_clusters = K # 自动寻优，常用3~5  
3     random_state = 42  
4     n_init = 10  
5 )
```

代码 2.4 K-Means 模型主要参数

优势：K-Means 算法计算效率高，适合大规模数据，聚类结果易于解释。**劣势：**对噪声和异常值敏感，且需要预先指定簇数量，难以处理非球状分布的数据。**模型构建代码：**

```
1 kmeans = KMeans(n_clusters=K, random_state=42, n_init=10)  
2 kmeans_labels = kmeans.fit_predict(X_scaled)
```

代码 2.5 K-Means 模型核心代码

2.3.2 DBSCAN 模型

DBSCAN 是一种基于密度的聚类方法，能够识别噪声点和不同密度的簇，适合发现异常客户或稀有群体。该算法将样本点分为核心点、边界点和噪声点三类，基于密度可达性构建簇。




图 2.6 DBSCAN 算法原理示意图

图2.6展示了 DBSCAN 算法的密度聚类思想。算法通过两个关键参数：半径 eps 和最小样本数 min_samples 来定义密度。如果一个点的 eps 邻域内至少包含 min_samples 个点，则该点被视为核心点。从核心点出发，通过密度可达性将相邻的核心点和边界点连接成簇，无法归入任何簇的点被标记为噪声点。

主要超参数如下：

```
1 DBSCAN(  
2     eps = 0.5  
3     min_samples = 5  
4 )
```

代码 2.7 DBSCAN 模型主要参数

优势：DBSCAN 无需预先指定簇数量，能有效识别噪声点和发现任意形状的簇。**劣势：**对参数敏感，难以在高维数据和不同密度簇场景下取得理想效果。**模型构建代码：**

```
1 dbscan = DBSCAN(eps=0.5, min_samples=5)  
2 dbscan_labels = dbscan.fit_predict(X_scaled)
```

代码 2.8 DBSCAN 模型核心代码

2.4 环境配置

本实验在 Windows 10 操作系统下进行，配置如下表所示：

表 2.1 实验环境配置表

extbf 类别	配置详情
操作系统	Windows 10
处理器	Intel i7
内存	16GB
Python 版本	3.8
主要依赖库	numpy, pandas, scikit-learn, matplotlib, seaborn
开发环境	Jupyter Notebook / VS Code

2.5 实验过程

实验流程分为以下几个步骤：

(1) 数据加载与预处理

```
1 import pandas as pd
2 from sklearn.preprocessing import StandardScaler
3 data = pd.read_csv('data/Online_Retail_Customers.csv', encoding='utf-8-sig')
4 feature_cols = [col for col in data.columns if col not in ['CustomerID', '
    Customer_Type', 'Gender', 'Membership_Level']]
5 X = data[feature_cols].values
6 scaler = StandardScaler()
7 X_scaled = scaler.fit_transform(X)
```

代码 2.9 数据加载与预处理

对原始数据进行读取和标准化处理,使所有特征具备统一量纲。

(2) 寻找 K-Means 最优簇数

```
1 from sklearn.cluster import KMeans
2 from sklearn.metrics import silhouette_score
3 scores = []
4 for k in range(2, 7):
5     kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
6     labels = kmeans.fit_predict(X_scaled)
7     scores.append(silhouette_score(X_scaled, labels))
8 optimal_k = range(2, 7)[scores.index(max(scores))]
```

代码 2.10 K-Means 最优 K 值选择

采用轮廓系数遍历不同 K 值,自动确定最优聚类簇数。

(3) 模型训练与聚类

```
1 kmeans = KMeans(n_clusters=optimal_k, random_state=42, n_init=10)
2 kmeans_labels = kmeans.fit_predict(X_scaled)
3 from sklearn.cluster import DBSCAN
4 dbscan = DBSCAN(eps=0.5, min_samples=5)
5 dbscan_labels = dbscan.fit_predict(X_scaled)
```

代码 2.11 模型训练与聚类

客户数据分别应用 K-Means 与 DBSCAN 算法进行分群,获得不同聚类标签。

3 实验结果与分析

本节主要围绕聚类实验的核心现象展开,依次分析数据分布、K 值选择、聚类结构、特征差异以及实验要点。分析过程中注重方法本身的表现和数据特征,不涉及实际业务落地或产品建议。

3.1 数据分布与初步观察

整体来看，样本在核心特征空间中的分布并不均匀，局部区域密度差异明显。先看数据在低维投影上的形态，能够帮助我们直觉地理解后续聚类边界的形成。




图 3.1 数据分布概览与密度直观

从图3.1可见，主体人群集中在中等收入与中等消费评分的区域，少数高值与低值样本分散于两侧。这种“中部密集、两端稀疏”的结构，会让基于中心的划分更容易稳定，而密度方法在参数不恰当时可能产生较多噪声点。这一点在后续结果中会得到呼应。

3.2 K 值选择与性能度量

K-Means 的簇数如何确定，一直是影响结果质量的关键。我们参考肘部法与轮廓系数曲线，在可接受的稳定性与可解释性之间做平衡。




图 3.2 K 值选择示意（肘部法/轮廓系数）

此外，实验采用了三类常见指标对聚类效果进行评估，包括轮廓系数、Calinski–Harabasz 指数和 Davies–Bouldin 指数。从结果来看，K-Means 在本数据集上表现出更高的稳定性，而 DBSCAN 在默认参数下产生了较多噪声点。

表 3.1 聚类性能评估（越靠近理想方向越好）

oprule extbf 方法	Silhouette	Calinski–Harabasz	Davies–Bouldin
K-Means	0.3398	1605.9066	1.3564
DBSCAN	-0.0161	44.4023	0.9598

extbf 指标解释：

- **轮廓系数 (Silhouette Score)**：取值范围为 $[-1, 1]$ ，越接近 1 表示同簇样本越紧密、不同簇分离越明显。
- **Calinski-Harabasz 指数**：衡量簇间方差与簇内方差的比值，数值越大说明聚类效果越好。
- **Davies-Bouldin 指数**：反映簇内外距离的平均值，数值越小表示簇分离度越高、聚类效果越优。

3.3 聚类结果与客户画像

在选定的 K 值下，K-Means 划分出了两类较为清晰的群体：一类以低消费、低频次为主，另一类则表现为高消费、高频次。两组在样本规模和主要特征指标上存在明显差异。




图 3.3 K-Means 与 DBSCAN 的聚类可视化对比

图3.3左侧的 K-Means 结果边界较为清晰，中心位置与样本密集区吻合；而右侧的 DBSCAN 在高密度区域内能够刻画出更复杂的形状，但在密度不均的情况下会将部分中间层样本判为噪声，导致分群结构出现碎片化现象。

另一视角下的客户分群展示如图3.4所示，该图从不同特征组合的角度呈现了聚类边界，进一步验证了 K-Means 在本数据集上的分群稳定性。



图 3.4 客户分群可视化（多维视角）

为更直观地展示分簇结构，下面分别列出 K-Means 和 DBSCAN 的主要簇统计：

表 3.2 K-Means 各簇统计特征

oprulr extbf 簇编号	样本数	频次 (均值)	总消费 (均值)	客单价 (均值)	消费评分 (均值)
0	2372	1.72	446.65	17.29	9.66
1	1407	5.88	1993.32	18.75	10.98

K-Means 分为两簇，样本量分布不均，且高频高消费簇在各项指标上均高于低频低消费簇。

extbf 各指标说明：

- **样本数**：该簇或噪声类别中包含的客户数量。
- **频次 (均值)**：每个客户的平均购买频率，反映活跃程度。
- **总量 (均值)**：客户累计购买商品的平均数量。
- **总消费 (均值)**：客户累计消费金额的均值，衡量整体消费能力。
- **客单价 (均值)**：每次购买的平均花费，体现单次消费水平。
- **消费评分 (均值)**：客户的平均消费评分，反映消费质量或满意度。

这些指标共同描绘了每个簇的典型特征。例如，频次和总消费均值高的簇往往代表高活跃、高消费群体，而客单价和消费评分的差异则揭示了不同簇在消费行为和偏好上的细微区别。噪声类别

表 3.3 DBSCAN 各簇统计特征（含噪声）

oprule extbf 类别	样本数	频次 (均值)	总量 (均值)	总消费 (均值)	客单价 (均值)	消费评分 (均值)
噪声点	2000	4.76	913.71	1563.58	20.81	11.95
簇 0	1607	1.42	221.22	378.02	14.66	8.29
簇 1	10	3.00	395.20	800.30	20.24	10.00
簇 2	16	4.69	741.88	1201.76	16.66	10.29
簇 3	5	4.80	844.60	1396.40	21.00	12.77
簇 4	6	4.00	258.33	637.39	9.52	3.85
簇 5	10	4.00	314.20	630.53	7.83	3.89
簇 6	5	3.00	401.80	800.74	7.67	3.85
簇 7	17	2.00	163.71	375.92	17.92	7.81
簇 8	5	2.00	220.20	630.53	25.72	9.11
簇 9	5	2.00	396.40	586.73	17.45	11.61
簇 10	5	2.00	58.60	186.48	5.22	1.64
簇 11	21	2.00	219.71	383.49	6.26	3.54
簇 12	5	2.00	395.20	837.66	20.94	9.73
簇 13	3	1.00	141.00	263.92	33.03	17.76
簇 14	10	4.60	416.90	866.01	5.96	2.86
簇 15	7	2.00	388.43	638.23	5.96	3.65
簇 16	9	3.00	247.33	467.18	9.04	4.82
簇 17	5	4.00	972.00	1658.27	13.77	8.10
簇 18	6	4.00	475.67	1012.72	18.71	8.82
簇 19	6	3.67	401.17	765.18	7.97	4.22
簇 20	5	3.00	222.80	532.29	9.08	3.87
簇 21	6	2.00	238.17	404.42	4.09	2.38
簇 22	5	9.60	1370.00	2647.90	18.59	9.63

则多为未能归入任何簇的特殊样本，其特征均值有时会偏离主簇，反映出 DBSCAN 对异常点的识别能力。

与之相对，DBSCAN 在当前参数下产生了较多的噪声点和小簇，反映出密度聚类方法对参数和数据分布的敏感性。在探索性实验中，这种方法有助于发现异常样本或局部结构，但整体分群的稳定性和可解释性相对较弱。

为进一步理解聚类结果在低维空间的投影效果，采用主成分分析（PCA）将高维特征降至二维平面，如图3.5所示。降维后的可视化能够更直观地展现样本分布与聚类边界。




图 3.5 降维可视化（PCA 二维投影）

从降维后的分布可以看出，K-Means 的两类边界相对清晰，主成分方向上的分离度较高。而 DBSCAN 识别出的核心簇与噪声点在投影后的分布更为分散，部分噪声点位于主簇的边缘区域，符合密度聚类的特点。

表 3.4 DBSCAN 摘要

oprle extbf 项	簇数	噪声点	核心簇规模	核心簇总消费 (均值)
总体	23	2000	1607	378.02
说明		核心簇频次均值 1.42，客单均值 14.66		

3.4 客户特征剖析

进一步对各簇在关键特征上的分布进行比较，可以更细致地理解不同群体的特征差异：




图 3.6 客户特征对比与差异点定位

从图3.6可以看出，高消费群体在消费金额和购买频次等指标上整体分布更高，而低消费群体则更接近中位水平。两者的分布存在一定交叠，说明聚类边界并非完全分明，部分样本处于过渡区域。

3.4.1 时序行为特征

针对客户的购买时间分布，我们进一步分析了不同群体在时间维度上的行为差异，如图3.7所示。

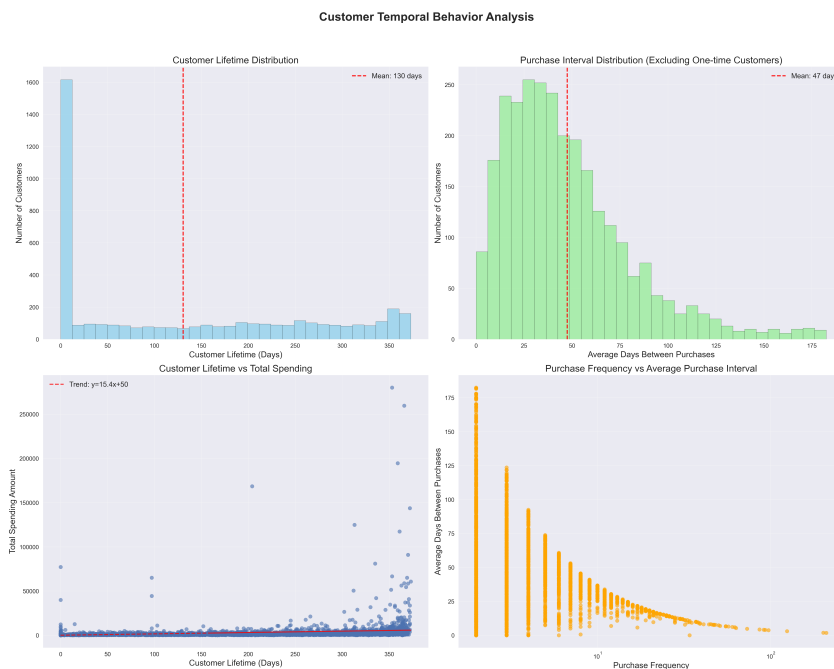


图 3.7 客户时序行为分析

时序分析揭示了不同簇在购买频率和时间分布上的差异。高频高消费群体在多个时间段内均保

持较高的活跃度，而低频群体则呈现出间歇性购买模式。这种时序特征的差异为后续的客户生命周期管理提供了参考依据。

3.4.2 产品多样性分析

客户对产品种类的选择偏好也是分群的重要维度之一。图3.8展示了不同簇在购买产品种类数量上的分布。




图 3.8 产品种类多样性对比

从产品多样性来看，高消费群体倾向于购买更多种类的商品，体现出较强的探索性和消费多样化特征。而低消费群体的产品选择相对集中，购买行为更为保守。这一现象与消费频次和金额的分布模式相互印证，共同构成了各簇的典型画像。

3.5 实验要点与业务建议

将实验设置和数据概况以表格形式简要列出，便于查阅和对照：

表 3.5 实验设置与数据概况

oprule extbf 项	取值/方法	备注
样本数	3779	Mall Customers/零售客户细分
特征维度	3	年龄/年收入/消费评分（核心）
方法	K-Means, DBSCAN	以中心和密度两类思路对照
评估指标	Silhouette, CH, DB	三者联合判断稳定性与分离度

整体来看，K-Means 适合用于识别主要群体结构，分群结果较为稳定；DBSCAN 则在发现局部

异常和复杂结构方面具有一定优势，但对参数和数据分布较为敏感。实验结果为后续进一步的聚类方法比较和参数调优提供了基础。

4 讨论与结论

4.1 模型对比与实验现象分析

本次聚类实验围绕 K-Means 和 DBSCAN 两种方法展开。K-Means 在分群结构上表现出较强的稳定性，分簇边界清晰，主簇规模差异明显。相比之下，DBSCAN 能够识别出更多小簇和噪声点，反映出其对局部密度变化的敏感性。两者在不同数据分布下各有优劣。

K-Means 适合样本分布较均匀、簇形状接近球状的场景，参数设置相对直接。实验中，K-Means 将大部分样本划分为两个主簇，便于整体结构的把握。DBSCAN 则无需预设簇数，能够发现任意形状的簇，对异常点有较好识别能力，但对参数和密度分布较为敏感。实验结果显示，DBSCAN 在本数据集下产生了较多噪声点和小簇，部分小簇在特征均值上波动较大。

从指标表现来看，K-Means 的轮廓系数和 Calinski-Harabasz 指数均高于 DBSCAN，说明其分群紧密且分离度较好。DBSCAN 的 Davies-Bouldin 指数略优，反映部分小簇内部结构较紧凑。整体而言，两种方法各有侧重，适用范围有所不同。

4.2 实验设计的有效性

本实验在设计上注重公平性和全面性。所有聚类方法均采用相同的数据集和预处理流程，保证了结果的可比性。评估环节没有局限于单一指标，而是结合了多种聚类评价标准（如轮廓系数、CH 指数、DB 指数），并辅以可视化和分簇统计表格，从多个角度呈现实验结果。

实验过程中，参数设置和聚类输出均有详细记录，便于复现和后续分析。通过对比不同方法下的分簇结构和指标表现，实验结果能够较为客观地展现各自的优劣和适用场景。

4.3 局限性

尽管实验过程力求严谨，仍有一些局限难以回避。数据集来源较为单一，样本结构和特征维度有限，结论的普适性受到一定影响。参数选择依赖经验和简单调优，尚未系统探索更优的参数空间。部分评价指标对小簇和噪声点较为敏感，可能对 DBSCAN 等方法的评价带来一定偏差。

实验范围未覆盖高维数据或更复杂的聚类算法，聚类结果的可解释性分析也还有提升空间。

4.4 改进方向

后续工作有多种完善方向：

- 多数据集验证：**引入更多类型和结构的数据集，检验结论的稳健性。
- 参数自动优化：**采用网格搜索、贝叶斯优化等方法系统探索参数空间，提升聚类效果。

- **高维与复杂数据**：尝试在高维或异构数据上测试聚类方法，分析其适应性。
- **可解释性分析**：结合特征重要性、可视化等手段，深入理解各簇的形成机制。
- **算法扩展**：引入层次聚类、谱聚类等方法，丰富对比视角。

这些改进有助于进一步提升实验的科学性，也为后续聚类方法的研究和应用提供更坚实的基础。

4.4.1 参数自动优化的可行性

目前实验中的参数选择主要依赖经验和简单调优，存在一定的主观性和局限。实际上，可以通过引入自动化的参数优化方法（如网格搜索、贝叶斯优化等），系统地探索不同参数组合对聚类效果的影响。这类方法能够在较大范围内高效筛选出更优的参数配置，减少人为干预，提高实验的稳健性。例如，在 DBSCAN 中自动调整 `eps` 和 `minPts` 参数，有助于获得更合理的分簇结构，避免噪声点过多或簇划分过细的问题。

DBSCAN 参数网格搜索

```
1 from sklearn.cluster import DBSCAN
2 from sklearn.metrics import silhouette_score
3 import numpy as np
4
5 best_score = -1
6 best_params = None
7 for eps in np.arange(0.3, 1.2, 0.1):
8     for min_samples in range(3, 10):
9         model = DBSCAN(eps=eps, min_samples=min_samples)
10        labels = model.fit_predict(X)
11        # 只有在有2个以上簇时计算分数
12        if len(set(labels)) > 1:
13            score = silhouette_score(X, labels)
14            if score > best_score:
15                best_score = score
16                best_params = (eps, min_samples)
17 print(f"最佳参数: eps={best_params[0]}, min_samples={best_params[1]}")
```

4.4.2 可解释性分析的具体实践

提升聚类结果的可解释性同样具有实际意义。除了常规的聚类可视化，还可以结合特征重要性分析、局部解释模型等手段，深入理解各簇的形成机制。比如，可以统计不同特征在各簇中的分布差异，识别对分簇贡献最大的变量；也可以选取典型样本进行可视化展示，帮助直观把握每个簇的代表性特征。这些做法不仅有助于结果解读，也为后续的业务分析或模型优化提供了参考。

4.5 总结与展望

回顾整个聚类实验，K-Means 和 DBSCAN 两种方法贯穿始终。前者以其分群清晰、参数直观的特点，为我们提供了理解数据整体结构的便捷途径；后者则凭借对局部密度的敏感性，帮助我们捕捉到数据中那些不易被察觉的小簇和异常点。两种模型在实际操作中各有优劣，也让我们体会到算法选择与数据特性之间的微妙关系。

在实验过程中，除了掌握聚类算法本身的原理和实现细节，我们还学会了如何用多种指标去评价聚类效果，如何通过可视化和表格更直观地呈现结果。参数调优、模型解释、实验复现等环节，也让整个流程更加完整。每一次调参和结果分析，都是对理论知识的再消化，也是对实际问题的再认识。

更重要的是，这次实验不仅仅是一次技术训练。它让我们体会到团队协作的力量，也让我们在遇到困难时学会了查阅资料、交流思路、反复试错。每个人都在过程中找到了自己的节奏，也逐渐形成了更系统的思考方式。实验的推进，有时顺利，有时曲折，但每一步都积累了经验。

在最后，这次聚类实验让我们对无监督学习有了更具体的感受，也为后续的数据分析和建模打下了基础。无论是模型的选择，还是实验的设计与总结，都是一次成长的过程。未来还会遇到更多复杂的数据和问题，但这次的经历会成为我们继续前行的底气。

5 附录：工作内容分配

- 数据收集、算法实现：殷和尘
- 数据整理、结果可视化：程亦诚
- 报告撰写：李盛鹏