

智能知识库搭建：人工智能发展的伦理困境与安全防线

实验指导手册

一、实验目标

- 知识目标：**掌握腾讯 IMA 平台的核心功能操作，理解大模型在知识管理和内容生成中的基本原理；系统了解人工智能发展过程中面临的主要伦理困境（算法偏见、隐私泄露、责任归属等）以及构建安全防线的政策与技术路径。
- 能力目标：**能够熟练利用腾讯 IMA 构建专题知识库，设计与优化提示词，生成一份结构完整、内容详实的“人工智能伦理困境与安全防线”分析报告。
- 素养目标：**培养对人工智能伦理问题的批判性思维能力与社会责任感，提升对 AI 治理复杂性的认知水平，增强在技术应用中坚守伦理底线的意识。

二、实验准备

腾讯开悟是由腾讯 AI 平台部与《王者荣耀》团队联合发起的一个 AI 多智能体与复杂决策开放研究平台。在腾讯开悟，研究人员将获得腾讯在算法、算力、场景等方面的研究资源与能力支持，进行算法研究和应用创新等工作。

腾讯 IMA (Intelligent Knowledge Assistant) 是腾讯推出的智能知识管理平台，支持知识库构建、文献智能解析、多模型对话生成等功能。本实验旨在通过腾讯 IMA 平台完成“人工智能伦理困境与安全防线”专题知识库的搭建，并通过多轮提示词调优生成分析报告，培养学生运用 AI 工具进行专业领域知识管理与研究报告撰写的能力。

实验背景：人工智能技术正以前所未有的速度重塑经济社会发展格局。2024 年我国人工智能核心产业规模已接近 6000 亿元。然而，人工智能的“双刃剑”效应同样突出——算法偏见可放大性别、种族、地区等歧视；深度伪造事件频发，截至 2025 年 4 月全球已报告 179 起相关事件；数据泄露、责任认定困难等问题日益凸显。如何在推动 AI 创新发展的同时筑牢伦理与安全防线，已成为全球治理的核心议题。本次实验将围绕这一主题展开深入研究。

三、实训步骤与内容

步骤一：平台登录

登录腾讯开悟教学平台，进入【课程实验】模块。

步骤二：进入实验

进入“AI 知识库创建与分析报告生成”任务 → 查看实验介绍，点击“进入实验”。



步骤三：准备实训环境

进入实验操作界面，在侧边栏选择【IMA】模块。



点击“立即前往”按钮后，系统将自动跳转至腾讯 IMA 官方网站。根据个人实验设备型号（如 Windows/Mac），在官网下载适配的 IMA 客户端安装包，运行安装程序完成客户端部署，登录 IMA。

步骤四：获取实验数据

1. 资料下载

在实验界面左侧导航栏中定位【实验资料】模块，点击进入后查阅课程预置的实验资料，并进行下载。



2. 主题资料收集指南

本实验围绕“人工智能发展的伦理困境与安全防线”，建议从以下几个维度进一步收集资料：

（一）伦理困境维度

子主题	关键问题	推荐关键词
算法偏见与歧视	算法如何在就业、信贷、司法等领域放大社会不公	算法偏见、算法歧视、公平性
隐私与数据安全	AI 大规模数据采集与深度分析对个人隐私的侵蚀	数据隐私、个人信息保护、数据泄露
责任归属困境	AI 决策的“黑箱”特性导致责任难以界定	算法黑箱、责任认定、可解释性
深度伪造与信息操纵	AI 生成虚假内容对社会信任的破坏	深度伪造、虚假信息、AI 诈骗
就业替代与社会分化	AI 对劳动力市场的结构性冲击	就业替代、技能鸿沟、社会公平
人类自主性削弱	算法决策对人类判断力与选择权的侵蚀	算法操控、人类自主性、人机关系

(二) 安全防线维度

子主题	关键内容	推荐关键词
伦理准则与规范	《新一代人工智能伦理规范》等软法体系	伦理规范、智能向善、以人为本
法律法规体系	《生成式人工智能服务管理暂行办法》 《新一代人工智能伦理规范》 《人工智能安全治理框架》2.0 版等	AI 立法、监管政策、法治保障
技术治理手段	算法评估、数据溯源、内容标识等技术防线	技术治理、安全评估、风险监测
全球治理合作	联合国、世界互联网大会等国际治理框架	全球治理、国际合作、治理体系

3. 扩展资料补充建议（可选）

可根据研究需求，在确保学术规范的前提下收集资料：

- **权威报告：**中国信通院《人工智能安全治理研究报告（2025 年）》、世界互联网大会《为人类共同福祉构建全球人工智能安全与治理体系》报告；
- **学术论文：**AI 伦理与治理领域权威论文；
- **典型案例：**收集算法偏见（如亚马逊 AI 招聘系统歧视女性申请者）、深度伪造诈骗、自动驾驶伦理困境等真实案例；
- **国际比较：**收集欧盟《人工智能法案》、美国《AI 权利法案蓝图》等域外治理实践。

4. IMA 知识库拓展（可选）

可通过以下方式丰富研究资源：

- (1) 在 IMA 客户端的导航栏选择“知识库广场”
- (2) 在搜索框输入精确关键词（如“人工智能伦理”“AI 安全治理”“算法偏见”）
- (3) 点击知识库详情页的“加入”按钮完成关联

步骤五：构建知识库

1. 创建知识库

打开 IMA 客户端，进入知识库功能模块，点击界面中的创建按钮，输入符合实验主题的命名（如“人工智能伦理困境与安全防线”）。

2. 数据分类与管理

在已创建的知识库中，可通过新建文件夹功能对实验资料进行分类，例如：

- 建立“**伦理困境**”文件夹存放算法偏见、隐私泄露、责任归属等资料
- 建立“**安全防线**”文件夹存放政策法规、技术治理、伦理准则等资料
- 建立“**典型案例**”文件夹存放国内外 AI 伦理与安全事件案例
- 建立“**国际比较**”文件夹存放各国 AI 治理实践资料
- 通过上传功能将本地文件导入对应文件夹

3. 标签与检索优化（可选）

为文件添加技术领域、数据年份等标签，例如：

- 伦理困境类：“算法偏见”“隐私泄露”“深度伪造”“责任归属”
- 安全防线类：“政策法规”“伦理规范”“技术治理”“全球合作”
- 按年份标注：“2025 年数据”“2026 年政策”

4. 分享设置（可选）

可通过知识库的分享功能选择共享给指定同学，促进主题资料的共建共享。

步骤六：IMA 智能高效理解文献

1. 文献智能解析

打开 IMA 客户端，在知识库中选择目标文献并点击界面提供的「问问 IMA」功能。可选择以下两种方式快速理解文献：

- **自动摘要**：生成文献核心观点的文字总结
- **脑图展示**：以可视化思维导图呈现文献逻辑框架

例如，对于《人工智能安全治理框架》2.0 版相关文献，可通过脑图功能快速梳理其“三类风险分类”（技术内生安全风险、技术应用安全风险、应用衍生安全风险）和全生命周期治理理念。

2. 注意事项：

- 文献须来自自己加入/创建的合规知识库，避免分析未授权内容
- 需自行判断智能生成内容的准确性，不可直接引用

步骤七：使用 IMA 生成研究报告

1. 知识库调用方式

在 IMA 系统中，可以根据需要选择不同的知识库调用方式：

- 要同时使用多个知识库的内容，可在首页输入框输入“@”，从列表中选择需要使用的知识库
- 要使用特定知识库的内容，可直接选择对应知识库

2. 查询方式支持

- 对特定文件夹的文档进行提问
- 使用“#”选择带有特定标签的文档

3. 生成报告的具体步骤

(1) 输入初始提示词

示例初始提示词：

“基于知识库中的资料，生成一份《人工智能发展的伦理困境与安全防线分析报告》，要求涵盖：AI 面临的主要伦理挑战（算法偏见、隐私泄露、深度伪造、责任归属等），国内外构建安全防线的政策法规与技术措施，当前治理面临的挑战与未来展望。”

(2) 评估初稿的完整性和准确性

检查初稿是否覆盖了核心伦理困境维度（算法偏见、隐私泄露、深度伪造、责任归属、就业替代等）和安全防线维度（政策法规、技术治理、伦理准则等）。

(3) 调整提示词进行多次生成

根据初稿不足，补充具体要求。示例优化提示词：

“在上述报告基础上，补充以下内容：（1）增加具体案例，如亚马逊 AI 招聘系统的性别偏见、深度伪造诈骗案例；（2）详细分析《人工智能安全治理框架》2.0 版的三大风险分类；（3）对比欧盟、美国、中国在 AI 伦理治理上的路径差异；（4）加入 2025-2026 年的最新数据和政策动态。”

(4) 尝试使用不同大模型生成内容并对比结果

尝试使用 Hunyuan、DeepSeek、GLM 等不同大模型生成内容，对比其在伦理议题分析深度、案例丰富度、政策解读准确性等方面的差异。

4. 报告优化方式

- 使用“记笔记”功能审核修正报告内容
- 使用“AI 帮写”优化段落结构和语言表达

5. 导出报告

导出 PDF 格式的分析报告。

6. 注意事项

- 所有操作必须基于已构建的知识库内容
- 生成内容需经过人工验证和修改
- 涉及伦理议题时需保持客观、严谨的学术态度

四、成果提交与评估

回到腾讯开悟教学平台，在教师创建的测评任务下，在规定时间内查看任务详情并提交报告。

1. 报告格式规范要求

（1）封面：需包含课程名称（2026 腾讯开悟专业实践）、报告题目（《人工智能发展的伦理困境与安全防线分析报告》）、学生姓名、学号及完成日期。

（2）正文应包含：

- 摘要：凝练人工智能伦理困境的核心议题与安全防线的关键路径
- 引言：阐述人工智能发展带来的伦理挑战的时代背景与研究意义
- 主体内容：
 - 第一部分：人工智能的主要伦理困境
 - 第二部分：筑牢人工智能安全防线的路径
 - 第三部分：当前治理面临的挑战与展望
- 参考文献：规范标注数据来源（包括官网、学术论文、行业报告等）
- 工具心得：详细记录 IMA 工具使用经验与学习收获

2. 评分说明

（1）教师查看提交的报告，进行评分

(2) 评估重点包括：

- 报告内容的完整性、准确性与逻辑性
- 对 AI 伦理困境分析的深度与批判性
- IMA 工具使用的熟练程度
- 信息筛选及分析能力体现

五、常见问题

1. IMA 生成报告与预期不符怎么办？

当报告内容产生偏差时，应重新检查提示词设置，增加具体限制条件和明确范围要求。例如可以在提示词中指定“基于知识库中的算法偏见案例”或“重点分析 2023-2026 年的政策法规发展”。

2. 如何提升报告生成质量？

建议从三个方面入手：优化提示词表达，添加足够的背景信息和要求（如要求包含具体案例、数据来源等）；检查知识库内容是否完整准确（确保涵盖伦理困境与安全防线两大维度）；尝试使用不同大模型进行生成对比。

3. 生成的报告数据不准确怎么办？

对于可疑数据应当比对原始资料核实，同时在提示词中要求提供具体数据来源，必要时可使用 IMA 的追问功能要求标明出处。

4. 如何确保伦理议题分析的客观性？

建议从多角度收集资料，既关注技术风险也关注治理实践，对比国内外不同治理路径，避免片面结论。可参考权威机构（如中国信通院、世界互联网大会等）发布的研究报告。