

人工智能通识课

安全防线：智能时代治理体系构建

讲 义

目 录

讲义信息..... 1

讲义内容..... 1

 一、 情景导入..... 1

 二、 本课简介..... 2

 三、 本课目标..... 2

 四、 本课目录..... 2

 五、 本课内容..... 3

 1. 规则构建：人工智能的法律与监管体系 3

 六、 本课总结..... 10

 七、 课后思考..... 10

 八、 参考资料..... 10

讲义信息

课件名称	安全防线：智能时代治理体系构建
课时规划	0.5 课时
教学形式	理论

讲义内容

一、情景导入

当系统越来越“懂你”，你还安全吗？

请思考以下问题：

- 如果数据被滥用，会不会侵犯我们的隐私权？
- 如果算法存在偏见，是否会加剧社会不公？
- 如果模型被攻击，会带来哪些安全风险？
- 如果深度伪造技术泛滥，我们还能相信眼前看到的信息吗？

这些问题正在变得越来越现实。智能推荐、虚拟助手、人脸识别等技术的发展，让“系统了解你”成为可能，但也使得数据安全、隐私保护、公平正义、信息可信性等问题浮出水面。

本课带你解码：如何为智能时代建立起一道「安全防线」，保障技术发展更安全、更可信。

二、本课简介

欢迎进入《安全防线：智能时代治理体系构建》任务的学习！

人工智能作为新一轮科技革命和产业变革的核心驱动力之一，正迅速改变经济、社会等各领域。我国具有人工智能高质量发展的优越条件，为人工智能高水平安全奠定坚实基础，同时也对高水平安全治理提出更高要求。

本课程将首先探讨人工智能安全面临的挑战与对策，随后介绍人工智能的法律与监管体系，为规范人工智能应用、保障其健康有序发展提供重要支撑。

三、本课目标

通过本课的学习，我们将完成以下目标：

1. 了解人工智能的法律与监管体系（了解）

四、本课目录

1. 规则构建：人工智能的法律与监管体系

五、本课内容

1. 规则构建：人工智能的法律与监管体系

1.1 AI 监管与治理倡议的全球概览

随着人工智能技术迅速发展，全球多个国家和国际组织相继提出监管和治理倡议，以应对 AI 带来的伦理风险、安全风险、社会公平和隐私保护等问题。这些倡议共同目标是：促进 AI 技术安全、可控、可信的发展，保障人类社会的共同利益。

欧盟：欧盟 AI 法案 (AI Act)

- 采用 风险分级管理 方法，将 AI 系统划分为「不可接受风险」「高风险」「有限风险」「低风险」四个等级；
- 禁止或严格限制高社会危害性的 AI，如面部识别监控、社会信用评分；
- 对高风险 AI 要求严格的透明性、数据治理、风险管理、合规评估。

美国：原则与指南导向

- 鼓励技术创新与产业发展，但强调保护公民权益；
- 提出公平性、可解释性、隐私保护、可审计性等核心原则；

中国：安全、可控、创新并重

- 强调国家安全、社会稳定和伦理原则；
- 提出生成式 AI 需经过安全评估，强化内容审查和责任划分；

-
- 鼓励 AI 应用的创新发展与产业赋能。

OECD（经济合作与发展组织）：AI 原则

- 倡导人类中心（human-centric）AI；
- 尊重法治、人权、民主价值观；
- 推动 AI 的透明性、可解释性、稳健性与安全性。

UNESCO（联合国教科文组织）：伦理框架

- 制定《人工智能伦理建议书》；
- 聚焦人权、社会包容、公平、环境可持续性全球性价值；
- 鼓励各国根据本地情况制定相应法规和伦理标准。

G7 / G20：多边合作倡议

- 促进 AI 技术的跨国合作，避免「技术孤岛」；
- 建议成员国共同制定治理标准，保障安全与公平竞争；
- 关注供应链安全、跨境数据流动、全球治理协调等问题。

美国、欧盟和中国在 AI 监管体系上的差异，主要由政策导向、经济文化背景与价值观等多方面因素造成。

地区	监管模式	详细描述
欧盟	以市场换监督	欧盟的监管框架在制定过程中要考虑更广泛的公众利益和社会影响。更倾向于保护公民权利，但可能会限制市场的灵活性和创新速度。
美国	市场驱动	美国在AI监管上更侧重于市场的自我调节和技术创新，主要以倡议性文件和分散监管的方式来应对AI的监管。有利于创新和技术突破，但可能会牺牲部分隐私和安全性。
中国	寻求平衡	中国的监管结合了政府的引导和支持，旨在平衡产业发展与社会福祉。一方面，政府通过设立专项基金、制定产业发展规划等方式，积极促进AI技术的研发和应用。另一方面，政府也在逐步建立健全相应的法律法规。

1.2 法律责任划分

随着人工智能技术在自动驾驶、医疗诊断、金融风控等关键领域大规模应用，AI 系统的「自主性」不断增强，一旦发生错误或损害事件，如何界定责任主体、明确法律责任，成为监管和治理的核心问题。

不同的分类方法会对相关主体赋予不同的法律责任和义务。责任划分模式主体分成四类：

- **开发者责任**：负责算法设计、训练模型的技术方；对算法中的安全性、公平性缺陷负责；包括训练数据偏差、模型不可解释性带来的风险。
- **部署者 / 运营者责任**：系统的应用落地方；对 AI 系统配置、运行环境、更新维护等方面承担主要责任；保障 AI 系统运行中持续的安全性与稳定性。
- **用户责任**：AI 系统的终端使用者；在使用过程中，如有违规操作、越权修改或恶意使用，需承担相关法律后果。
- **AI 系统自身（争议性主体）**：目前法律框架下，AI 系统尚不具备法律主

体资格，但随着“自主性”增强，该类主体的责任定位存在争议。

1.3 数据保护与隐私权

人工智能技术依赖海量数据来驱动算法学习、模型训练和功能优化，这些数据中往往包含大量个人信息、行为轨迹、面部特征、语音数据等敏感信息。随着隐私泄露、数据滥用事件频发，如何保障数据安全、保护个人隐私权，成为 AI 法律与治理体系中最关键的议题之一。

核心原则

- 数据最小化（只采集必要数据）
- 知情同意（用户授权）
- 合法、正当、透明
- 精确性与完整性
- 限制保存期限（数据不得长期保存）

技术与治理方法

- 数据加密
- 匿名化 / 去标识化
- 差分隐私（加入噪声保护个体信息）
- 联邦学习（不共享原始数据，仅共享模型参数）
- 隐私影响评估（PIA）机制（在数据处理前评估风险）

主要法律要求

- 明确用户的以下权利：访问权、更正权、删除权、限制处理权、数据可携带权等
- 明确界定“敏感个人信息”：要求 最小必要原则、知情同意、告知退订等

1.4 内容生成与版权问题

随着生成式人工智能（如 ChatGPT、Midjourney、Sora 等）快速发展，AI 可以自动生成 文本、图片、音乐、视频、代码等多种形式的内容，这些内容的原创性、归属权以及商业使用引发了大量法律和伦理争议。

法律难题

- 版权归属不明确：传统版权法基于「人类作者」概念，AI 本身并非法律主体，无法成为作品作者
- 原创性认定困难：很多生成内容是基于已有训练数据「拼接」或「演绎」而成，原创性存在争议
- 潜在侵权风险：AI 生成内容可能引用、模仿或重构受版权保护的作品，如名画、影视片段、音乐元素等，用户在不知情下将这些内容商用，可能构成侵权

应对思路

- 明确版权归属机制：法律需明确界定 AI 辅助创作与完全自动生成 两

类场景

- 建立生成内容标识和溯源机制：确保内容可追溯，便于管理和维权
- 加强合规要求和合同条款：明确使用 AI 生成内容的责任与限制
- 完善版权法规：补充现有著作权法

1.5 面向未来的 AI 治理框架

随着人工智能技术快速演进，单一的法律条款或临时政策难以长期适应。

未来 AI 治理需要一种 系统化、长期性、动态更新 的综合治理框架，确保 AI 技术安全、可信、可持续地发展，同时促进技术创新与社会利益的平衡。

核心理念

- 以人为本：把保障人类福祉、维护社会公平和尊重人权放在治理首位
- 风险导向：对不同场景、不同风险水平的 AI 系统进行分级治理，重点监管高风险应用（如自动驾驶、医疗诊断、金融决策等）
- 动态治理：随技术发展不断完善法规和标准，保持灵活性和适应性，避免「一刀切」

关键要素

- 法律法规完善：持续完善与更新 AI 相关法律体系，明确责任主体、权利义务、合规要求
- 技术支撑与安全保障：强化可解释性、透明性和可追溯性技术
- 多方协同治理：政府、企业、科研机构、公众和社会组织共同参与治

理，形成多层次治理网络

- 全球协作与标准对齐：加强国际合作，推动制定全球 AI 治理标准和伦理规范

实施思路

- 建立分级监管机制：结合欧盟 AI 法案理念，根据风险等级设定不同的合规要求和监管强度
- 定期安全评估与审计：要求高风险系统定期进行安全性、隐私性、伦理合规性等多维度审计，及时修正潜在问题
- 推动技术伦理融合：在算法设计、模型训练、产品上线全流程中融入伦理审查机制
- 加强科普与公众教育：增强社会整体数字素养

治理路径

- 规则引领：建立完善的治理理论和制度基础
- 技术支撑：推动合规增强技术研发，如模型可解释性、多样性、隐私保护、安全可控性等
- 场景落地：面向智慧医疗、自动驾驶、智慧城市等重点行业，针对实际应用需求设计解决方案，验证技术和规则的可行性和有效性
- 评估与认证：形成可持续的评估认证机制

六、本课总结

本课程围绕人工智能在法律监管层面面临的责任划分、隐私保护和内容生成版权归属等核心议题。通过课程学习，学生应能了解 AI 技术在安全防护与法律治理方面的主要问题及应对思路，为未来深入参与 AI 相关工作和研究奠定基础。

七、课后思考

问题 1：人工智能安全中的对抗攻击是什么意思？

参考答案：

对抗攻击是指通过对输入数据进行微小但刻意的扰动，从而误导人工智能模型做出错误判断的一种攻击方式。这类攻击往往肉眼难以察觉，但能显著降低模型的准确性与鲁棒性。比如，一张看起来正常的图片加入特殊扰动后，AI 模型可能会将“猫”识别为“狗”。对抗攻击在自动驾驶、人脸识别等关键领域可能带来严重后果，是当前 AI 安全研究的重要方向。

八、参考资料

- 人工智能安全白皮书，中国信息通信研究院，2021 年
- 人工智能伦理与治理报告，联合国教科文组织，2022 年
- 人工智能法案草案 (AI Act)，欧盟委员会，2021 年
- 生成式人工智能服务管理暂行办法，中国国家互联网信息办公室，2023 年